

UNIVERSIDADE FEDERAL DE SANTA CATARINA
CAMPUS FLORIANÓPOLIS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO

Lucas Bueno Cesario

POLYGLOT IMPORT CSV: UMA SOLUÇÃO PARA IMPORTAÇÃO DE DOCUMENTOS CSV PARA MÚLTIPLOS BANCOS DE DADOS

Florianópolis
2026

Lucas Bueno Cesario

POLYGLOT IMPORT CSV: UMA SOLUÇÃO PARA IMPORTAÇÃO DE DOCUMENTOS CSV PARA MÚLTIPLOS BANCOS DE DADOS

Trabalho de Conclusão de Curso submetido ao Curso de Graduação em Ciência da Computação do Centro Tecnológico da Universidade Federal de Santa Catarina para obtenção do título de Bacharel em Ciência da Computação.
Orientador: Prof. Ronaldo dos Santos Mello, Dr.

Florianópolis
2026

Ficha catalográfica para trabalhos acadêmicos.

Cesario, Lucas Bueno
Polyglot Import CSV : Uma solução para importação de documentos CSV para múltiplos bancos de dados / Lucas Bueno Cesario ; orientador, Ronaldo dos Santos Mello, 2026.
49 p.

Trabalho de Conclusão de Curso (graduação) - Universidade Federal de Santa Catarina, Centro Tecnológico, Graduação em Ciências da Computação, Florianópolis, 2026.

Inclui referências.

1. Ciências da Computação. 2. Persistência poliglota. 3. Importação de dados CSV. 4. NoSQL. 5. Software Livre. I. Mello, Ronaldo dos Santos. II. Universidade Federal de Santa Catarina. Graduação em Ciências da Computação. III. Título.

Lucas Bueno Cesario

POLYGLOT IMPORT CSV: UMA SOLUÇÃO PARA IMPORTAÇÃO DE DOCUMENTOS CSV PARA MÚLTIPLOS BANCOS DE DADOS

Este Trabalho de Conclusão de Curso foi julgado adequado para obtenção do Título de "Bacharel em Ciência da Computação" e aprovado em sua forma final pelo Curso de Graduação em Ciências da Computação.

Florianópolis, _____ de _____ de 2026.

_____

Profa. Lúcia Helena Martins Pacheco, Dra.
Coordenadora do Curso

Banca Examinadora:

_____

Prof. Ronaldo dos Santos Mello, Dr.
Orientador
Universidade Federal de Santa Catarina

_____

Profa. Carina Friedrich Dorneles, Dra.
Avaliadora
Universidade Federal de Santa Catarina

_____

Prof. Jônata Tyska Carvalho, Dr.
Avaliador
Universidade Federal de Santa Catarina

“Sabendo que a provação da fé que vocês têm produz perseverança. Ora, a perseverança deve ter ação completa, para que vocês sejam perfeitos e íntegros, sem que lhes falte nada.”

Tiago, 1:3-4

RESUMO

A persistência poliglota é essencial na arquitetura contemporânea de bancos de dados, integrando diversas tecnologias de armazenamento em uma mesma aplicação. A ferramenta *Polyglot Import CSV* destaca-se como solução para otimizar a importação de dados CSV em diversos bancos de dados simultaneamente, superando desafios da persistência poliglota. Optou-se pelo formato CSV por ser amplamente utilizado na importação de dados pelos diversos SGBDs e por ser um formato simples e familiar tanto a humanos quanto a sistemas. Por meio de configurações declarativas em arquivos JSON, a ferramenta oferece suporte ao principal representante de código aberto dos bancos de dados relacionais — o PostgreSQL — e aos principais representantes dos bancos de dados NoSQL: Redis (chave-valor), MongoDB (documento), Apache Cassandra (colunar) e Neo4j (grafo). A importação admite dois modos de entrada — um arquivo CSV por entidade ou um único CSV combinado — e realiza a conversão nativa aos tipos de cada SGBD, com observabilidade e métricas por fase de execução. Antes de gravar qualquer dado, a ferramenta confere as configurações e os dados em três etapas de validação, inclusive uma leitura completa dos dados pelo mesmo código da gravação, e interrompe a importação, sem gravar nada, diante de qualquer problema que essas etapas encontrem. O desempenho apoia-se na escrita em lote, com conversão vetorizada de tipos, e na leitura dos arquivos em blocos, ~~cujo~~ projetada para que o consumo de memória ~~acompanha~~ acompanhe o tamanho do bloco e o número de chaves distintas, e não o tamanho do arquivo; o tamanho do bloco é escolhido pela própria ferramenta, a partir da maior fonte e da memória livre do computador. Uma avaliação empírica com dados sintéticos~~mostrou que~~ , de 1.024 a 262.144 linhas, mostrou que o tempo de importação cresce linearmente com o volume de dados e que a validação prévia ocupa cerca de um quinto do tempo de uma importação~~de cem mil linhas~~, dominada pela escrita nos bancos; medições ~~históricas~~ feitas com uma versão anterior da ferramenta mostraram que a escrita em lote ~~acelerou~~ acelera a importação em cerca de nove vezes em relação à gravação linha a linha e que a leitura em blocos reduz~~iu~~o pico de memória em mais de doze vezes ~~no maior volume medido~~em cem mil linhas, em relação à carga do arquivo inteiro na memória. Não foram identificadas ferramentas equivalentes que realizem, a partir de arquivos CSV e de regras declarativas, a importação simultânea para múltiplos paradigmas de dados, o que evidencia a originalidade da proposta. A publicação do código aberto da ferramenta impulsiona avanços colaborativos na dinâmica arquitetura moderna de bancos de dados.

Palavras-chave: Persistência poliglota. Ferramenta *Polyglot Import CSV*. Importação de dados CSV. Avaliação de desempenho. JSON. SQL. NoSQL. Software Livre.

ABSTRACT

Polyglot persistence is essential in contemporary database architecture, integrating various storage technologies within the same application. The Polyglot Import CSV tool stands out as a solution for optimizing CSV data import into multiple databases simultaneously, overcoming polyglot persistence challenges. The CSV format was chosen because it is widely used for data import by various DBMSs and because it is a simple and familiar format for both humans and systems. Through declarative configurations in JSON files, the tool supports the leading open-source representative of relational databases — PostgreSQL — and the main representatives of NoSQL databases: Redis (key-value), MongoDB (document), Apache Cassandra (columnar), and Neo4j (graph). The import supports two input modes — one CSV file per entity or a single combined CSV — and performs native type casting to each DBMS, with observability and per-phase execution metrics. Before writing any data, the tool checks the configuration and the data in three validation stages, including a full read of the data through the same code as the write, and stops the import, writing nothing, at any problem these stages find. Performance rests on batch writing, with vectorized type casting, and on reading the files in chunks, ~~whose~~ designed so that memory use follows the chunk size and the number of distinct keys, not the file size; the tool chooses the chunk size itself, from the largest source and the free memory of the computer. An empirical evaluation with synthetic data, from 1,024 to 262,144 rows, showed that the import time grows linearly with the data volume and that the prior validation takes about one fifth of the time of ~~a 100,000-row~~ an import, which is dominated by database writes; ~~historical measurements~~ measurements made with an earlier version of the tool showed that batch writing ~~sped~~ speeds up the import by roughly nine times over row-by-row writing and that chunked reading ~~reduced~~ reduces peak memory by more than twelve times at ~~the largest measured volume,~~ 100,000 rows, compared with loading the whole file in memory. No equivalent tools were identified that perform, from CSV files and declarative rules, the simultaneous import to multiple data paradigms, which highlights the originality of the proposal. The open-source publication of the tool drives collaborative advances in the dynamic modern database architecture.

Keywords: *Polyglot persistence. Polyglot Import CSV tool. CSV data import. Performance evaluation. JSON. SQL. NoSQL. Free Software.*

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de aplicação da Persistência Poliglota em um e-commerce. 19
Figura 2 – Diferentes tipos de modelos de dados NoSQL. 20
Figura 3 – Modelo chave-valor: chaves apontando para valores arbitrários (Redis). 21
Figura 4 – Modelo colunar: chaves de linha e famílias de colunas (Cassandra). 22
Figura 5 – Modelo de documento: documentos autocontidos com campos variáveis (MongoDB). 23
Figura 6 – Modelo de grafo: nós e arestas tipadas com propriedades (Neo4j). . 24
Figura 7 – Visão geral da ferramenta: entradas, processamento e saídas. . . . 33
Figura 8 – Estrutura do JSON Schema de importação (`import_config`). 36
Figura 9 – Estrutura do JSON Schema de conexão (`dbms_config`). 49
Figura 10 – As três etapas de validação, todas antes da gravação. 52
Figura 11 – Passos do fluxo de execução da importação. 54
Figura 12 – Caminho da primeira linha de `stock` no cenário exemplo, com três problemas induzidos em cópias alteradas dos arquivos. 59
Figura 13 – Interface gráfica no estado ocioso: configuração multifonte escolhida, ícones de ajuda e comando montado, colorido, em modo somente leitura. 73
Figura 14 – Execução em andamento: formulário bloqueado, botão de interrupção e saída colorida da CLI chegando ao console em tempo real. 74
Figura 15 – ~~Execução~~ Simulação (`--dry-run`) concluída com sucesso, com o tempo total e o arquivo de *log* da sessão na barra de estado. 75
Figura 16 – Erro detectado antes da execução: a configuração de importação viola o *JSON Schema*, a mensagem da CLI, com o caminho do campo recusado, aparece no cartão de configuração e o botão de execução permanece desabilitado. 76
Figura 17 – Verificação dos SGBDs pela interface gráfica: o botão **Check DBMSs**, acionado, aparece destacado em vermelho; no console, MongoDB e Neo4j fora do ar e, abaixo da tabela de estados, os comandos que os iniciam. 77
Figura 18 – Tempo total de importação em função do volume, em escala logarítmica nos dois eixos. A reta tracejada representa o crescimento linear (tempo proporcional ao volume) a partir do ponto de 16.384 linhas do modo multifonte. Campanha de tempo. . . 88

LISTA DE TABELAS

Tabela 1 – Tipos de evento do cenário exemplo. 35
Tabela 2 – Partes do arquivo de importação. 37
Tabela 3 – Campos de mapeamento de coluna (`columnSpec`). 42
Tabela 4 – Correspondência entre tipo inferido e tipo de destino na geração de DDL. 44
Tabela 5 – Partes do arquivo de conexão. 48
Tabela 6 – Campos do descritor `connection` por SGBD. 50
Tabela 7 – Estados reportados por `--check-dbms` com dois SGBDs fora do ar. . 57
Tabela 8 – Linhas da fonte `stock` (`ecommerce_stock.csv`, colunas de identificação resumidas; todas as colunas, inclusive `last_restock_date`, estão na Tabela 25). 60
Tabela 9 – Relação `inventory` gravada no PostgreSQL a partir da fonte `stock`. 61
Tabela 10 – Partição do usuário `user1` na tabela `user_activity_log` (Cassandra). 62
Tabela 11 – Gravação de uma linha da fonte `stock` nos diferentes SGBDs. . . . 64
Tabela 12 – Linhas a gravar em cada destino, após os filtros, reportadas pelo modo `--dry-run` no cenário exemplo. 65
Tabela 13 – Imagens Docker dos SGBDs utilizadas na avaliação. 82
Tabela 14 – O que cada SGBD grava no cenário exemplo, e de quais fontes. . . 83
Tabela 15 – Tempo por fase de uma importação (~~$N = 100\,000$, bloco de 8 MB~~$N = 262.144$), em segundos. Campanha ~~sem instrumentação~~ de ~~memória~~tempo. 84
Tabela 16 – Escrita por SGBD em uma importação (~~$N = 100\,000$,~~ multifonte ~~, bloco de 8 MB~~($N = 262.144$): linhas processadas~~pela escrita~~, antes da eliminação de duplicatas. Campanha ~~sem instrumentação~~ de ~~memória~~tempo. 84
Tabela 17 – Multifonte *versus* combinado (~~$N = 100\,000$, bloco de 8 MB~~$N = 262.144$). Tempos ~~e~~ da campanha de tempo; picos da campanha de memória~~provêm de campanhas distintas, conforme indicado~~. 86
Tabela 18 – Tempo total, tempo por linha e pico de memória por volume. Tempos da campanha de tempo; picos da campanha de memória. 87
Tabela 19 – Fração do tempo total ocupada pelas leituras de inferência e de validação~~(bloco de 8 MB)~~. Campanha ~~sem instrumentação~~ de ~~memória~~tempo. 89

Tabela 20 – Tempo total e das fases dominantes por estratégia Efeito do tamanho do bloco de escrita, em segundos leitura ($N = 10\,000 N = 131.072$, materialização; medição históricamultifonte, lote de 2.048 linhas).Campanha sem instrumentação de memória. 91
Tabela 21 – Pico Efeito do tamanho do lote de memória por modelo de execução gravação (N crescente$N = 131.072$, multifonte, estratégia em lote; medição histórica), em bloco de 128 MB).Campanha com instrumentação de memória. 92
Tabela 22 – Tempo total por modelo Bloco de execução (N crescenteleitura escolhido pela regra automática na campanha final, multifonte, estratégia em lote; medição histórica)MB, em segundos. Campanha sem instrumentação com cerca de 920 MB de memória livre. 93
Tabela 23 – Grupos de colunas do `ecommerce_join.csv` preenchidos por ação. . 115
Tabela 24 – Usuários do `ecommerce_join.csv` e seus dados de identificação e endereço. 116
Tabela 25 – Linhas `action == stock` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4). 117
Tabela 26 – Linhas `action == stock` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8). 118
Tabela 27 – Linhas `action == purchase` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4). 119
Tabela 28 – Linhas `action == purchase` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8). 120
Tabela 29 – Linhas `action == select_product` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4). 121
Tabela 30 – Linhas `action == select_product` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8). 121
Tabela 31 – Linhas `action == add_to_cart` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4). 122
Tabela 32 – Linhas `action == add_to_cart` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8). 122

LISTA DE ABREVIATURAS E SIGLAS

ABNT	Associação Brasileira de Normas Técnicas
API	*Application Programming Interface* (Interface de Programação de Aplicações)
BSON	*Binary JSON*
CI	*Continuous Integration* (Integração Contínua)
CLI	*Command Line Interface* (Interface de Linha de Comando)
CSV	*Comma-Separated Values* (Valores Separados por Vírgula)
DBMS	*Database Management System* (Sistema de Gerenciamento de Banco de Dados)
DDL	*Data Definition Language* (Linguagem de Definição de Dados)
GUI	*Graphical User Interface* (Interface Gráfica de Usuário)
JSON	*JavaScript Object Notation*
NoSQL	*Not Only SQL*
SGBD	Sistema de Gerenciamento de Banco de Dados
SGPD	Sistema de Gerenciamento Poliglota de Dados
SQL	*Structured Query Language* (Linguagem de Consulta Estruturada)
TCC	Trabalho de Conclusão de Curso
UFSC	Universidade Federal de Santa Catarina
XML	*Extensible Markup Language*
YCSB	*Yahoo! Cloud Serving Benchmark*

SUMÁRIO

1 INTRODUÇÃO . . . 14
1.1 Visão Geral . . . 14
1.2 Objetivos . . . 15
1.2.1 Objetivo Geral . . . 15
1.2.2 Objetivos Específicos . . . 15
1.3 Metodologia . . . 15
1.4 Estrutura do Trabalho . . . 17

2 FUNDAMENTAÇÃO TEÓRICA . . . 18
2.1 Persistência Poliglota . . . 18
2.2 Bancos de Dados NoSQL . . . 20
2.2.1 Chave-valor . . . 20
2.2.2 Colunar . . . 21
2.2.3 Documento . . . 22
2.2.4 Grafo . . . 23
2.3 Bancos de Dados Multimodelo e Arquiteturas de Persistência Poliglota . . . 24

3 TRABALHOS RELACIONADOS . . . 26
3.1 Importação de Arquivo CSV para um Único SGBD . . . 26
3.1.1 PostgreSQL . . . 26
3.1.2 Redis . . . 27
3.1.3 MongoDB . . . 28
3.1.4 Cassandra . . . 28
3.1.5 Neo4j . . . 29
3.2 Importação de Arquivo CSV para SGBD Multimodelo . . . 29
3.3 Considerações sobre os Trabalhos Relacionados . . . 30

4 A FERRAMENTA POLYGLOTIMPORTCSV . . . 32
4.1 Visão Geral . . . 32
4.2 Formato de Configuração (JSON Schema) . . . 35
4.2.1 O Arquivo de Importação . . . 36
4.2.1.1 Raiz e bloco `sources` . . . 38
4.2.1.2 Blocos de SGBD . . . 39
4.2.1.3 Entidade . . . 40
4.2.1.4 Colunas . . . 42

4.2.2 Particularidades de Cada SGBD no Arquivo de Importação 44
4.2.3 O Arquivo de Conexão 48
4.2.3.1 Raiz e blocos de SGBD 50
4.2.3.2 Parâmetros de conexão 50
4.2.3.3 Inicialização dos SGBDs 50
4.2.4 As Três Etapas de Validação 51
4.3 Fluxo de Execução da Importação 53
4.3.1 Verificação dos SGBDs 56
4.3.2 O Cenário Exemplo e os Arquivos de Dados 58
4.3.3 A Importação em Cada SGBD 60
4.3.4 Exemplo de Uso e Evidência de Execução (Cenário Exemplo) 64
4.4 Observabilidade e Métricas 66
4.5 Estratégia de Escrita e Modelo de Execução 67
4.5.1 Evolução da Estratégia de Escrita e do Modelo de Execução 68
4.5.2 Modelo de Execução: Leitura em Blocos 69
4.6 Interface Gráfica 71

5 AVALIAÇÃO DE DESEMPENHO 78
5.1 Metodologia 78
5.1.1 Geração dos Dados 79
5.1.2 Protocolo de Medição 80
5.2 Configuração Experimental 82
5.3 Resultados 83
5.3.1 ~~Decomposição~~ Custo por Fase e ~~Escrita~~ por SGBD (QP1) 83
5.3.2 Modos de Importação: Multifonte *versus* Combinado (QP2) 85
5.3.3 Escalabilidade (QP3) 87
5.3.4 Custo da Validação Prévia ~~e Tamanho do Bloco~~ (~~QP7~~QP4) 89
5.3.5 Tamanhos do Bloco e do Lote (QP5) 90
5.3.6 ~~Resultados Históricos: Estratégia de Escrita (QP4)~~ 90
5.3.6 ~~Resultados Históricos: Materialização *versus* Leitura em Blocos (QP5 e QP6)~~ 91
5.3.6 ~~Uma Observação sobre o Pico de Memória da Estratégia em Lote~~ . 93
5.4 Análise e Discussão 94
5.4.1 Ameaças à Validade 95

6 ~~ATIVIDADES FUTURAS~~ 97

6 ~~CONSIDERAÇÕES FINAIS~~CONCLUSÃO 99
6.1 Atividades Futuras 100

REFERÊNCIAS 102

APÊNDICES 105

APÊNDICE A – JSON SCHEMAS DE CONFIGURAÇÃO NA FORMA SERIALIZADA 106
A.1 Schema de Importação (import_config.schema.json) 106
A.2 Schema de Conexão (dbms_config.schema.json) 110

APÊNDICE B – O ARQUIVO DE DADOS ECOMMERCE_JOIN.CSV . . . 114
B.1 Linhas com action == stock 116
B.2 Linhas com action == purchase 118
B.3 Linhas com action == select_product 121
B.4 Linhas com action == add_to_cart 121

APÊNDICE C – ARQUIVOS DE CONFIGURAÇÃO DO CENÁRIO EXEMPLO 123
C.1 Arquivo de Importação (import_config.json) 123
C.2 Arquivo de Importação no Modo Combinado (import_config_combined.json) 126
C.3 Arquivo de Conexão (dbms_config.json) 127

1 INTRODUÇÃO

1.1 VISÃO GERAL

Nas esferas industrial e acadêmica de bancos de dados, a concepção de que um único modelo de dados não atende a todas as necessidades tem conquistado aceitação, apontando para a perspectiva de persistência poliglota no futuro. Embora os sistemas de banco de dados relacionais devam manter sua predominância, espera-se uma convivência com diversas formas de sistemas, como os NoSQL (SADALAGE; FOWLER, 2013).

Algumas pesquisas têm sido feitas na área de persistência poliglota, como sugestões de modelos de dados unificados (CHILLóN et al., 2023), comparação de desempenho de bancos de dados multi-modelos contra abordagens de persistência poliglota (YE et al., 2023), revisões sistemáticas sobre modelagem poliglota de dados (SILVA; BORNIA; MELLO, 2024), tutoriais sobre o estado da arte e desafios abertos (KIEHN et al., 2022), e a adoção da persistência poliglota em Big Data (KHINE; WANG, 2019).

Dada essa necessidade crescente da adoção de persistência poliglota pelas aplicações, percebe-se a falta de uma ferramenta única de importação simultânea de dados para diversos SGBDs que tratem modelos de dados diferentes. Até onde se investigou (Capítulo 3), não foram identificadas ferramentas equivalentes: os importadores nativos atendem a um único SGBD por vez, e as soluções de migração ou de modelagem poliglota não realizam a gravação simultânea de um mesmo CSV em múltiplos paradigmas de dados — o que ressalta a originalidade desta proposta.

Assim sendo, este trabalho desenvolve a ferramenta *Polyglot Import CSV*, que importa dados armazenados em CSV para SGBDs relacionais e NoSQL. A configuração da ferramenta baseia-se em dois arquivos JSON: um de importação, mapeando entidades e relacionamentos em cada SGBD, considerado seu modelo de dados; outro de configuração de conexão dos SGBDs envolvidos. A escolha pelo formato JSON deve-se à sua simplicidade e ampla adoção; sua finalidade é detalhar, de forma declarativa, o mapeamento das colunas do CSV para os modelos de dados de cada SGBD, permitindo a validação prévia da importação.

CSV (*Comma-Separated Values*) é um arquivo de valores separados por vírgulas, frequentemente visualizado em Excel e outras planilhas eletrônicas. Pode haver outros tipos de valores como delimitadores, mas o mais comum é a vírgula. Muitos sistemas e processos hoje convertem seus dados para o formato CSV para saídas de

arquivo para outros sistemas, relatórios amigáveis para humanos, disponibilização de dados públicos, e outras necessidades. É um formato de arquivo padrão com o qual humanos e sistemas já estão familiarizados ao usar e manipular.

1.2 OBJETIVOS

1.2.1 Objetivo Geral

Desenvolver a ferramenta *Polyglot Import CSV* que possibilitará a importação de dados em arquivos CSV para múltiplos SGBDs: PostgreSQL, Redis, MongoDB, Cassandra ou Neo4j.

1.2.2 Objetivos Específicos

- Projetar os arquivos de configuração JSON para que eles sigam sintaxes específicas, e flexíveis para lidar com vários modelos de dados, além de adicionar opções como filtros, escolha de chave primária e escolha do nome da coluna no banco de dados;
- Não permitir configurações incorretas, ou seja, se houver erro em algum lugar dos arquivos de configuração, ou nos dados que eles mapeiam, a importação não deve gravar nada até que sejam corrigidos (validação prévia da configuração e dos dados);
- Avaliar o desempenho da ferramenta para diferentes volumes e modelos de dados destino;
- Disponibilizar a ferramenta de forma acessível ao usuário: por meio de uma interface de linha de comando (CLI) e de uma interface gráfica (GUI) que monta e executa o comando de importação de forma assistida, mantendo-o visível ao usuário.

1.3 METODOLOGIA

O desenvolvimento deste trabalho segue uma metodologia de pesquisa aplicada, adotando as seguintes etapas:

1. Estudo sobre persistência poliglota e seu estado da arte;
2. Estudo sobre os paradigmas não-relacionais que serão abrangidos pela solução: chave-valor, documento, grafo e colunar;

3. Estudo de decisão de linguagem de implementação que demonstra melhor produtividade para codificar a solução;
4. Projeto dos arquivos de configuração JSON;
5. Projeto da instrução principal de importação que utiliza os arquivos de configuração;
6. Implementação da solução “Polyglot Import CSV”;
7. Testes da solução “Polyglot Import CSV” implementada;
8. Avaliação de desempenho da solução para diferentes volumes e modelos de dados destino.

Na primeira etapa, foi estudado o que é a persistência poliglota, e a sua relevância no cenário atual.

Na segunda etapa, foram estudados os diversos modelos de dados não-relacionais: como cada modelo representa suas entidades; se há relacionamentos entre entidades no modelo; se é possível a existência de entidades aninhadas e multivaloradas; as limitações de cada modelo.

Na terceira etapa, foram estudadas as formas de implementar a solução usando as linguagens Java e Python e, pela simplicidade e produtividade, a linguagem Python foi escolhida.

Na quarta e quinta etapas, foram projetados os dois arquivos de configuração JSON — um para o mapeamento da importação (entidades, relacionamentos e colunas) e outro para a conexão dos SGBDs — bem como a instrução principal de importação que os utiliza.

As etapas seguintes trataram da implementação da solução proposta, “Polyglot Import CSV”, e dos testes da mesma com diferentes volumes de dados CSV e importações simples e complexas para diferentes modelos de dados destino. A última etapa consistiu na avaliação de desempenho da ferramenta, cujos resultados — ~~*throughput* por SGBD,~~ o custo de cada fase e de cada SGBD, a comparação entre os dois modos de importação, a escalabilidade com o volume de dados, o custo da validação prévia dos dados ~~, efeito do tamanho do~~ e o efeito dos tamanhos do bloco de leitura e ~~, como linha de base, o ganho da escrita em lote e a economia de memória da leitura em blocos~~ do lote de gravação, de que sai a escolha automática desses dois valores — são apresentados no Capítulo 5.

1.4 ESTRUTURA DO TRABALHO

Este trabalho está estruturado em ~~sete~~ seis capítulos principais. O primeiro aborda os objetivos, a metodologia e o contexto que levaram à elaboração deste trabalho. O capítulo 2 revisa os fundamentos teóricos e o capítulo 3 apresenta os trabalhos relacionados. O capítulo 4 descreve a ferramenta *Polyglot Import CSV* — o formato de configuração, as etapas de validação, o fluxo de execução da importação, a observabilidade e o modelo de execução. O capítulo 5 apresenta a avaliação de desempenho da ferramenta, com resultados medidos. O capítulo 6 ~~discute~~ traz a conclusão do trabalho e as atividades futuras~~e o capítulo 7 traz as considerações finais~~.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 PERSISTÊNCIA POLIGLOTA

Ford (2008) introduziu o conceito de “programação poliglota” para expressar a ideia de que aplicativos devem ser desenvolvidos utilizando uma combinação de linguagens, aproveitando o fato de que diferentes linguagens são mais adequadas para lidar com diferentes problemas. Uma das consequências notáveis da programação poliglota é a transição para a “persistência poliglota”, usando a mesma analogia: pode-se dizer que múltiplas tecnologias de bancos de dados podem ser utilizadas como armazenamento persistente para diferentes tipos de casos de uso. Embora ainda exista uma quantidade considerável de dados gerenciados por sistemas relacionais, a abordagem predominante passa a ser a reflexão sobre como se deseja manipular os dados antes de determinar qual tecnologia é a mais adequada para essa manipulação (FOWLER, 2011).

A persistência poliglota abrange uma variedade de formatos de dados, incluindo estruturados, semi-estruturados e não estruturados. Dados estruturados geralmente englobam formatos como relacional, objeto-relacional, e grafos de propriedades. Dados semi-estruturados incluem principalmente documentos JSON e XML. Por fim, dados não estruturados são representados por arquivos de texto, imagens e áudios, dentre outros (YE et al., 2023).

Um domínio em que a persistência poliglota pode ser aplicada é o de um e-commerce. Nesse cenário, diferentes categorias de dados possuem características e padrões de acesso distintos — volume de escrita, frequência de leitura, necessidade de consistência, estrutura dos registros — o que torna mais adequado o uso de um SGBD específico para cada uma delas. A Figura 1 ilustra esse cenário, mapeando cada categoria de dado do e-commerce ao SGBD mais adequado, conforme sugerido a seguir:

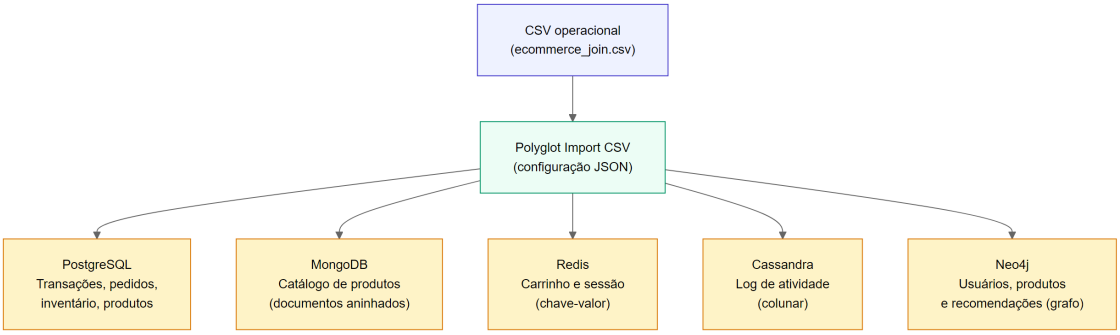


Figura 1 – Exemplo de aplicação da Persistência Poliglota em um e-commerce.
Fonte: Elaborado pelo autor (2026).

- **Dados Financeiros/Transacionais de Pagamento e Inventário de Produtos:** Pedidos, pagamentos e estoques exigem garantias transacionais fortes (ACID) para evitar inconsistências — por exemplo, debitar um pagamento sem registrar o pedido correspondente. Além disso, consultas analíticas sobre esses dados frequentemente combinam várias entidades por meio de junções. Bancos de dados relacionais como o PostgreSQL são a escolha natural para esse perfil, pois oferecem suporte nativo a transações com consistência forte, integridade referencial e uma linguagem de consulta expressiva (SQL).

- **Dados do Catálogo de Produtos:** O catálogo de um e-commerce tende a ter esquema variável: diferentes produtos possuem atributos distintos (um livro físico com ISBN e editora; um eletrodoméstico com voltagem e garantia). Além disso, o catálogo é lido com muito maior frequência do que escrito, e cada consulta normalmente recupera o produto completo de uma vez. Bancos de dados orientados a documentos como o MongoDB são otimizados exatamente para esse perfil: armazenam cada produto como um documento autocontido (favorecendo leituras de agregados complexos), suportam esquemas flexíveis e oferecem índices secundários e *pipelines* de agregação para fins de consulta.

- **Dados da Sessão e do Carrinho de Compras do Usuário:** Dados de sessão e carrinho são acessados a cada interação do usuário durante a navegação, exigindo latência mínima, e são também inerentemente temporários — um carrinho abandonado não precisa persistir indefinidamente. Bancos de dados chave-valor em memória como o Redis oferecem latência de microssegundos, expiração automática de chaves e são horizontalmente escaláveis para absorver picos de tráfego, tornando-se a escolha ideal para dados de natureza efêmera e de acesso intenso.

- **Dados de Atividade do Usuário:** Eventos de navegação (*clickstream*), visualizações de produto e histórico de ações são gerados em alto volume e alta

velocidade. Consultas típicas percorrem o histórico de um usuário em um intervalo de tempo, ou agregam eventos por tipo de ação. Bancos de dados colunares como o Apache Cassandra são projetados para ingestão massiva com particionamento por chave primária composta (por exemplo, `(user_id, timestamp)`), garantindo escritas rápidas e leituras eficientes por usuário ou período — padrão ideal para séries temporais de atividade.

- **Dados de Recomendação:** Sistemas de recomendação dependem de relacionamentos entre entidades: usuários que compraram os mesmos produtos, produtos frequentemente adquiridos em conjunto ou usuários com perfis semelhantes. Esses padrões são naturalmente modelados como grafos, onde nós representam usuários e produtos, e arestas representam interações (comprou, avaliou, visualizou, etc.). Bancos de dados orientados a grafos como o Neo4j permitem percorrer esses relacionamentos com eficiência por meio de consultas Cypher, tarefa que em um banco de dados relacional exigiria múltiplas junções e difícil otimização.

2.2 BANCOS DE DADOS NOSQL

Os bancos de dados NoSQL podem ser divididos em subcategorias com base em seus modelos de dados. Este trabalho utiliza a classificação de Hecht e Jablonski (2011), que categoriza os bancos de dados NoSQL em quatro tipos: chave-valor, colunares, documentos e grafos.

A Figura 2 ilustra esses modelos de dados, que são detalhados a seguir.



Figura 2 – Diferentes tipos de modelos de dados NoSQL.
Fonte: Elaborado pelo autor (2026).

2.2.1 Chave-valor

Os bancos de dados de chave-valor têm um modelo de dados simples baseado justamente em pares chave-valor, semelhante a um mapa associativo ou dicionário. A chave identifica exclusivamente o valor e é usada para armazenar e recuperar o valor no banco de dados, funcionando como uma chave primária. O valor pode ser usado para armazenar qualquer dado arbitrário, incluindo um número inteiro, uma *string*, um *array* ou um objeto, proporcionando uma representação de dados sem esquema conhecido.

Além disso, os bancos de dados de chave-valor são muito eficientes no armazenamento de dados distribuídos, mas não são adequados para cenários que requerem a definição de relacionamentos entre dados ou esquemas fortemente estruturados.

Qualquer funcionalidade que necessite desses requisitos deve ser implementada na aplicação cliente que interage com o banco de dados chave-valor.

Como os valores são opacos para os bancos de dados, esses não podem lidar com consultas e indexações a nível de dados, podendo realizar consultas apenas por meio de chaves. Um exemplo de SGBD chave-valor é o Redis, que mantém os dados tanto na memória como no disco. A Figura 3 ilustra o modelo com um exemplo de carrinho de compras e sessão de usuário, em que cada chave aponta para um valor opaco ao SGBD.

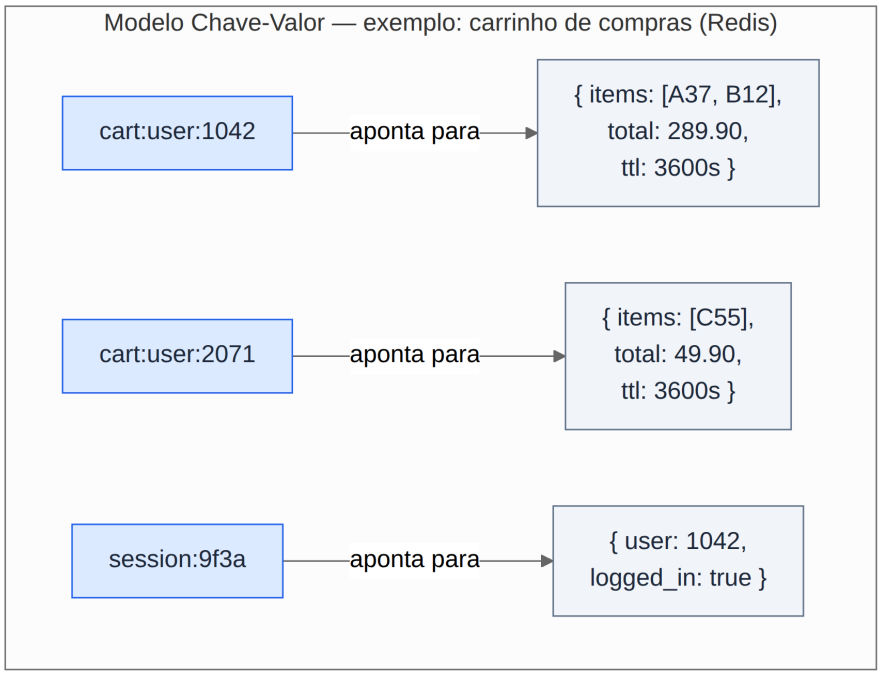


Figura 3 – Modelo chave-valor: chaves apontando para valores arbitrários (Redis).
Fonte: Elaborado pelo autor (2026).

2.2.2 Colunar

Em bancos de dados colunares, o conjunto de dados consiste em várias linhas, cada uma identificada por uma chave de linha única, semelhante a uma chave primária. Cada linha é composta por uma família (ou conjunto) de colunas, e diferentes linhas podem ter diferentes famílias de colunas. Semelhante aos bancos de dados de chave-valor, a chave de linha funciona como a chave, e o conjunto de famílias de colunas atua como o valor representado pela chave de linha. No entanto, colunas em uma família de colunas consistem em pares atributo-valor que podem ser indexadas. O SGBD Cassandra oferece a funcionalidade adicional de supercolunas, que são criadas agrupando várias colunas.

Normalmente, os dados pertencentes a uma linha são armazenados juntos no mesmo nó do servidor. No entanto, o Cassandra pode distribuir uma única linha

por vários nós de servidor usando chaves de partição compostas. Nos bancos de dados colunares, a configuração das famílias de colunas é tipicamente feita durante a inicialização. No entanto, a definição prévia de colunas não é necessária, oferecendo grande flexibilidade no armazenamento de qualquer tipo de dado.

De forma semelhante aos bancos de dados de chave-valor, qualquer lógica que exija relações deve ser implementada na aplicação cliente, ou seja, essa categoria de banco de dados também não têm ciência de relacionamentos entre dados e controle de integridade referencial. A Figura 4 apresenta um exemplo de *log* de atividade, em que cada chave de linha (`user_id`) agrupa uma família de colunas com eventos indexados por *timestamp*.

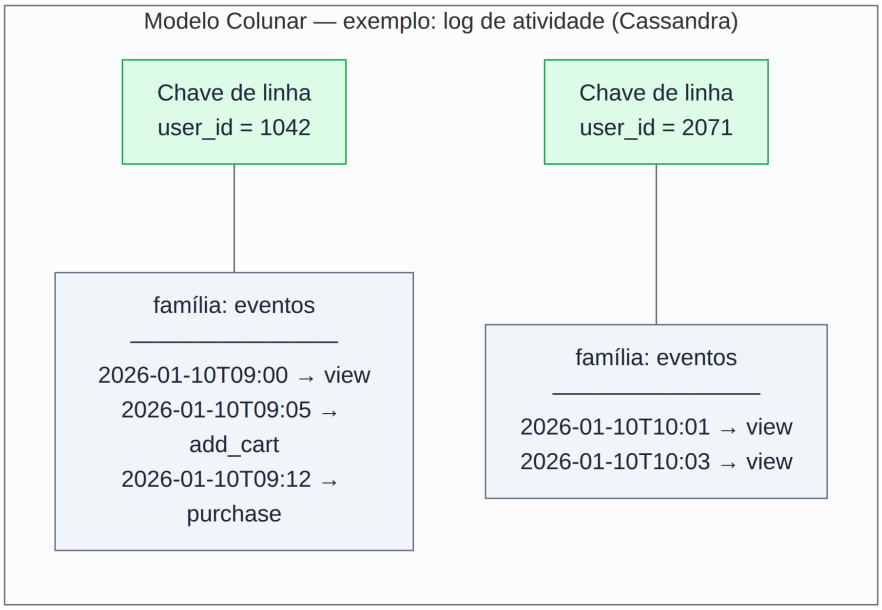


Figura 4 – Modelo colunar: chaves de linha e famílias de colunas (Cassandra).
Fonte: Elaborado pelo autor (2026).

2.2.3 Documento

Bancos de dados orientados a documento armazenam dados como documentos autocontidos, em geral em formato JSON ou BSON. Cada documento possui um identificador e um conjunto de campos que podem variar entre documentos de uma mesma coleção, favorecendo esquemas flexíveis e agregados de leitura (*read-optimized*). O SGBD MongoDB é um exemplo popular nesta categoria. Ele define coleções de documentos, índices secundários e *pipelines* de agregação, permitindo consultas ricas sem exigir junções (*joins*) no servidor. A Figura 5 ilustra uma coleção de catálogo de produtos, em que cada documento é autocontido e pode conter subdocumentos aninhados (como `category` e `stock`) e campos distintos entre si.

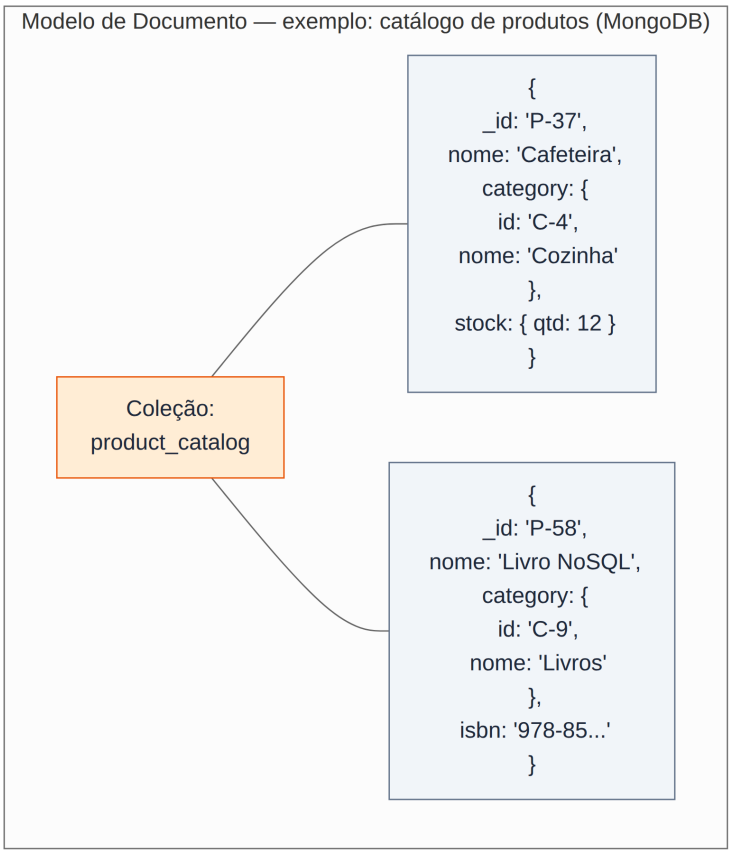


Figura 5 – Modelo de documento: documentos autocontidos com campos variáveis (MongoDB).
Fonte: Elaborado pelo autor (2026).

2.2.4 Grafo

Bancos de dados em grafo representam dados como **nós** (entidades) e **arestas** (relacionamentos tipados), com propriedades em ambos. Consultas exploram caminhos e vizinhanças de forma natural, o que é útil para recomendação, detecção de fraude e redes sociais. O Neo4j utiliza a linguagem Cypher para `MERGE`/`CREATE` de nós e relacionamentos.

Na ferramenta proposta, o destino grafo exige que o usuário declare explicitamente quais colunas do CSV identificam cada rótulo de nó e quais colunas alimentam propriedades do relacionamento (por exemplo, comprador $\rightarrow$ vendedor com atributos do pedido). A Figura 6 exemplifica um cenário de recomendação, em que nós `User` e `Product` são conectados por arestas tipadas (`PURCHASED`, `VIEWED`, `SIMILAR_TO`), algumas portando propriedades próprias.

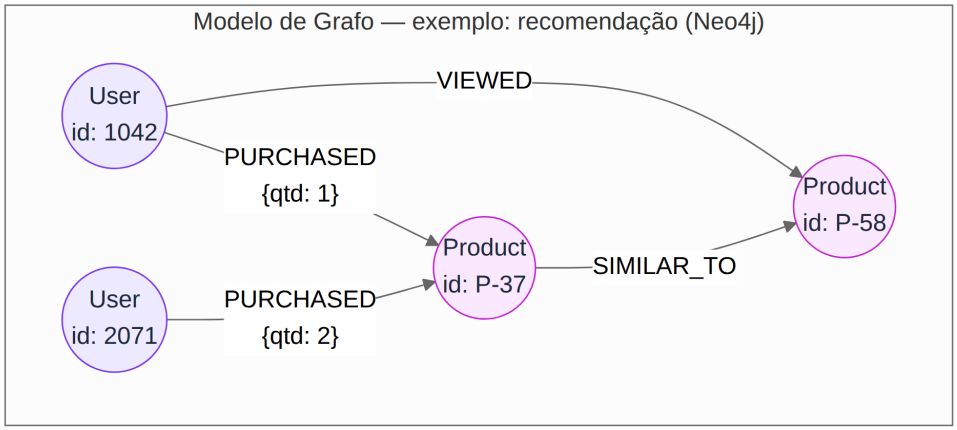


Figura 6 – Modelo de grafo: nós e arestas tipadas com propriedades (Neo4j).
Fonte: Elaborado pelo autor (2026).

2.3 BANCOS DE DADOS MULTIMODELO E ARQUITETURAS DE PERSISTÊNCIA POLIGLOTA

SGBDs multimodelo integram mais de um paradigma de dados no mesmo motor de gerência de dados (por exemplo, documento + chave-valor + grafo), oferecendo em geral uma interface de acesso unificada — como a linguagem AQL do SGBD ArangoDB, que combina filtros sobre estruturas de documento similares ao JSON e travessias em grafos em uma única abstração de modelo de dados que combina ambos os modelos NoSQL.

A persistência poliglota, por outro lado, combina vários SGBDs heterogêneos, cada um escolhido pela adequação a um caso de uso da aplicação (SADALAGE; FOWLER, 2013). Na literatura recente, essa ideia materializa-se como um SGPD (Sistema de Gerenciamento Poliglota de Dados): coordenação transparente entre tecnologias distintas, com requisitos de modelagem e expressividade de acesso (diferentes padrões de consulta) e capacidade de adaptação quando o *workload* evolui (KIEHN et al., 2022; GLAKE et al., 2022).

Tan et al. (2017) apresentam uma taxonomia útil para distinguir arquiteturas relacionadas: BD federado (fontes homogêneas, interface única), BD multistore (fontes heterogêneas, modelo canônico de consulta), BD *polystore* (fontes heterogêneas, múltiplas interfaces de acesso — exemplificadas por sistemas como o BigDAWG) e abordagens multimodelo (vários modelos no mesmo motor).

A escolha entre essas arquiteturas não é trivial. Roy-Hubara, Shoval e Sturm (2022) propõem critérios para selecionar quais modelos de dados usar em aplicações de persistência poliglota, destacando o *trade-off* entre especialização por SGBD e simplicidade operacional de um motor multimodelo.

O *Polyglot Import CSV* adota explicitamente a linha da persistência poliglota ao invés de multimodelo, conforme detalhado no capítulo 4. O usuário direciona entidades e filtros para PostgreSQL, Redis, MongoDB, Cassandra e Neo4j conforme o padrão de representação e acesso desejados.

3 TRABALHOS RELACIONADOS

Este capítulo apresenta e discute ferramentas oferecidas na indústria por SGBDs e também propostas na literatura acadêmica relacionadas com a importação de dados por SGBDs heterogêneos. A preferência está em dados no formato CSV que devem ser importados por alguma tecnologia de banco de dados, que é o foco deste trabalho.

3.1 IMPORTAÇÃO DE ARQUIVO CSV PARA UM ÚNICO SGBD

Esta seção investiga mecanismos de importação de dados presentes em SGBDs populares na indústria que são considerados neste trabalho.

3.1.1 PostgreSQL

No SGBD PostgreSQL você utiliza o comando `COPY` para realizar importações de dados CSV (The PostgreSQL Global Development Group, 2026). É necessário especificar a tabela com os nomes das colunas após a cláusula `COPY`. A ordem das colunas deve ser a mesma que aquelas no arquivo CSV, conforme ilustra o exemplo a seguir:

```
COPY nome_da_tabela(col1, col2, col3)
FROM 'C:/caminho_do_arquivo/dados_de_amostra.csv'
DELIMITER ','
CSV HEADER;
```

Caso o arquivo CSV contenha todas as colunas da tabela, você não precisa especificá-las explicitamente:

```
COPY nome_da_tabela
FROM 'C:/caminho_do_arquivo/dados_de_amostra.csv'
DELIMITER ','
CSV HEADER;
```

Você também deve inserir o caminho do arquivo CSV após a palavra-chave `FROM`. Como o formato do arquivo é CSV, você precisa especificar `DELIMITER`, bem como a cláusula `CSV`. A cláusula `HEADER` deve ser especificada para indicar que o arquivo CSV contém um cabeçalho. Quando o comando `COPY` importa dados, ele ignora o cabeçalho do arquivo.

O arquivo CSV deve ser lido diretamente pelo servidor PostgreSQL, não pela aplicação cliente. Portanto, ele deve ser acessível pela máquina do servidor PostgreSQL. Além disso, é necessário ter permissão de superusuário para executar com sucesso o comando `COPY`.

3.1.2 Redis

A maneira preferida de importar uma massa de dados para o Redis é gerar um arquivo de texto contendo o protocolo Redis, em formato bruto, para chamar os comandos necessários para inserir os dados requeridos (Redis Ltd., 2026).

Por exemplo, se é necessário gerar um grande conjunto de dados com bilhões de chaves no formato "chaveN $\rightarrow$ ValorN", deve ser criado um arquivo contendo os seguintes comandos:

```
SET Chave0 Valor0
SET Chave1 Valor1
SET ChaveN ValorN
```

Uma vez criado esse arquivo, a ação restante é alimentá-lo no Redis. No passado, a maneira de fazer isso era usar o netcat com o seguinte comando:

```
(cat dados.txt; sleep 10) | nc localhost 6379
```

Nas versões 2.6 ou posteriores do Redis, o utilitário `redis-cli` suporta um novo modo chamado modo *pipe* que foi projetado para realizar o carregamento em massa. O comando a ser executado neste caso é o seguinte:

```
cat dados.txt | redis-cli --pipe
```

O utilitário `redis-cli` imprime um pequeno resumo. A saída típica é semelhante a esta:

```
All data transferred. Waiting for the last reply...
Last reply received from server.
errors: 0, replies: 1000000
```

A linha de contagem ao final é a informação mais importante do resumo: `errors` indica quantos comandos foram rejeitados pelo servidor, e `replies` indica o total de respostas recebidas. Se `errors: 0`, todos os comandos foram processados com sucesso. Um valor maior que zero em `errors` significa que ao menos um comando falhou — seja por sintaxe inválida no arquivo, por tipo de dado incompatível com a chave existente, ou por qualquer outra razão que o Redis tenha rejeitado.

Vale notar que o `--pipe` não exibe cada resposta individualmente (como um `+OK` por `SET`), o que é intencional: imprimir bilhões de respostas destruiria o ganho de *performance* do modo *pipe* e inundaria o terminal. Em vez disso, o `redis-cli` lê e contabiliza todas as respostas silenciosamente conforme chegam, entregando apenas o agregado final.

Por fim, uma verificação útil: o valor de `replies` deve ser igual ao número de comandos enviados. Uma divergência entre os dois pode indicar que o arquivo de entrada estava truncado ou malformado, mesmo que `errors` apareça como zero.

3.1.3 MongoDB

No SGBD MongoDB, o processo de importação de dados em formato CSV é realizado através do utilitário `mongoimport` (MongoDB, Inc., 2026). Sua sintaxe básica exige que se informe o banco de dados de destino através do parâmetro `--db`, seguido do nome da coleção que receberá os dados, especificado em `--collection`. Caso esse último parâmetro seja omitido, o nome da coleção será automaticamente inferido a partir do nome do arquivo CSV fornecido.

```
mongoimport --db nome_do_db --collection nome_da_colecao \
  --type csv --headerline --ignoreBlanks \
  --file caminho/do/arquivo.csv
```

O tipo do arquivo de entrada deve ser declarado explicitamente através do parâmetro `--type`, que neste caso recebe o valor `csv`. Para que o `mongoimport` reconheça os nomes dos campos a partir do próprio arquivo, utiliza-se o parâmetro `--headerline`, que instrui o utilitário a tratar o conteúdo da primeira linha do CSV como o cabeçalho dos campos. Opcionalmente, o parâmetro `--ignoreBlanks` pode ser utilizado para que valores em branco presentes no arquivo sejam ignorados durante a importação, evitando que campos vazios sejam persistidos na coleção. Por fim, o caminho do arquivo CSV a ser importado é fornecido através do parâmetro `--file`.

3.1.4 Cassandra

A importação de dados CSV para o Cassandra pode ser feita de duas formas. A mais direta é o comando `COPY FROM` do `cqlsh`, o terminal de comandos CQL do Cassandra, que copia as linhas de um arquivo CSV para uma tabela já existente (The Apache Software Foundation, 2026a). O arquivo precisa estar no formato adequado à tabela: os tipos de dados e as colunas devem corresponder ao esquema dela. Um exemplo de uso é o seguinte:

```
cqlsh -e "COPY keyspace_name.table_name FROM 'arquivo.csv' WITH
   HEADER = true;"
```

Para volumes maiores, o Cassandra oferece o `sstableloader`, que carrega dados já no seu formato interno de armazenamento, o SSTable (The Apache Software Foundation, 2026b). Nesse caso, o CSV não é lido diretamente: ele precisa antes ser convertido em SSTables por um programa próprio, e só então os arquivos gerados são carregados. A sintaxe do comando é a seguinte:

```
sstableloader -d <hostname> -u <username> -pw <password> \
  output_directory/keyspace_name/table_name
```

- `<hostname>`: O endereço do nó Cassandra.
- `<username>`: O nome de usuário, se a autenticação estiver habilitada.

- `<password>`: A senha correspondente.

Este comando move os dados do diretório de saída para o Cassandra.

3.1.5 Neo4j

Usar `neo4j-admin` para importar grandes conjuntos de dados no Neo4j envolve alguns passos (Neo4j, Inc., 2026). Esta ferramenta de linha de comando é projetada para importações em massa eficientes.

Certifique-se de que seus arquivos CSV estejam estruturados corretamente e sigam o formato necessário para nós e relacionamentos. Crie um banco de dados não povoado:

```
neo4j-admin create-db --database=nome_do_seu_banco_de_dados \
  --from=diretorio_com_arquivos_csv
```

Substitua `nome_do_seu_banco_de_dados` pelo nome desejado para o novo banco de dados. A opção `--from` especifica o diretório onde estão localizados seus arquivos CSV. Execute o comando de importação com `neo4j-admin`. O comando exato depende do seu modelo de dados, mas pode se parecer com isto:

```
neo4j-admin import --database=nome_do_seu_banco_de_dados \
  --mode=csv \
  --nodes:Rotulo1 nos.csv \
  --nodes:Rotulo2 nos2.csv \
  --relationships:TIPO_RELACIONAMENTO relacionamentos.csv
```

Substitua *Rotulo1*, *Rotulo2*, *nos.csv*, *nos2.csv*, *TIPO_RELACIONAMENTO* e *relacionamentos.csv* pelos seus rótulos específicos e nomes de arquivo.

3.2 IMPORTAÇÃO DE ARQUIVO CSV PARA SGBD MULTIMODELO

Ferramentas comerciais e de código aberto tratam de **migração** ou **modelagem** entre tecnologias heterogêneas, embora raramente com o foco deste TCC (um único CSV largo + regras declarativas + cinco paradigmas).

- **ArangoDB** é um SGBD multimodelo nativo (documento/chave-valor/grafo) com `arangoimport` para CSV; a importação é para **um** motor multimodelo, não para cinco SGBDs independentes.
- **`mongoimport`** / **`COPY`** / **`redis-cli --pipe`** / **`cqlsh`** / **`neo4j-admin`** (seção 3.1) cobrem importação **para um único** produto por vez.
- **dbcrossbar** (DBCROSSBAR. . . , 2024) copia dados tabulares entre PostgreSQL, BigQuery, armazenamento em nuvem e CSV, incluindo conversão de esquemas; a ênfase é *pipeline* de migração, não mapeamento semântico de entidades aninhadas com filtros por valor.

- **Hackolade** (Hackolade, 2024) oferece *polyglot data modeling* com engenharia de esquema para dezenas de alvos; trata-se de **modelagem visual** e geração de artefatos, e não de um utilitário CLI único para importar um CSV operacional com validação prévia de filtros.

3.3 CONSIDERAÇÕES SOBRE OS TRABALHOS RELACIONADOS

A literatura sobre **metamodelos unificados** para SQL e NoSQL (por exemplo, U-Schema (CANDEL; RUIZ; GARCíA-MOLINA, 2022)) e sobre **evolução de esquema** em ambientes heterogêneos (CHILLóN et al., 2023; CHILLóN et al., 2024) informa decisões de validação e de representação de entidades no JSON de configuração, mas não substitui uma ferramenta de *bulk import* orientada a CSV.

Surveys recentes convergem em desafios abertos da gestão poliglota de dados: migração automatizada entre *stores* quando o *workload* muda, planejamento de consultas entre sistemas, gestão de esquemas multi-modelo e preservação das propriedades não funcionais de cada SGBD (KIEHN et al., 2022; GLAKE et al., 2022). Roy-Hubara, Shoval e Sturm (2022) tratam da **seleção de SGBDs** por fragmento de aplicação; Silva, Bornia e Mello (2024) mapeiam o estado da arte em **modelagem poliglota**. Nenhum desses trabalhos implementa, contudo, um utilitário declarativo que receba um CSV operacional único e o grave simultaneamente em cinco paradigmas distintos com validação estática prévia.

Abordagens recentes reforçam essa tendência. Pereira, Guerra e Rosa (2025) propõem um *framework* de persistência poliglota **transparente**, com uma API unificada e extensível a diferentes tipos de banco, enquanto Sachdeva e Vasava (2024) exploram a combinação de bancos **multimodelo** e persistência poliglota para acomodar a variedade dos dados. Ambos os trabalhos atuam, porém, na **camada de acesso da aplicação** — oferecendo uma interface única para ler e gravar em múltiplos SGBDs em tempo de execução —, e não na **carga inicial declarativa** a partir de um CSV operacional, que é o foco da *Polyglot Import CSV*.

Sistemas *polystore* como o BigDAWG (DUGGAN et al., 2015) e *middlewares* de portabilidade em nuvem (KAUR; SHARMA; KAHLON, 2020) tratam de **consultas federadas** e movimentação de dados em ecossistemas complexos. Tan et al. (2017) classificam essas soluções (federado, multistore, polystore, poliglota) e avaliam transparência, autonomia e heterogeneidade — eixos nos quais importadores nativos (seção 3.1) e ferramentas de migração (seção 3.2) também divergem, mas sem convergir para um *pipeline* único de ingestão.

Ferramentas como **dbcrossbar** (DBCROSSBAR. . . , 2024) e **Hackolade** (Hackolade, 2024) aproximam-se do domínio de integração de dados, porém com foco

em *pipelines* de migração ou modelagem visual, respectivamente — não em regras declarativas sobre entidades aninhadas, filtros por valor (`each`) e validação por JSON Schema antes de qualquer conexão com SGBDs.

Lacuna identificada: a combinação de (i) um CSV largo como fonte operacional, (ii) configuração JSON validada estaticamente, (iii) gravação distinta por paradigma (relacional, chave-valor, documento, colunar, grafo) e (iv) modo *dry-run* para revisão prévia. O *Polyglot Import CSV* ocupa essa lacuna como ferramenta de **bootstrap de persistência poliglota** — carga inicial e reprodutível de dados — enquanto *middlewares* e *polystores* assumem dados já residentes ou consultas em tempo de execução. Trabalhos futuros podem integrar a ferramenta a mecanismos de migração adaptativa descritos por Kiehn et al. (2022) e Glake et al. (2022).

4 A FERRAMENTA POLYGLOTIMPORTCSV

4.1 VISÃO GERAL

A ferramenta **PolyglotImportCSV** (pacote Python `polyglot-import-csv`) importa dados em formato CSV para vários SGBDs em uma única execução. Conforme ilustra a Figura 7, a ferramenta recebe como entrada os **arquivos de dados** (um ou mais CSV) e **dois arquivos de configuração** em formato JSON — o arquivo de **importação**, que declara quais CSVs alimentam a carga e mapeia as suas colunas para as entidades e relacionamentos desejados em cada SGBD, e o arquivo de **conexão**, que declara quais SGBDs estão disponíveis e como alcançá-los.

O processamento é disparado por um comando de linha de comando (CLI), que primeiro **valida** as entradas — cada arquivo de configuração é conferido contra um **JSON Schema** embutido e, em seguida, contra os cabeçalhos e os dados dos próprios CSVs — e só então grava os dados. A **saída** são os dados persistidos em cada SGBD destino presente na configuração, dentre os suportados: PostgreSQL, MongoDB, Cassandra, Redis e Neo4j. A ferramenta é um projeto de código aberto, hospedado no GitHub sob o nome `polyglot-import-csv`[1]; todos os caminhos de arquivo citados neste trabalho, como `data/ecommerce/` ou `docker-compose.yml`, são relativos à raiz desse repositório.

[1] Disponível em <https://github.com/lucasbc92/polyglot-import-csv>. Executáveis para Windows e Linux, que dispensam a instalação do Python, estão disponíveis na página de *releases* do projeto.

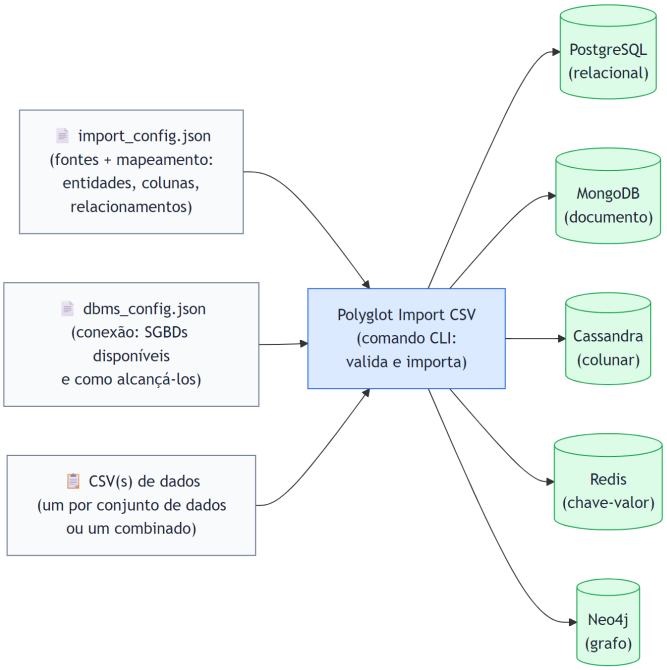


Figura 7 – Visão geral da ferramenta: entradas, processamento e saídas.
Fonte: Elaborado pelo autor (2026).

O formato completo dos dois arquivos de configuração é detalhado na seção 4.2; as etapas de validação realizadas antes de gravar, na seção 4.2.4; o fluxo de execução da importação, na seção 4.3; a camada de observabilidade e métricas, na seção 4.4; e a interface gráfica, na seção 4.6. O comando principal da CLI é o seguinte:

```
python -m polyglotimportcsv \
  --config caminho/import_config.json \
  [--dbms-config caminho/dbms_config.json] \
  [--source NOME=CAMINHO ...] \
  [--dry-run] \
  [--check-dbms] \
  [--only postgres,redis] \
  [--chunk-size MB] \
  [--batch-size N] \
  [--log-level INFO] \
  [--sample N | --show-data | --no-data] \
  [--benchmark]
```

Cada parte do comando tem o seguinte papel. A opção `--config` é a única **obrigatória** e indica o caminho do arquivo JSON de importação, que contém, em seu bloco `sources`, os caminhos dos CSVs a carregar. As demais opções, entre colchetes, são opcionais. A opção `--dbms-config` indica o caminho do arquivo JSON de conexão dos SGBDs; quando não é informada, a ferramenta usa o arquivo `dbms_config.json` do mesmo diretório do arquivo de importação. A opção `--source NOME=CAMINHO` **sobrescreve**, em tempo de execução, o caminho de uma fonte declarada no bloco `sources` sem editar o arquivo de configuração (por exemplo, para apontar a mesma configuração a um conjunto de dados maior). Ela não aceita uma lista com separador: para substituir mais de uma fonte, a opção é repetida, uma vez por fonte. A Listagem 4.1 mostra uma

importação do cenário exemplo em que as fontes `purchase` e `stock` são lidas de outros arquivos.

```
python -m polyglotimportcsv \
  --config data/ecommerce/import_config.json \
  --source purchase=novos/compras.csv \
  --source stock=novos/estoque.csv
```

Listagem 4.1 – Duas fontes substituídas com a opção `--source` repetida.

Cada ocorrência de `--source` associa o nome de uma fonte do bloco `sources` a um novo caminho; as fontes não citadas, como `select_product` e `add_to_cart`, continuam lidas dos caminhos do arquivo de importação.

As outras opções agrupam-se em três conjuntos. O primeiro controla **o que** e **onde** importar. A opção `--dry-run` executa todas as etapas de validação, inclusive a leitura completa dos dados, e informa quantas linhas **seriam** gravadas em cada destino, sem conectar a nenhum SGBD, o que é útil para revisar o mapeamento antes da carga real. A opção `--check-dbms` apenas verifica se os SGBDs destino respondem e encerra sem importar; ela é passada no mesmo comando, como em `python -m polyglotimportcsv --config data/ecommerce/import_config.json --check-dbms`, e a interface gráfica oferece a mesma verificação no botão "~~Verificar SGBDs~~Check DBMSs" (seções 4.3.1 e 4.6). A opção `--only` restringe a execução a um subconjunto dos SGBDs configurados (por exemplo, `--only postgres,redis`).

Não há opção para criar ou deixar de criar estruturas: antes de gravar, a ferramenta sempre prepara cada SGBD destino. No PostgreSQL, ela cria o esquema e as tabelas que ainda não existem e remove as chaves estrangeiras declaradas no mapeamento, que recria ao fim da carga, porque as tabelas são gravadas em blocos e uma tabela filha pode receber linhas antes da tabela mãe. No Cassandra, cria o *keyspace* e as tabelas que ainda não existem; no Neo4j, cria as restrições de unicidade sobre a chave de cada rótulo de nó. Estruturas que já existem são reaproveitadas. O MongoDB e o Redis não exigem estrutura prévia: coleções e chaves surgem na primeira gravação.

O segundo conjunto define **como** importar. Os arquivos são lidos em **blocos**, nunca inteiros, e gravados em **lotes**~~: `--chunk-size` fixa a~~ . Por padrão, a ferramenta escolhe sozinha a memória ~~reservada a~~ de cada bloco de leitura, ~~em MB (8, por padrão, de 8 a 256),~~ conforme o tamanho das fontes e a memória livre do computador, e grava lotes de 2.048 linhas; `--chunk-size` fixa o bloco à mão, em MB, e `--batch-size`, o número de linhas de cada lote~~de gravação (1024, por padrão, de 1024 a 8192),~~ , limitado às linhas de um bloco. A seção 4.5.2 descreve esse modelo de execução e ~~o efeito do tamanho do bloco~~a escolha automática.

O terceiro conjunto governa a **observabilidade** da execução — `--log-level`

ajusta o nível de detalhe das mensagens no terminal; `--sample N` exibe as primeiras `N` linhas de cada entidade (50, por padrão), enquanto `--show-data` exibe todas as linhas e `--no-data`, nenhuma; e `--benchmark` registra métricas de desempenho por fase —; essas opções são descritas em detalhe na seção 4.4.

4.2 FORMATO DE CONFIGURAÇÃO (JSON SCHEMA)

A configuração da ferramenta é dividida em **dois arquivos JSON**. O arquivo de **importação** (`import_config.json`) declara as fontes de dados e o **mapeamento** das suas colunas para entidades e relacionamentos em cada SGBD; o arquivo de **conexão** (`dbms_config.json`) declara quais SGBDs estão disponíveis e como alcançá-los. Cada arquivo é validado por um **JSON Schema** próprio, embutido na ferramenta em `src/polyglotimportcsv/schemas/` e reproduzido no Apêndice A.

Os exemplos desta seção vêm do **cenário exemplo**, o de comércio eletrônico apresentado na Seção 2.1 (Figura 1), cujos arquivos acompanham o repositório da ferramenta em `data/ecommerce/`. Os dados desse cenário registram os eventos de uma loja virtual, de quatro tipos, resumidos na Tabela 1. Todo evento registra o instante em que ocorreu e o usuário envolvido; a tabela indica os demais dados de cada tipo.

Tabela 1 – Tipos de evento do cenário exemplo.

Tipo	**Evento**	**Demais dados registrados**
`stock`	reposição de estoque	produto, categoria, quantidade disponível e preço
`purchase`	compra	pedido, produto, contraparte da venda, pagamento e avaliação
`select_product`	seleção de produto	produto selecionado
`add_to_cart`	adição ao carrinho	carrinho, produto e quantidade

Fonte: Elaborado pelo autor (2026).

Cada tipo de evento tem o seu próprio CSV, com oito linhas: `ecommerce_stock.csv`, `ecommerce_purchase.csv`, `ecommerce_select_product.csv` e `ecommerce_add_to_cart.csv`. Os mesmos eventos estão também reunidos em um único arquivo, `ecommerce_join.csv`, cuja primeira coluna (`action`) indica o tipo de cada linha. O Apêndice B reproduz esses dados em forma tabular.

As subseções seguintes descrevem cada arquivo da raiz até as folhas do seu schema: a Seção 4.2.1 apresenta o arquivo de importação; a Seção 4.2.2, o que esse arquivo tem de específico em cada SGBD; a Seção 4.2.3, o arquivo de conexão; e a Seção 4.2.4, as validações aplicadas aos dois antes da importação.

4.2.1 O Arquivo de Importação

A Figura 8 mostra a estrutura do schema do arquivo de importação, da raiz (no alto) até as folhas (embaixo); o asterisco marca os campos que o próprio JSON Schema exige. A Tabela 2 resume a finalidade de cada parte e indica quais podem ser omitidas.

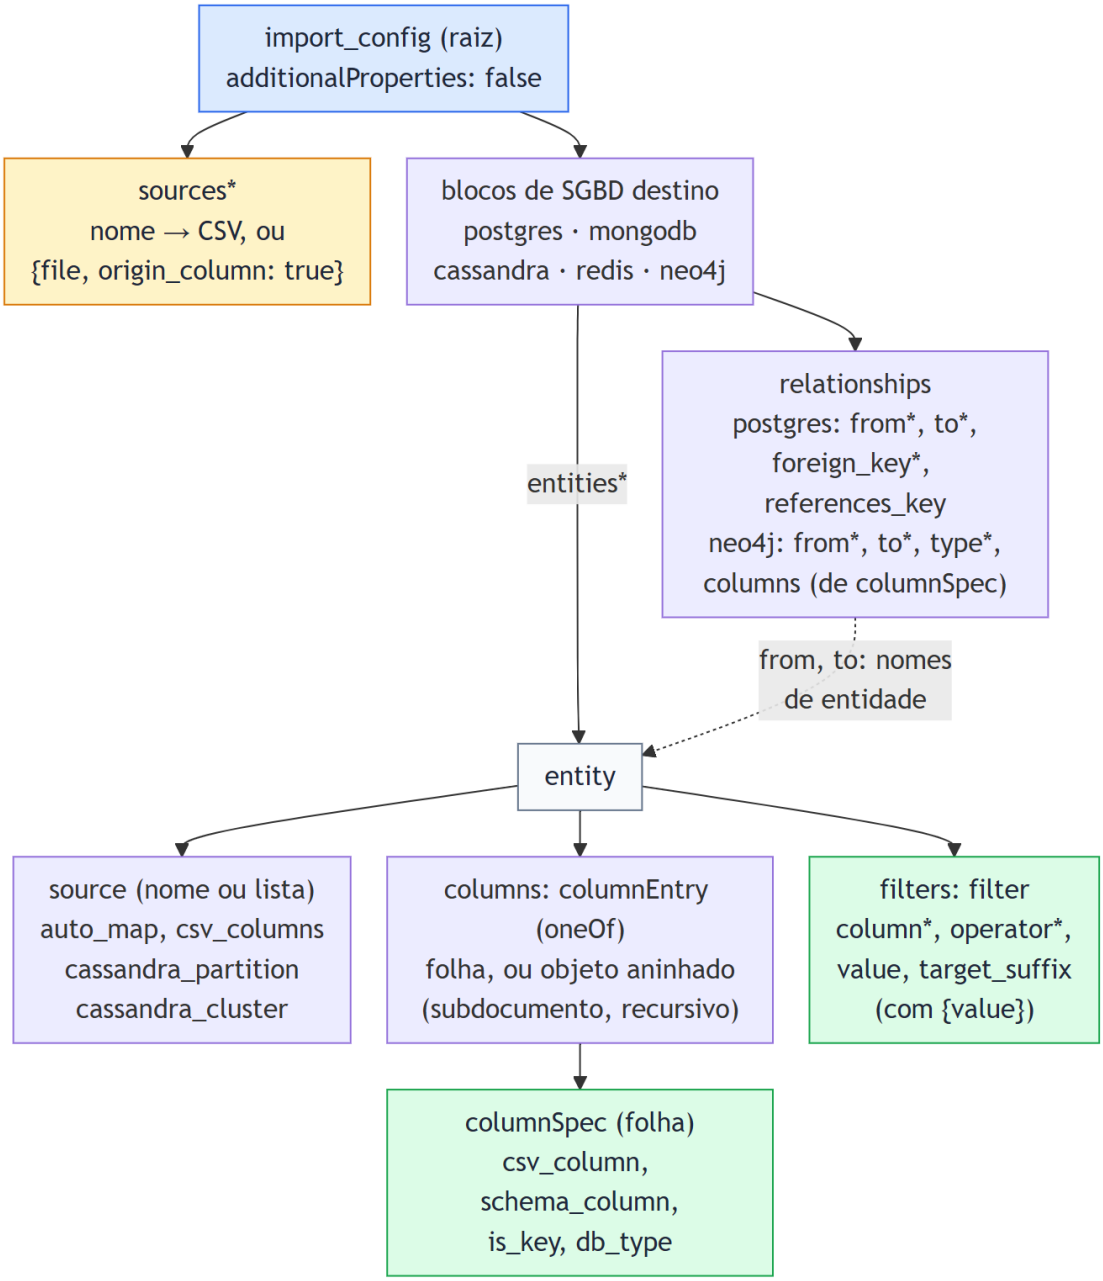


Figura 8 – Estrutura do JSON Schema de importação (`import_config`).
Fonte: Elaborado pelo autor (2026).

Tabela 2 – Partes do arquivo de importação.

Parte	**Onde**	**Finalidade**	**Obrigatória?**
`sources`	raiz	nomear os CSVs de entrada	sim
`postgres`, `mongodb`, `cassandra`, `redis`, `neo4j`	raiz	mapear dados para um SGBD	sim; ao menos os SGBDs de destino
`entities`	bloco de SGBD	declarar os alvos (tabelas, coleções, nós...)	sim
`relationships`	bloco PostgreSQL ou Neo4j	declarar chaves estrangeiras ou arestas	não
`source`	entidade	indicar a fonte lida	não; padrão: a fonte de mesmo nome
`columns`	entidade	mapear as colunas	não; se omitido, todas as colunas da fonte
`auto_map`, `csv_columns`	entidade	controlar o mapeamento automático	não
`filters`	entidade	selecionar linhas	não
`cassandra_partition`, `cassandra_cluster`	entidade do Cassandra	definir a chave primária	a partição, sim; exigida pela etapa 3 de validação
`csv_column`, `schema_column`, `is_key`, `db_type`	coluna	ligar uma coluna do CSV a um atributo	não

Fonte: Elaborado pelo autor (2026).

Os blocos de SGBD aparecem como obrigatórios na tabela, mas não na figura, porque a exigência não está no JSON Schema: ele aceita um arquivo sem nenhum bloco de SGBD. Quem a confere é a execução, que termina com código de saída 1 quando não resta nenhum SGBD destino, inclusive quando a opção `--only` exclui todos os configurados.

A Listagem 4.2 mostra um trecho do arquivo de importação do cenário exemplo que percorre essa estrutura da raiz até as folhas: o bloco `sources`, o bloco do Post-

greSQL, uma de suas entidades e duas de suas colunas. As reticências (. . .) marcam o conteúdo omitido; o arquivo completo está no Apêndice C.

```
"sources": {
  "stock":    "ecommerce_stock.csv",
  "purchase": "ecommerce_purchase.csv",
  ...
},
"postgres": {
  "entities": {
    "inventory": {
      "source": "stock",
      "columns": {
        "product_id": { "is_key": true, "db_type": "BIGINT" },
        ...
        "price":      { "db_type": "NUMERIC(14,2)" }
      }
    },
    ...
  }
},
...
```

Listagem 4.2 – Trecho do arquivo de importação, da raiz até as colunas.

Lido de cima para baixo, o trecho diz que: o bloco `sources` nomeia os arquivos de dados; o bloco `postgres` indica que parte dos dados vai para o PostgreSQL; a entidade `inventory` será uma tabela, alimentada pela fonte `stock`; e cada entrada de `columns` cria uma coluna dessa tabela. As subseções a seguir explicam cada um desses níveis, nessa ordem.

4.2.1.1 Raiz e bloco `sources`

A raiz do arquivo admite apenas o bloco `sources`, obrigatório, e um bloco por SGBD destino. Qualquer outra chave é rejeitada (`additionalProperties: false`), de modo que um erro de digitação como `postgress` é apontado na validação em vez de ser ignorado.

O bloco `sources` dá um **nome** a cada arquivo CSV de entrada, e as entidades referem-se às fontes por esse nome. Há duas formas de declarar as fontes, que correspondem aos dois modos de importação. No modo **multifonte**, cada nome aponta diretamente para um CSV, como na Listagem 4.3: uma fonte por tipo de evento.

```
"sources": {
  "stock":          "ecommerce_stock.csv",
  "purchase":       "ecommerce_purchase.csv",
  "select_product": "ecommerce_select_product.csv",
  "add_to_cart":    "ecommerce_add_to_cart.csv"
}
```

Listagem 4.3 – Bloco `sources` no modo multifonte (um CSV por conjunto de dados).

No modo **combinado**, uma única fonte aponta para o CSV que reúne todos os eventos, e `"origin_column": true` indica que a primeira coluna desse arquivo identifica a origem de cada linha, como na Listagem 4.4.

```
"sources": {
  "ecommerce": { "file": "ecommerce_join.csv", "origin_column": true }
}
```

Listagem 4.4 – Bloco `sources` no modo combinado (um CSV com coluna de origem).

Ao carregar uma fonte combinada, a ferramenta separa as linhas pelo valor da primeira coluna e registra, além da própria fonte, uma fonte para cada valor distinto. Assim, os nomes `stock`, `purchase`, `select_product` e `add_to_cart` ficam disponíveis como no modo multifonte, e o restante do arquivo de importação é idêntico nos dois modos. Em ambos, cada linha recebe ainda uma **pseudo-coluna** `_source` com a sua origem — o nome da fonte, no modo multifonte, ou o valor da coluna de origem, no modo combinado —, que pode ser mapeada como qualquer outra coluna (um exemplo aparece na Listagem 4.13).

Nos dois modos, a **primeira linha de todo CSV é o seu cabeçalho**: é dela que vêm os nomes das colunas, aos quais o mapeamento se refere. O cabeçalho é, portanto, **obrigatório**, e a ferramenta não tem como distingui-lo de uma linha de dados. Em um CSV sem cabeçalho, a primeira linha de dados seria tomada como nomes de coluna e não seria importada. Quando o mapeamento se refere às colunas pelo nome, elas não seriam encontradas, e a execução terminaria com erro na validação (Seção 4.2.4). Com o mapeamento automático ou com colunas indicadas pela posição, porém, não haveria erro: a importação prosseguiria sem a primeira linha e, no mapeamento automático, com os valores dela como nomes de coluna. No modo combinado, a primeira coluna do cabeçalho é a coluna de origem.

4.2.1.2 Blocos de SGBD

Cada bloco de SGBD (`postgres`, `mongodb`, `cassandra`, `redis` ou `neo4j`) descreve o que será gravado naquele SGBD; só aparecem os blocos dos SGBDs que se deseja alimentar. A Listagem 4.5 mostra o esqueleto do bloco do PostgreSQL no cenário exemplo, com o conteúdo de cada entrada omitido.

```
"postgres": {
  "entities": {
    "categories": { ... },
    "products":   { ... },
    "inventory":  { ... },
    "orders":     { ... }
  },
  "relationships": {
    "product_category": { ... },
    "order_product":    { ... }
```

```
  }
}
```

Listagem 4.5 – Esqueleto do bloco `postgres` do arquivo de importação.

O mapa `entities`, obrigatório, contém as entidades a criar, cada uma identificada pelo nome que terá no SGBD — aqui, quatro tabelas. O mapa `relationships`, opcional, existe apenas nos blocos do PostgreSQL, onde declara chaves estrangeiras, e do Neo4j, onde declara arestas; ambos são detalhados na Seção 4.2.2.

4.2.1.3 Entidade

Uma entidade representa um alvo no SGBD: uma tabela no PostgreSQL ou no Cassandra, uma coleção no MongoDB, um conjunto de chaves no Redis ou um rótulo de nó no Neo4j. Todos os SGBDs usam a mesma definição de entidade, exemplificada na Listagem 4.6 pela entidade `inventory` do PostgreSQL.

```
"inventory": {
  "source": "stock",
  "columns": {
    "product_id":         { "is_key": true, "db_type": "BIGINT" },
    "quantity_available": { "db_type": "BIGINT" },
    "last_restock_date":  { "db_type": "TIMESTAMPTZ" },
    "price":              { "db_type": "NUMERIC(14,2)" }
  }
}
```

Listagem 4.6 – Entidade `inventory` do arquivo de importação.

Todos os campos de uma entidade são opcionais:

- `source` indica a fonte da qual a entidade lê. Pode ser o nome de uma fonte, como na listagem; uma lista de nomes (`"source": ["stock", "purchase"]`), caso em que as linhas das fontes são unidas em uma só entidade, com valores vazios nas colunas que faltam em alguma delas; ou ser omitido, caso em que a entidade lê da fonte que tem o seu próprio nome.
- `columns` lista as colunas da entidade (Seção 4.2.1.4). Se for omitido, a entidade recebe **todas** as colunas da fonte, com os nomes do CSV e tipos inferidos dos próprios dados; é o **mapeamento automático**, que `auto_map` e `csv_columns` ajustam, como descreve a mesma seção.
- `filters` restringe as linhas da fonte que participam da entidade, como descrito a seguir.
- `cassandra_partition` e `cassandra_cluster` definem a chave primária no Cassandra (Seção 4.2.2).

No cenário exemplo, cada tipo de evento já vem de uma fonte própria, e nenhuma entidade precisa de filtros para selecionar linhas. A Listagem 4.7 mostra um filtro ilustrativo, que não faz parte do cenário exemplo: aplicado a uma entidade que lê da fonte `purchase`, ele manteria apenas as compras pagas com cartão de crédito.

```
"filters": [
  { "column": "payment_method", "operator": "==", "value": "credit_card" }
]
```

Listagem 4.7 – Filtro ilustrativo sobre a coluna `payment_method`.

Cada filtro exige a coluna (`column`) e o operador (`operator`), que pode ser `==`, `!=`, `>`, `<`, `>=`, `<=`, `in`, `not_in` ou `each`; o valor comparado (`value`) também é exigido, exceto com `each`, e é uma lista com `in` e `not_in`.

O operador `each` não restringe as linhas, e sim **divide** a entidade: cada valor distinto da coluna gera um alvo próprio, com as linhas que têm esse valor. O cenário exemplo usa esse operador na coleção `orders` do MongoDB, que guarda um documento por compra e é dividida pelo estado do comprador. A Listagem 4.8 reproduz essa entidade, com parte das colunas omitida.

```
"orders": {
  "source": "purchase",
  "columns": {
    "order_number": {},
    "user_id": {},
    ...
  },
  "filters": [
    { "column": "state", "operator": "each", "target_suffix": "state_{value}" }
  ]
}
```

Listagem 4.8 – Coleção `orders` do MongoDB, dividida por estado com o operador `each`.

O campo `target_suffix` é um modelo para o nome de cada parte: o marcador `{value}`, obrigatório e único, é trocado pelo valor da coluna, com cada trecho de caracteres que não sejam letras, dígitos ou sublinhado substituído por um sublinhado; o nome final é o da entidade, um sublinhado e o modelo preenchido. As oito compras do cenário exemplo vêm de sete estados, e a importação grava sete coleções: `orders_state_CA`, `orders_state_RJ`, `orders_state_RS`, `orders_state_SC`, `orders_state_SE` e `orders_state_TO`, com um documento cada, e `orders_state_SP`, com dois. Sem `target_suffix`, o sufixo seria o próprio valor (`orders_CA`, ...). Linhas com a coluna vazia não geram alvo, cada entidade admite um único `each`, e nenhum relacionamento pode apontar para uma entidade dividida, pois ela não tem um alvo único; a validação recusa essa configuração antes de gravar.

4.2.1.4 Colunas

O mapa `columns` associa cada atributo da entidade a uma coluna do CSV. A Listagem 4.9 mostra três entradas: as duas primeiras pertencem à entidade `user_activity_log` do Cassandra (Listagem 4.13); a terceira é ilustrativa.

```
"columns": {
  "product_id": {},
  "timestamp":  { "schema_column": "event_time" },
  "preco":      { "csv_column": "price" }
}
```

Listagem 4.9 – Três formas de mapear uma coluna.

A chave de cada entrada dá, por padrão, dois nomes ao mesmo tempo: o da coluna lida no CSV e o do atributo gravado no SGBD. Na primeira entrada, os dois nomes são iguais à chave (`product_id`), e o objeto vazio basta. Na segunda, a coluna `timestamp` do CSV é gravada com outro nome, `event_time`, indicado em `schema_column`. Na terceira, o atributo se chama `preco` no SGBD, mas é lido da coluna `price` do CSV, indicada em `csv_column`; esse campo também aceita a posição da coluna de dados, a partir de 1. A Tabela 3 resume os quatro campos que uma entrada pode ter.

Tabela 3 – Campos de mapeamento de coluna (`columnSpec`).

Campo	**Tipo**	**Obrigatório**	**Descrição**
`csv_column`	*string* ou inteiro (≥ 1)	não	Cabeçalho CSV ou posição da coluna de dados (base 1). Padrão: a chave.
`schema_column`	*string*	não	Nome do atributo no SGBD destino. Padrão: a chave.
`is_key`	booleano	não	Chave primária, chave de `MERGE` (Neo4j) ou chave Redis.
`db_type`	*string*	não	Tipo SQL/CQL para geração de DDL.

Fonte: Elaborado pelo autor (2026).

No lugar de uma entrada simples, `columns` pode conter um novo mapa de colunas. Esse **aninhamento** só é aceito no MongoDB, onde produz um subdocumento (Listagem 4.12).

Mapeamento automático. Quando `columns` é omitido, a entidade recebe todas as colunas da sua fonte, com os nomes do CSV. Com `"auto_map": true`, as colunas

declaradas em `columns` somam-se às automáticas e prevalecem sobre elas: na Listagem 4.14, a entidade `shopping_cart` declara apenas a coluna-chave e recebe as demais automaticamente. Nos dois casos, `csv_columns` limita o mapeamento automático às colunas indicadas, por nome, por posição (a partir de 1) ou por intervalo, como `"1-5"`. A Listagem 4.10 mostra uma entidade criada só para ilustrar esse recurso, fora do cenário exemplo, que lê da fonte `stock`.

```
"product_summary": {
  "source": "stock",
  "auto_map": true,
  "csv_columns": ["10-13", "price"],
  "columns": { "product_id": { "schema_column": "id" } }
}
```

Listagem 4.10 – Entidade ilustrativa com `auto_map` e `csv_columns`.

O intervalo `"10-13"` seleciona as colunas de dados da 10.ª à 13.ª do arquivo `ecommerce_stock.csv` (`product_id`, `product_name`, `product_variant` e `product_brand`), e `"price"` acrescenta uma coluna pelo nome. Como `auto_map` está ativo, a coluna `product_id`, declarada em `columns`, prevalece sobre a automática e é gravada como `id`. A entidade recebe, assim, cinco atributos: `id`, `product_name`, `product_variant`, `product_brand` e `price`.

Inferência de tipos. Todos os valores são lidos inicialmente como texto, preservando o conteúdo original do arquivo. Antes de gravar, uma **leitura de inferência** percorre cada arquivo inteiro, em blocos, e classifica cada coluna: booleana, se todos os valores não vazios são booleanos; inteira ou real, se todos são numéricos (inteira quando nenhum tem parte fracionária); data/hora, se mais de 85% dos valores não vazios são datas; texto, nos demais casos; e vazia, se não há valor. Os valores são então convertidos para o tipo nativo correspondente, e um valor que não converte, como uma data inválida numa coluna de datas, é apontado na validação (Seção 4.2.4). Essa classificação também define o tipo de destino (`db_type`) usado na geração de DDL quando a coluna é auto-mapeada, segundo a correspondência da Tabela 4. Para uma coluna declarada sem `db_type`, o PostgreSQL usa `TEXT`, enquanto o Cassandra usa o tipo inferido.

Tabela 4 – Correspondência entre tipo inferido e tipo de destino na geração de DDL.

Tipo inferido	**Tipo de destino (`db_type`)**
inteiro (*integer*)	`BIGINT`
real (*float*)	`NUMERIC`
data/hora (*datetime*)	`TIMESTAMPTZ`
booleano (*boolean*)	`BOOLEAN`
texto (*string*) ou vazia	`TEXT`

Fonte: Elaborado pelo autor (2026).

4.2.2 Particularidades de Cada SGBD no Arquivo de Importação

Os cinco blocos de SGBD destino usam a mesma definição de entidade, mas cada SGBD acrescenta regras próprias, decorrentes do seu modelo de dados. Esta subseção apresenta essas regras, cada uma com o trecho correspondente do arquivo de importação do cenário exemplo; o arquivo completo está no Apêndice C.

PostgreSQL. As entidades são tabelas e só admitem colunas simples, sem aninhamento. O campo `db_type` de cada coluna define o tipo usado na criação da tabela (`CREATE TABLE`), quando ela ainda não existe, e as colunas com `is_key` formam a chave primária. O mapa `relationships` declara chaves estrangeiras: `from` é a tabela que contém a chave, `to` é a tabela referenciada, `foreign_key` é a coluna de `from` e `references_key` é a coluna de `to` (por padrão, a de mesmo nome). A Listagem 4.11 mostra a entidade `products` e a chave estrangeira que a liga às categorias.

```
"postgres": {
  "entities": {
    "products": {
      "source": "stock",
      "columns": {
        "product_id":   { "is_key": true, "db_type": "BIGINT" },
        "product_name": { "db_type": "TEXT" },
        ...
        "category_id":  { "db_type": "BIGINT" },
        ...
      }
    },
    ...
  },
  "relationships": {
    "product_category": {
      "from": "products",
      "to":   "categories",
      "foreign_key":    "category_id",
      "references_key": "category_id"
    },
    ...
```

```
  }
}
```

Listagem 4.11 – Fragmento de importação PostgreSQL com chave estrangeira.

As reticências omitem três colunas de `products` (variante, marca e preço), as outras três entidades (`categories`, `inventory` e `orders`) e a segunda chave estrangeira (`order_product`, de pedidos para produtos).

MongoDB. As entidades são coleções, e o MongoDB é o único SGBD que aceita **aninhamento** em `columns`: uma chave cujo valor é um novo mapa de colunas produz um subdocumento, sem nenhum campo adicional. Na Listagem 4.12, as chaves `category` e `stock` não são colunas do CSV, e sim agrupam outras colunas em dois subdocumentos de cada documento `product_catalog`.

```
"mongodb": {
  "entities": {
    "product_catalog": {
      "source": "stock",
      "columns": {
        "product_id":   {},
        "product_name": {},
        ...
        "category": {
          "category_id": {},
          "category_name": {}
        },
        "stock": {
          "quantity_available": {},
          "last_restock_date": {}
        }
      }
    },
    ...
  }
}
```

Listagem 4.12 – Fragmento de importação MongoDB com subdocumentos.

As reticências omitem as demais colunas cadastrais do produto (variante, marca, descrição, imagem e preço), mapeadas da mesma forma que `product_id` e `product_name`, e a segunda coleção do bloco, `orders`, já apresentada na Listagem 4.8.

Apache Cassandra. As entidades são tabelas com colunas simples, e a chave primária é definida por dois campos próprios: `cassandra_partition`, a lista de colunas da chave de partição, e `cassandra_cluster`, as colunas de agrupamento. A partição é obrigatória, pois a linguagem CQL requer ao menos uma coluna de partição na chave primária. O JSON Schema não a exige, mas a etapa 3 de validação recusa uma entidade do Cassandra sem `cassandra_partition` já na conferência dos cabeçalhos, inclusive no `--dry-run`, antes de gravar qualquer dado (Seção 4.2.4). No Cassandra,

`is_key` não participa da chave primária. A Listagem 4.13 mostra uma entidade que **une** as quatro fontes em uma tabela de eventos.

```
"cassandra": {
  "entities": {
    "user_activity_log": {
      "source": ["stock", "purchase", "select_product", "add_to_cart"],
      "columns": {
        "user_id":             {},
        "timestamp":           { "schema_column": "event_time" },
        "_source":             { "schema_column": "event_type" },
        "product_id":          {},
        "order_number":        {},
        "selected_product_id": {},
        "shopping_cart_id":    {}
      },
      "cassandra_partition": ["user_id"],
      "cassandra_cluster":   ["timestamp"]
    }
  }
}
```

Listagem 4.13 – Fragmento de importação Cassandra com união de fontes e chave composta.

A pseudo-coluna `_source`, que guarda a fonte de cada linha, é gravada na coluna `event_type`, distinguindo os tipos de evento na tabela; a chave primária é formada pelo usuário (partição) e pelo instante do evento (agrupamento).

Redis. Cada entidade gera um conjunto de pares chave-valor e deve ter **exatamente uma** coluna com `is_key`: o valor dessa coluna, tal como aparece no CSV, torna-se a chave Redis, e os demais campos mapeados compõem o valor, armazenado em JSON. Na Listagem 4.14, `shopping_cart` declara apenas a chave e usa `auto_map` para receber as demais colunas da fonte `add_to_cart`; `user_session` usa como chave o identificador do usuário e renomeia `timestamp` para `last_seen`, registrando a última navegação de cada usuário.

```
"redis": {
  "entities": {
    "shopping_cart": {
      "source": "add_to_cart",
      "auto_map": true,
      "columns": {
        "shopping_cart_id": { "is_key": true }
      }
    },
    "user_session": {
      "source": "select_product",
      "columns": {
        "user_id":    { "is_key": true },
        "user_name":  {},
        "user_email": {},
        "timestamp":  { "schema_column": "last_seen" }
      }
```

```
    }
  }
}
```

Listagem 4.14 – Fragmento de importação Redis (cenário exemplo), com mapeamento automático.

Neo4j. Cada entidade é um rótulo (*label*) de nó e deve ter exatamente uma coluna com `is_key`, usada para identificar o nó na operação `MERGE` da linguagem Cypher, que só cria o nó se ele ainda não existir. O mapa `relationships` declara arestas: `from` e `to` são os rótulos de origem e de destino, `type` é o tipo da aresta e `columns`, opcional, lista as propriedades da aresta. Na Listagem 4.15, o nó `User` lê da fonte `purchase` (os compradores) e o nó `Product`, da fonte `stock`; a aresta `PURCHASED` liga cada comprador ao produto comprado, com quantidade, preço e nota da avaliação.

```
"neo4j": {
  "entities": {
    "User": {
      "source": "purchase",
      "columns": {
        "user_id":    { "is_key": true },
        "user_name":  {},
        "user_email": {}
      }
    },
    "Product": {
      "source": "stock",
      "columns": {
        "product_id":    { "is_key": true },
        "product_name":  {},
        "product_brand": {}
      }
    }
  },
  "relationships": {
    "PURCHASED": {
      "from": "User",
      "to":   "Product",
      "type": "PURCHASED",
      "columns": {
        "order_number": { "is_key": true },
        "quantity":     {},
        "price":        {},
        "rating":       {}
      }
    }
  }
}
```

Listagem 4.15 – Fragmento de importação Neo4j (nós e aresta).

4.2.3 O Arquivo de Conexão

O arquivo de conexão diz *onde* alcançar cada SGBD. A Figura 9 mostra a estrutura do seu schema, também com os campos obrigatórios marcados com asterisco: a raiz, um bloco por SGBD e, dentro de cada bloco, os parâmetros de acesso. A Tabela 5 resume a finalidade de cada parte.

Tabela 5 – Partes do arquivo de conexão.

Parte	**Onde**	**Finalidade**	**Obrigatória?**
`version`	raiz	versão do formato do arquivo (atualmente, 1)	sim
`postgres`, `mongodb`, `cassandra`, `redis`, `neo4j`	raiz	dar acesso a um SGBD	sim; ao menos os SGBDs de destino
`connection`	bloco de SGBD	parâmetros de acesso	sim
`schema`	bloco PostgreSQL	schema de destino das tabelas	não; padrão: `public`
`start`	bloco de SGBD	como iniciar o SGBD	não

Fonte: Elaborado pelo autor (2026).

Como no arquivo de importação, os blocos de SGBD são obrigatórios na tabela, mas não na figura: o JSON Schema exige apenas `version`, e a exigência de que cada SGBD destino tenha o seu bloco é conferida na segunda etapa de validação (Seção 4.2.4). A Listagem 4.16 mostra o início do arquivo de conexão do cenário exemplo, com os blocos do PostgreSQL e do MongoDB. As reticências marcam os descritores `start`, tratados na Seção 4.2.3.3, e os blocos dos demais SGBDs; o arquivo completo está no Apêndice C.

```
{
  "version": 1,
  "postgres": {
    "connection": {
      "host": "127.0.0.1", "port": 5432,
      "database": "ecommerce",
      "user": "postgres", "password": "postgres"
    },
    "schema": "public",
    ...
  },
  "mongodb": {
    "connection": {
```

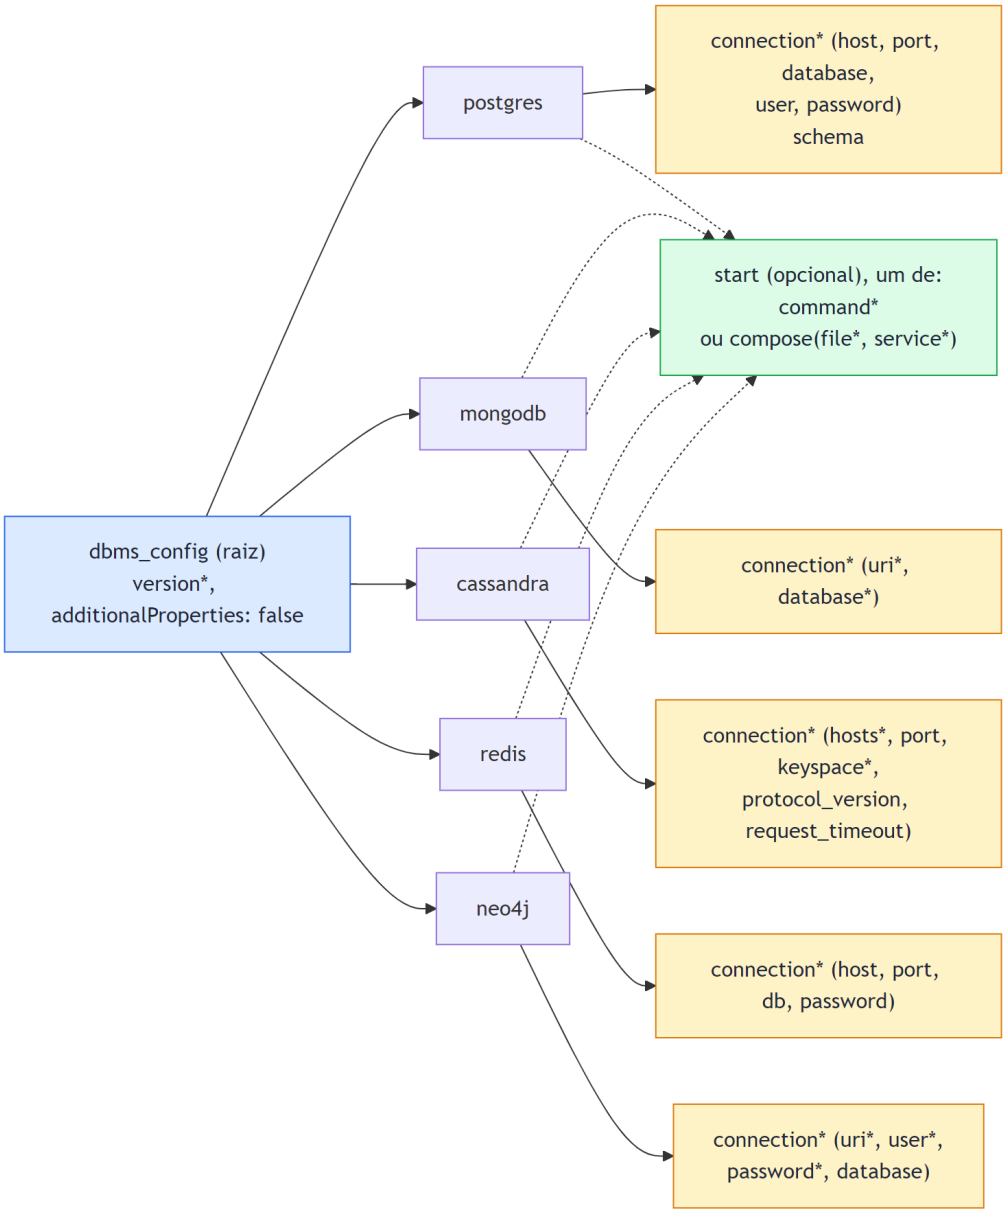


Figura 9 – Estrutura do JSON Schema de conexão (`dbms_config`).
Fonte: Elaborado pelo autor (2026).

```
      "uri": "mongodb://127.0.0.1:27017",
      "database": "ecommerce"
    },
    ...
  },
  ...
}
```

Listagem 4.16 – Início do arquivo de conexão do cenário exemplo (`dbms_config.json`).

4.2.3.1 Raiz e blocos de SGBD

A raiz exige o campo `version` e aceita um bloco por SGBD; como no arquivo de importação, chaves desconhecidas são rejeitadas. Todo SGBD que aparece no arquivo de importação precisa ter o seu bloco aqui; caso contrário, a importação é recusada antes de começar (Seção 4.2.4). Cada bloco presente deve conter o descritor `connection`.

4.2.3.2 Parâmetros de conexão

Os campos de `connection` dependem do SGBD, pois seguem os parâmetros do *driver* de cada um. A Tabela 6 lista esses campos, os obrigatórios e os valores usados quando um campo opcional é omitido.

Tabela 6 – Campos do descritor `connection` por SGBD.

SGBD	**Campos**	**Obrigatórios**	**Padrões**
PostgreSQL	`host`, `port`, `database`, `user`, `password`	—	`127.0.0.1`, `5432`, `postgres`, `postgres`, senha vazia
MongoDB	`uri`, `database`	`uri`, `database`	—
Cassandra	`hosts`, `port`, `keyspace`, `protocol_version`, `request_timeout`	`hosts`, `keyspace`	porta `9042`; `request_timeout` de 30 s; protocolo negociado pelo *driver*
Redis	`host`, `port`, `db`, `password`	—	`127.0.0.1`, `6379`, `0`, sem senha
Neo4j	`uri`, `user`, `password`, `database`	`uri`, `user`, `password`	`database`: o banco padrão do servidor

Fonte: Elaborado pelo autor (2026).

No MongoDB e no Neo4j, o endereço é uma URI no formato do respectivo *driver* (`mongodb://...` e `bolt://...`). A URI do MongoDB pode incluir usuário e senha; no Neo4j, as credenciais vão nos campos `user` e `password`. No Cassandra, `hosts` é uma lista, pois um *cluster* pode ter vários nós, e `request_timeout` é o tempo máximo, em segundos, de cada requisição.

4.2.3.3 Inicialização dos SGBDs

O descritor `connection` diz *onde* alcançar cada SGBD, mas não o que fazer quando ele não responde. Para esse caso, cada bloco de SGBD aceita um descritor opcional `start`, que registra *como* iniciá-lo, em uma de duas formas mutuamente exclu-

sivas: `command`, uma linha de comando para um SGBD instalado na própria máquina, ou `compose`, que indica um arquivo do Docker Compose e o serviço correspondente. A ferramenta **nunca executa** esse comando: ela o exibe, pronto para ser copiado para um terminal, quando a verificação descrita na Seção 4.3.1 encontra o SGBD fora do ar. A escolha é deliberada: iniciar um serviço do sistema operacional costuma exigir privilégios de administrador, que a ferramenta não tem nem deve pedir. A Listagem 4.17 mostra dois blocos do arquivo de conexão de exemplo para Windows, um em cada forma.

```
"postgres": {
  "connection": { ... },
  "schema": "public",
  "start": { "command": "net start postgresql-x64-16" }
},
"cassandra": {
  "connection": { ... },
  "start": {
    "compose": {
      "file":    "../../docker-compose.yml",
      "service": "cassandra"
    }
  }
}
```

Listagem 4.17 – Descritores `start` nas duas formas (`dbms_config_windows.json`).

Na listagem, o conteúdo dos descritores `connection`, igual ao do arquivo reproduzido no Apêndice C, foi omitido. O PostgreSQL, instalado como serviço do Windows, é iniciado por `net start`; o Apache Cassandra, que não roda nativamente no Windows, é descrito por um serviço do Docker Compose, cujo arquivo tem caminho relativo à pasta do próprio arquivo de conexão. O cenário exemplo traz três arquivos de conexão com as mesmas conexões e descritores `start` distintos: `dbms_config.json`, todo em Docker Compose; `dbms_config_windows.json`, com serviços do Windows; e `dbms_config_linux.json`, com o `systemctl`. Como os nomes de serviço dependem de cada instalação, os comandos desses arquivos são exemplos a ajustar.

4.2.4 As Três Etapas de Validação

Antes de gravar qualquer dado, a ferramenta confere as entradas em três **etapas de validação**, mostradas na Figura 10. Cada etapa só começa se a anterior passou, e qualquer problema encerra a execução com código de saída 1, sem gravar nada em nenhum SGBD.

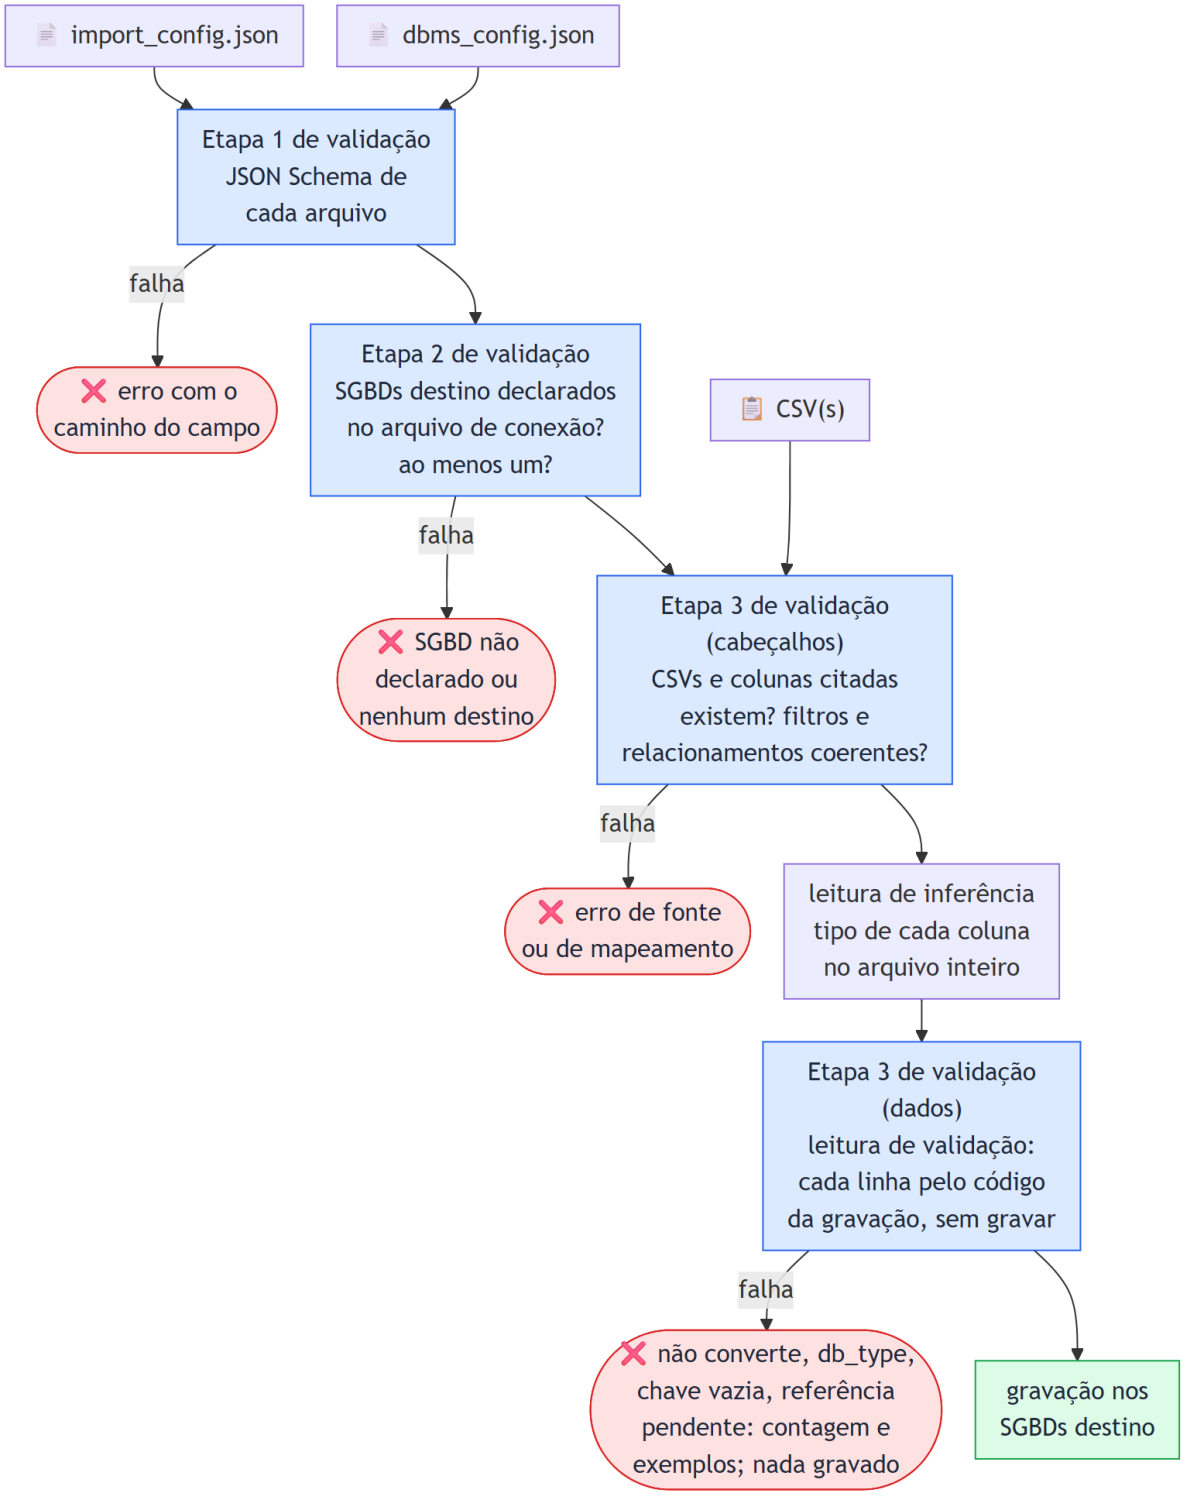


Figura 10 – As três etapas de validação, todas antes da gravação.
Fonte: Elaborado pelo autor (2026).

A **etapa 1 de validação** confere cada arquivo de configuração contra o seu JSON Schema (Apêndice A): a sintaxe JSON, os tipos dos valores, os campos obrigatórios e as chaves permitidas. A mensagem de erro indica o caminho do campo recusado, como `$.sources.stock`. Um erro em qualquer dos dois arquivos é apontado antes de

qualquer CSV ser aberto.

A **etapa 2 de validação** confere a consistência entre os dois arquivos: todo SGBD que tem um bloco no arquivo de importação precisa estar declarado no arquivo de conexão, e precisa restar ao menos um SGBD destino depois de aplicada a opção `--only`.

A **etapa 3 de validação** confronta o mapeamento com os CSVs, em duas partes. A primeira olha só os **cabeçalhos**: confere se os arquivos existem e se as colunas citadas no mapeamento estão neles, se os SGBDs de modelo plano (todos, exceto o MongoDB) não recebem colunas aninhadas, se cada entidade do Cassandra declara a sua partição e se as colunas de partição e de agrupamento existem, se os filtros são coerentes e se as chaves estrangeiras do PostgreSQL e as arestas do Neo4j ligam entidades válidas, nenhuma delas dividida por `each`.

A segunda parte olha os **dados**. Depois da verificação dos SGBDs destino (Seção 4.3.1), omitida no `--dry-run`, a ferramenta lê os CSVs duas vezes, em blocos. A **leitura de inferência** percorre cada arquivo inteiro e fixa o tipo de cada coluna (Seção 4.2.1.4); nela, uma entidade do modo combinado cuja fonte não aparece na coluna de origem do arquivo é recusada. A **leitura de validação** passa cada linha pelo mesmo código da gravação — filtros, divisão por `each`, conversão de tipos e montagem dos registros de cada SGBD —, com a escrita trocada por conferências, e aponta:

- valor que não converte para o tipo da sua coluna;
- valor que o `db_type` declarado recusaria, como um inteiro grande demais para a coluna;
- chave vazia;
- referência pendente: uma chave estrangeira do PostgreSQL ou uma aresta do Neo4j que aponta para uma chave ausente da entidade de destino.

Cada tipo de problema é relatado com o número de ocorrências e até cinco exemplos, cada um com arquivo, linha, coluna e valor. A Figura 12, na Seção 4.3, acompanha esse caminho no cenário exemplo e mostra um problema de cada tipo. As etapas de validação não cobrem falhas que só aparecem durante a gravação, como a queda de um SGBD no meio da carga; nesse caso, a execução também termina com código 1, informando os SGBDs já gravados, e o que foi gravado permanece.

4.3 FLUXO DE EXECUÇÃO DA IMPORTAÇÃO

Definidos o formato de configuração e as etapas de validação, esta seção descreve como a ferramenta executa a importação, desde o comando apresentado na

seção 4.1 até a gravação em cada SGBD destino. A Figura 11 mostra os passos do fluxo de execução, explicados a seguir; a seção 4.3.2 acompanha esses passos no cenário exemplo.

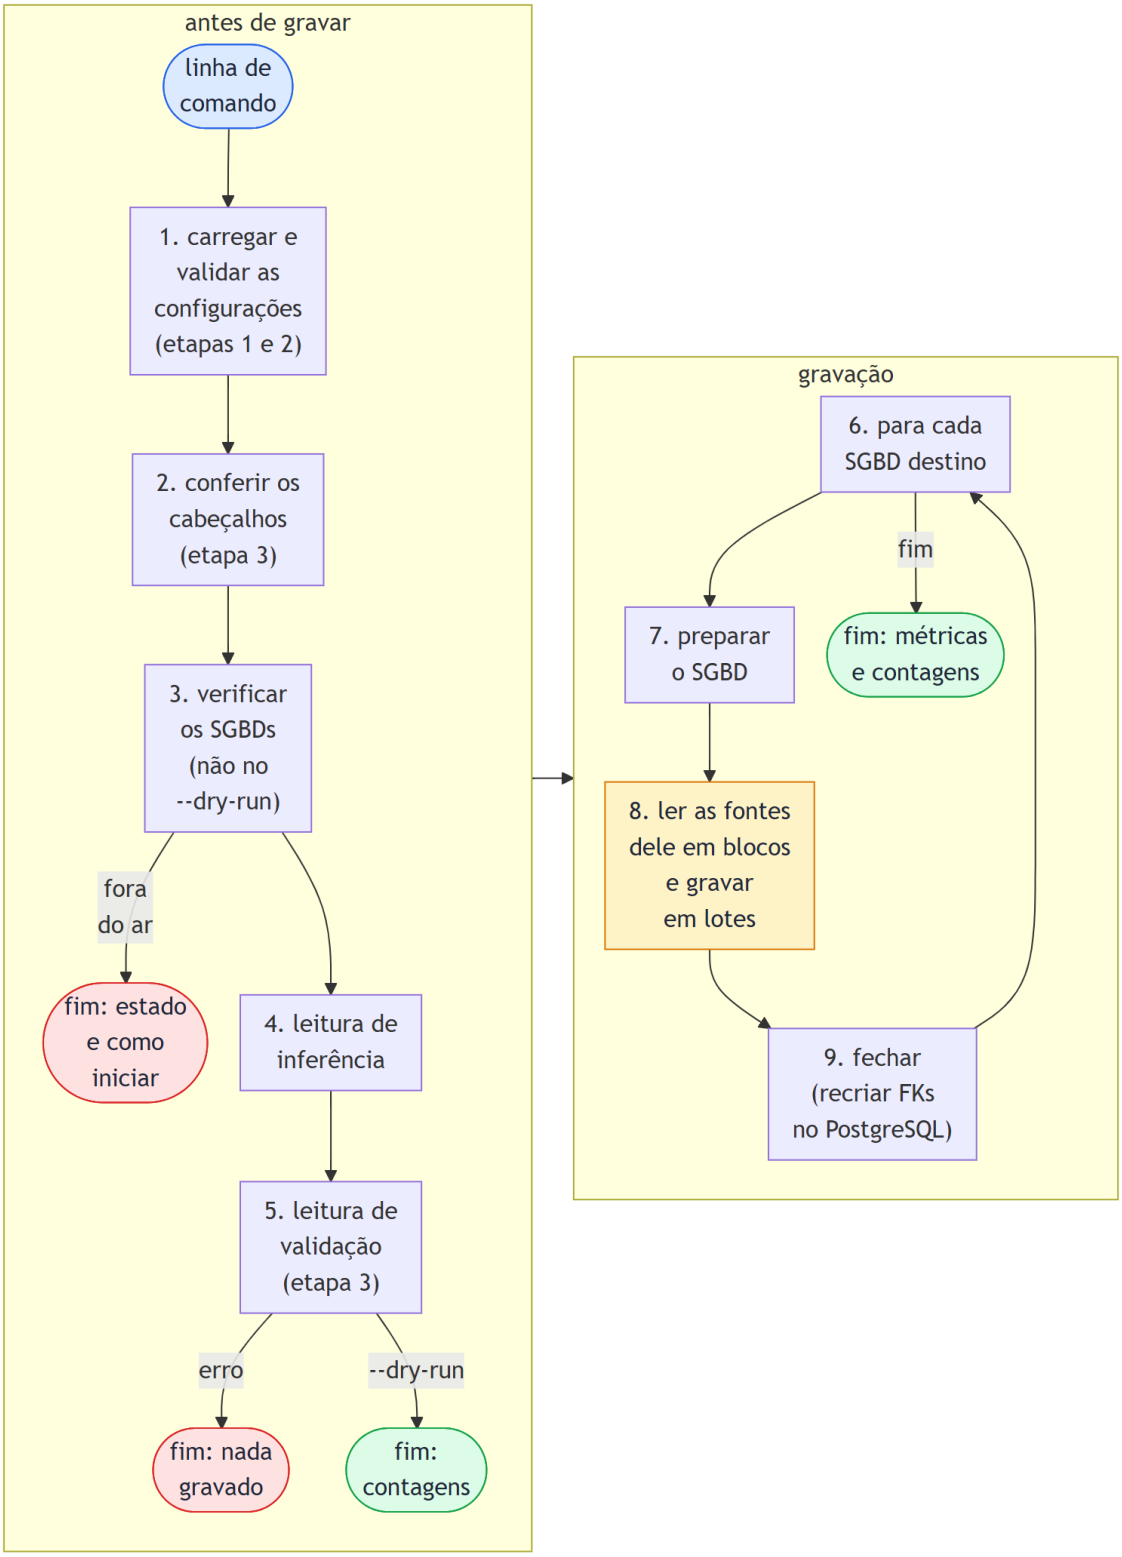


Figura 11 – Passos do fluxo de execução da importação.

Fonte: Elaborado pelo autor (2026).

A execução parte da **entrada** fornecida na linha de comando: os caminhos dos dois arquivos JSON de configuração, eventuais sobrescritas de fonte (`--source`) e as opções `--dry-run`, `--only`, `--chunk-size` e `--batch-size`, descritas na seção 4.1.

No **passo 1**, os dois arquivos de configuração são carregados e passam pelas etapas 1 e 2 de validação (seção 4.2.4); em seguida, são mesclados em uma estrutura única de execução, com o mapeamento e a conexão de cada SGBD destino.

No **passo 2**, a ferramenta lê apenas o cabeçalho de cada CSV declarado no bloco `sources` e aplica a primeira parte da etapa 3 de validação, sobre os cabeçalhos.

No **passo 3**, em uma importação real, verificam-se os SGBDs destino, como detalha a Seção 4.3.1: se algum deles não responder, a execução termina antes da leitura dos dados, com a indicação de como iniciá-lo. O `--dry-run` pula este passo, pois não se conecta a nenhum SGBD.

No **passo 4**, a **leitura de inferência** percorre cada CSV inteiro, em blocos cujo tamanho em memória é dado por `--chunk-size`, e fixa o tipo de cada coluna (seção 4.2.1.4). Os valores são lidos como texto, preservando o conteúdo original do arquivo e evitando conversões prematuras de tipo (por exemplo, em datas com fuso horário). Quando a fonte é combinada, a sua primeira coluna indica a origem de cada linha, e cada valor distinto dá nome a uma fonte derivada; a pseudo-coluna `_source` é preenchida nos dois modos. Com os tipos fixados, a ferramenta **vincula** cada entidade à sua fonte — nome único, união de fontes ou vínculo pelo nome — e expande o mapeamento de colunas (manual, automático ou híbrido).

No **passo 5**, a **leitura de validação** percorre os CSVs mais uma vez e passa cada linha pelo mesmo tratamento da gravação, descrito a seguir, com a escrita trocada pela segunda parte da etapa 3 de validação. Uma só leitura atende a todos os SGBDs destino. Qualquer problema encerra a execução sem que nada seja gravado; no `--dry-run`, a execução termina neste passo, com a contagem das linhas que cada entidade receberia.

Os passos 6 a 9 compõem a **gravação**, que percorre os SGBDs destino um de cada vez. No **passo 7**, a ferramenta conecta-se ao SGBD e o prepara, criando as estruturas que ainda não existem, como descreve a seção 4.1. No **passo 8**, lê de novo, em blocos, apenas as fontes usadas pelas entidades desse SGBD e trata cada bloco da seguinte forma.

Primeiro, a ferramenta **aplica os filtros** declarados, quando houver — operação que corresponde à *seleção* da álgebra relacional: apenas as linhas que satisfazem os predicados participam da entidade. Havendo filtro com o operador `each`, a entidade é ainda **particionada** pelos valores distintos da coluna indicada, um particionamento horizontal em que cada valor dá origem a um alvo próprio. Em seguida, os valores são

convertidos para os tipos nativos fixados no passo 4.

Depois, cada linha selecionada é **transformada** na estrutura do modelo de dados de destino, segundo os conceitos revisados no capítulo 2. Para os SGBDs de organização tabular (o relacional PostgreSQL e o colunar Cassandra), a transformação combina operações também descritas pela álgebra relacional: *projeção* (somente as colunas mapeadas em `columns` são mantidas) e *renomeação* (aplicação de `schema_column`); no PostgreSQL, também a *eliminação de duplicatas* com base nas colunas de chave (`is_key`). No Cassandra, cuja chave vem de `cassandra_partition` e `cassandra_cluster`, uma linha com chave já existente substitui a anterior; a seção 4.3.4 detalha o tratamento de duplicatas em cada SGBD. Para o modelo de documentos (MongoDB), os valores da linha são agregados em um documento cuja hierarquia reproduz o aninhamento declarado em `columns`, na representação desnormalizada característica desse modelo. Para o modelo chave-valor (Redis), cada linha dá origem a um par em que a chave é o valor da coluna marcada com `is_key` e o valor é a representação textual (JSON) dos demais campos mapeados. Para o modelo de grafo (Neo4j), cada linha dá origem a um nó com as propriedades mapeadas; na sequência, as arestas declaradas em `relationships` conectam os nós criados, com semântica de mesclagem — a aresta só é criada se ainda não existir, evitando duplicação quando a mesma relação aparece em várias linhas. Por fim, os registros são **gravados em lotes** de até `--batch-size` linhas, pela operação de escrita própria de cada tecnologia.

No **passo 9**, a ferramenta fecha a conexão com o SGBD; no PostgreSQL, recria antes as chaves estrangeiras removidas no passo 7. Concluídos todos os SGBDs destino, a **saída** da execução é um relatório com as contagens de linhas enviadas, por entidade e por SGBD e as métricas de cada fase (seção 4.4), que permite conferir o resultado da carga.

4.3.1 Verificação dos SGBDs

Antes de ler os dados das fontes, toda importação real verifica se os SGBDs destino — os presentes no arquivo de importação, filtrados por `--only` — respondem; até esse ponto, só os cabeçalhos dos CSVs foram lidos. A verificação abre uma conexão TCP com cada endereço declarado no arquivo de conexão e a fecha em seguida, sem autenticar. As sondas correm em paralelo, com limite de dois segundos cada, de modo que o tempo total não cresce com o número de SGBDs. Cada SGBD termina em um de três estados: **no ar**, quando algum de seus endereços responde (no Cassandra, basta um nó); **fora do ar**, quando nenhum responde; e **conexão inválida**, quando o próprio *driver* rejeita a configuração, como em uma URI com esquema desconhecido. Um único SGBD fora do ar ou com conexão inválida **interrompe** a execução antes da leitura dos dados, o que evita uma carga parcial: sem a verificação, os SGBDs

anteriores na ordem de importação receberiam dados antes que a falha do seguinte fosse descoberta.

Os endereços não são extraídos por um analisador próprio. Para o MongoDB e o Neo4j, cuja conexão é descrita por uma URI, a ferramenta constrói o cliente do próprio *driver* sem conectar e obtém dele os endereços; assim, uma URI aceita pelo *driver* nunca é recusada pela verificação, e uma recusada nunca passa. Para o PostgreSQL, seguem-se as regras da biblioteca cliente `libpq`, inclusive listas de hosts e *sockets* Unix.

Quando algum SGBD não responde, a ferramenta mostra, abaixo da tabela de estados, o que fazer: para cada descritor `command`, o próprio comando; para os descritores `compose` de um mesmo arquivo, um único `docker compose up`; e, para um SGBD sem `start`, uma orientação genérica. A opção `--check-dbms`, da linha de comando da ferramenta (seção 4.1), executa apenas esse passo e encerra, com código de saída zero quando todos os SGBDs respondem e 1 quando algum não responde; na interface gráfica, o mesmo passo é disparado pelo botão "~~Verificar SGBDs~~Check DBMSs" (seção 4.6). A Tabela 7 e a Listagem 4.18 reproduzem uma verificação feita com o arquivo de conexão de exemplo para Windows, com o MongoDB e o Neo4j fora do ar.

Tabela 7 – Estados reportados por `--check-dbms` com dois SGBDs fora do ar.

SGBD	Endereço	Estado
postgres	127.0.0.1:5432	up
mongodb	127.0.0.1:27017	down
cassandra	127.0.0.1:9042	up
redis	127.0.0.1:6379	up
neo4j	127.0.0.1:7687	down

Fonte: Elaborado pelo autor (2026).

A Listagem 4.18 mostra os comandos que a ferramenta lista abaixo da tabela para iniciar os dois SGBDs fora do ar, retirados dos descritores `start` do arquivo de conexão.

```
To start the DBMS that are down, run in a terminal:
  net start MongoDB
  net start neo4j
Service commands (net start, systemctl) may need an administrator
   terminal or sudo.
```

Listagem 4.18 – Comandos de inicialização mostrados por `--check-dbms`.

4.3.2 O Cenário Exemplo e os Arquivos de Dados

Para concretizar o fluxo, esta subseção e a seguinte acompanham as linhas do cenário exemplo apresentado na seção 4.2 (Tabela 1) pelos passos da Figura 11; a execução completa do cenário exemplo é demonstrada na seção 4.3.4. O exemplo adota o modo multifonte, em que cada tipo de evento tem o seu próprio CSV.

A Figura 12 resume o caminho da primeira linha da fonte `stock` por esses passos. À esquerda, as etapas de validação e as leituras de inferência e de validação, com os tipos que a leitura de inferência fixou para algumas colunas; à direita, acima, as entidades em que essa linha é gravada. À direita, abaixo, aparecem três problemas que a leitura de validação recusa, provocados de propósito em cópias alteradas dos arquivos: uma data inválida em `purchase`, um `product_id` vazio em `stock` e um `product_id` de `purchase` sem produto correspondente em `stock`. Em cada um deles, a execução termina com código 1 e a mensagem `nothing was written`.

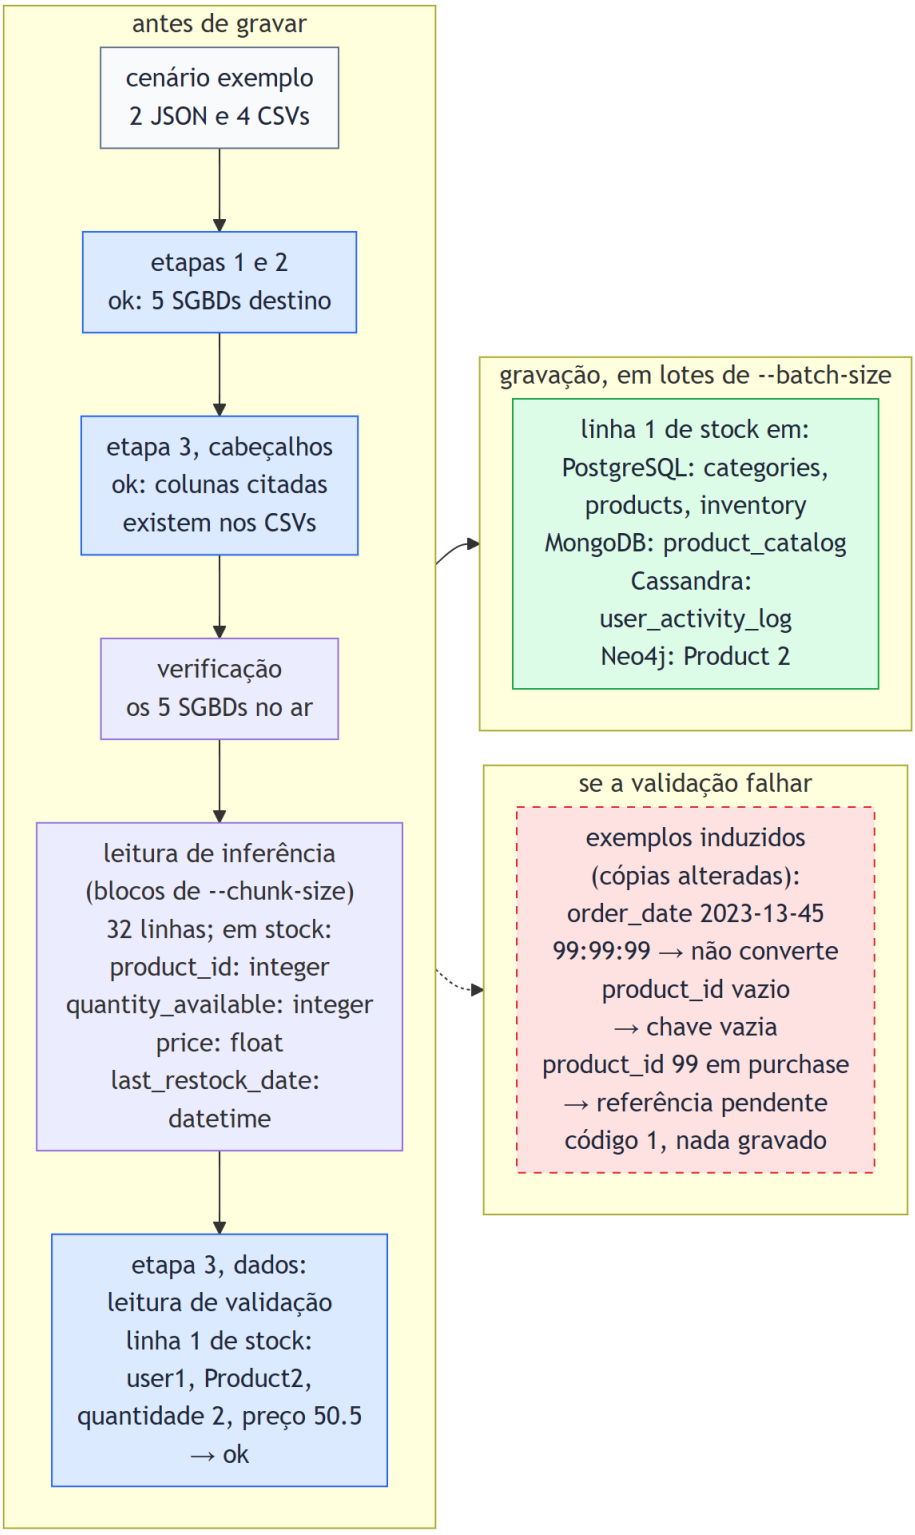


Figura 12 – Caminho da primeira linha de `stock` no cenário exemplo, com três problemas induzidos em cópias alteradas dos arquivos.

Fonte: Elaborado pelo autor (2026), a partir de execuções reais da ferramenta.

A Tabela 8 apresenta as oito linhas da fonte `stock` (`ecommerce_stock.csv`), que servem de fio condutor do exemplo. Para caber na página, a tabela resume as colu-

nas de identificação, cujos valores seguem padrões regulares no arquivo: o produto `Product`N tem `product_id` N e pertence à categoria `Categoria`N (`category_id` N); o usuário `user`N é identificado por um `user_id` alfanumérico (por exemplo, `7fd7eee7-...` para `user1`), tem e-mail `user`N`@example.com` e um endereço próprio, detalhado no Apêndice B; a descrição e a imagem do produto seguem padrões análogos. Todos os eventos de estoque ocorrem em 02/11/2023, e a coluna `last_restock_date` repete o instante do próprio evento (Tabela 25, no Apêndice B).

Tabela 8 – Linhas da fonte `stock` (`ecommerce_stock.csv`, colunas de identificação resumidas; todas as colunas, inclusive `last_restock_date`, estão na Tabela 25).

Hora	Usuário	Produto	Variante	Marca	Categoria	Qtd.	Preço
03:30	user1	Product2	blue	Microsoft	Categoria2	2	50.5
06:45	user2	Product3	green	Google	Categoria3	1	52.07
09:15	user2	Product9	black	Pepsi	Categoria9	67	32.78
12:00	user8	Product8	white	Google	Categoria8	60	46.79
14:30	user9	Product4	yellow	Apple	Categoria4	82	55.94
17:15	user9	Product5	red	Samsung	Categoria5	57	34.21
20:00	user9	Product6	orange	Coca-Cola	Categoria6	64	51.98
22:30	user9	Product7	grey	Audi	Categoria7	1	100000

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_stock.csv`.

4.3.3 A Importação em Cada SGBD

Apresentados os arquivos de dados, esta subseção acompanha o percurso dessas linhas pelos passos de gravação, SGBD a SGBD. Em cada caso estão em jogo as entradas da ferramenta: as linhas da fonte pertinente, o trecho correspondente do arquivo de importação e o arquivo de conexão — trechos reproduzidos nas listagens da seção 4.2 e, na íntegra, no Apêndice C. O que varia de um SGBD para outro é a estrutura de dados produzida como saída, apresentada a seguir.

PostgreSQL. O arquivo de importação declara quatro entidades (Listagem 4.11). A entidade `inventory` lê da fonte `stock` e projeta quatro colunas, com o `product_id` como chave: o resultado é a relação da Tabela 9, criada e gravada no banco `ecommerce` declarado no arquivo de conexão (Listagem 4.16). As entidades `categories` e `products` também leem de `stock` e recebem os oito produtos e as oito categorias da fonte, todos distintos; a entidade `orders` lê da fonte `purchase` (as oito compras). As chaves estrangeiras declaradas em `relationships` ligam produtos a categorias e pedidos a produtos. Como a coluna `price` é declarada `NUMERIC(14,2)`, o PostgreSQL guarda os

preços com duas casas decimais (`50.50` para o `50.5` do CSV).

Tabela 9 – Relação `inventory` gravada no PostgreSQL a partir da fonte `stock`.

product_id	quantity_available	last_restock_date	price
2	2	02/11/2023 03:30	50.50
3	1	02/11/2023 06:45	52.07
9	67	02/11/2023 09:15	32.78
8	60	02/11/2023 12:00	46.79
4	82	02/11/2023 14:30	55.94
5	57	02/11/2023 17:15	34.21
6	64	02/11/2023 20:00	51.98
7	1	02/11/2023 22:30	100000.00

Fonte: Elaborado pelo autor (2026), a partir da tabela gravada.

MongoDB. A entidade `product_catalog` (Listagem 4.12) também lê da fonte `stock`, mas grava cada linha como um documento cuja hierarquia reproduz o aninhamento declarado em `columns`. A Listagem 4.19 mostra o documento gerado a partir da primeira linha de estoque, tal como lido do MongoDB depois da importação, com a data na notação do terminal do MongoDB. Os valores são gravados com os tipos fixados pela leitura de inferência: números como números e a data como data, e não como o texto lido do CSV; os subdocumentos `category` e `stock` agrupam, sem repetição de linhas, o que no PostgreSQL ficou distribuído em três tabelas ligadas por chaves estrangeiras — a representação desnormalizada característica do modelo de documentos.

```
{
  "product_id": 2,
  "product_name": "Product2",
  "product_variant": "blue",
  "product_brand": "Microsoft",
  "product_description": "Description1",
  "product_image": "https://example.com/image1.jpg",
  "price": 50.5,
  "category": {
    "category_id": 2,
    "category_name": "Categoria2"
  },
  "stock": {
    "quantity_available": 2,
    "last_restock_date": ISODate("2023-11-02T03:30:00Z")
  }
}
```

Listagem 4.19 – Documento gerado na coleção `product_catalog` para a primeira linha de estoque.

Cassandra. A entidade `user_activity_log` (Listagem 4.13) une as quatro fontes: os 32 eventos alimentam a tabela, com `timestamp` renomeado para `event_time` e a pseudo-coluna `_source` mapeada para `event_type`. A chave primária composta — partição por `user_id`, agrupamento por `timestamp` — faz com que todos os eventos de um mesmo usuário fiquem na mesma partição, ordenados no tempo. A Tabela 10 mostra a partição do usuário `user1`: os seus quatro eventos, um de cada fonte, com as colunas de referência preenchidas conforme a origem — cada fonte preenche apenas o subconjunto de colunas pertinente ao seu evento, agora a serviço de uma consulta típica do modelo colunar ("o histórico de atividades de um usuário").

Tabela 10 – Partição do usuário `user1` na tabela `user_activity_log` (Cassandra).

event_time	event_type	product_id	order_number	selected_product_id	shopping_cart_id
02/11 03:30	stock	2	—	—	—
15/11 15:09	select_product	—	—	11	—
15/11 15:17	add_to_cart	—	—	—	user:7fd7. . . :cart
15/11 15:46	purchase	2	ORD1	—	—

Fonte: Elaborado pelo autor (2026).

Redis. As duas entidades desse SGBD (Listagem 4.14) leem de fontes distintas: `shopping_cart` da fonte `add_to_cart` e `user_session` da fonte `select_product`. Cada linha torna-se um par chave-valor: a chave é o valor da coluna marcada com `is_key` e o valor é a representação textual (JSON) dos demais campos mapeados. A Listagem 4.20 mostra os dois pares gerados a partir dos eventos de `user1`; ao todo, são oito carrinhos e oito sessões. Como `shopping_cart` usa mapeamento automático, o seu valor reúne todas as demais colunas da fonte `add_to_cart`; já `user_session` mapeia apenas os campos declarados. Note-se que o padrão `user:. . . :cart` da chave do carrinho vem do próprio CSV (coluna `shopping_cart_id`), e não de alguma convenção da ferramenta.

```
chave: user:7fd7eee7-4675-4f56-ad81-108da6cecebc:cart
valor: {"timestamp": "2023-11-15 15:17:30+00:00", "user_id": "7fd7
   ...",
        "user_name": "user1", "user_email": "user1@example.com",
        "cart_product_id": 3, "cart_quantity": 1}
chave: 7fd7eee7-4675-4f56-ad81-108da6cecebc
valor: {"user_name": "user1", "user_email": "user1@example.com",
        "last_seen": "2023-11-15 15:09:30+00:00"}
```

Listagem 4.20 – Pares chave-valor gerados no Redis a partir dos eventos de `user1`.

Neo4j. As entidades e a aresta da Listagem 4.15 produzem um grafo de propriedades: os oito produtos da fonte `stock` dão origem aos nós `Product`; os oito compradores da fonte `purchase` dão origem aos nós `User` e às oito arestas `PURCHASED`, identificadas pelo número do pedido e decoradas com quantidade, preço e nota da avaliação. A semântica de mesclagem garante que nós e arestas não se dupliquem quando a mesma chave reaparece. A Listagem 4.21 representa, na notação usual de grafos de propriedades, o fragmento do grafo derivado da primeira compra (`ORD1`).

```
(:User {user_id: "7fd7eee7-...", user_name: "user1",
        user_email: "user1@example.com"})
    -[:PURCHASED {order_number: "ORD1", quantity: 1,
                  price: 50.5, rating: 2}]->
(:Product {product_id: 2, product_name: "Product2",
           product_brand: "Microsoft"})
```

Listagem 4.21 – Fragmento do grafo gravado no Neo4j para o pedido `ORD1`.

A Tabela 11 consolida o percurso, tomando por referência a primeira linha da fonte `stock` (Tabela 8, o produto `Product2`): cada célula da coluna “Saída gravada” decorre diretamente das entidades, do vínculo com a fonte e das `columns` declaradas no arquivo de importação.

Tabela 11 – Gravação de uma linha da fonte `stock` nos diferentes SGBDs.

SGBD	Entidade	Fonte	Saída gravada
PostgreSQL	`inventory` (a linha também alimenta `products` e `categories`)	`stock`	Linha da Tabela 9: `product_id`, `quantity_available`, `last_restock_date`, `price`.
MongoDB	`product_catalog`	`stock`	Documento da Listagem 4.19, com subdocumentos `category` e `stock` aninhados.
Cassandra	`user_activity_log`	`stock` ∪ demais	Registro com `timestamp` e `_source` renomeados para `event_time` e `event_type`; chave primária composta `(user_id, timestamp)`.
Redis	—	—	As entidades Redis leem de outras fontes; esta linha não alimenta o Redis.
Neo4j	nó `Product`	`stock`	Nó `:Product` da Listagem 4.21, identificado por `product_id`.

Fonte: Elaborado pelo autor (2026).

Assim, **fontes heterogêneas** alimentam destinos igualmente heterogêneos: tabelas relacionais, documentos aninhados, *log* colunar com renomeação de colunas e união de fontes, pares chave-valor e um grafo de propriedades — concretizando a persistência poliglota descrita no capítulo 2. As contagens observadas neste percurso (oito registros por entidade de estoque e 32 no registro de atividades) reaparecem na verificação prévia da execução, apresentada a seguir.

4.3.4 Exemplo de Uso e Evidência de Execução (Cenário Exemplo)

Esta seção demonstra o uso da ferramenta em uma execução completa do cenário exemplo, que acompanha o código-fonte. Todos os arquivos de entrada encontram-se no diretório `data/ecommerce/` do repositório da ferramenta: os

quatro CSVs de fonte (`ecommerce_stock.csv`, `ecommerce_purchase.csv`, `ecommerce_select_product.csv` e `ecommerce_add_to_cart.csv`), com oito linhas cada; o arquivo de importação `import_config.json`, cujos fragmentos por SGBD foram apresentados nas Listagens 4.11 a 4.15; e o arquivo de conexão `dbms_config.json`, cujos fragmentos acompanham as mesmas subseções — ambos reproduzidos na íntegra no Apêndice C. Além deles, o arquivo `docker-compose.yml`, na raiz do repositório, define os contêineres dos cinco SGBDs usados no exemplo. A execução usa o comando apresentado na seção 4.1, instanciado com esses arquivos:

```
python -m polyglotimportcsv \
  --config data/ecommerce/import_config.json \
  --dbms-config data/ecommerce/dbms_config.json \
  --dry-run
```

Com a opção `--dry-run`, a ferramenta executa os passos 1, 2, 4 e 5 da Figura 11 — todas as etapas de validação, inclusive as leituras de inferência e de validação —, mas não abre conexão com nenhum SGBD. O resultado são as contagens da Tabela 12: as linhas que cada destino receberia, úteis para revisar o mapeamento antes da carga real.

Tabela 12 – Linhas a gravar em cada destino, após os filtros, reportadas pelo modo `--dry-run` no cenário exemplo.

SGBD	Destino	Linhas a gravar
PostgreSQL	`categories`	8
PostgreSQL	`products`	8
PostgreSQL	`inventory`	8
PostgreSQL	`orders`	8
MongoDB	`product_catalog`	8
MongoDB	`orders_state_SP`	2
MongoDB	`orders_state_`CA, RJ, RS, SC, SE e TO	1 cada
Cassandra	`user_activity_log`	32 (união das 4 fontes)
Redis	`shopping_cart`	8
Redis	`user_session`	8
Neo4j	nó `User`	8
Neo4j	nó `Product`	8
Neo4j	aresta `PURCHASED`	8

Fonte: Elaborado pelo autor (2026), a partir da saída do `--dry-run`.

As contagens são de linhas depois dos filtros e da divisão por `each`, e antes

de qualquer eliminação de duplicatas, que acontece na gravação e varia por SGBD. No PostgreSQL, a ferramenta descarta, dentro de cada lote, as linhas com chave repetida, mantendo a última, e grava com `INSERT ... ON CONFLICT DO NOTHING`, de modo que, entre lotes diferentes, prevalece a primeira linha gravada. No Neo4j, o `MERGE` não duplica nós nem arestas já existentes: entre linhas com a mesma chave de nó, prevalece a primeira; numa aresta repetida, prevalecem as propriedades da última linha. No Cassandra e no Redis, uma escrita com chave já existente substitui o registro anterior. No MongoDB, não há eliminação de duplicatas: cada linha gera um documento. No cenário exemplo, nenhuma chave se repete — as oito compras são de oito compradores e oito pedidos distintos —, e o que é gravado coincide com as contagens da tabela.

A ferramenta nunca inicia os SGBDs: quem os coloca no ar é o usuário, antes da importação real. No cenário exemplo, isso se faz com `docker compose up -d` na raiz do repositório; o arquivo `docker-compose.yml` também acompanha os pacotes executáveis da ferramenta. Também é possível usar instalações nativas, alcançadas pelos endereços do arquivo de conexão. Com os SGBDs no ar, basta repetir o mesmo comando sem a opção `--dry-run`: as linhas da Tabela 12 são então gravadas nos cinco SGBDs configurados, concretizando o cenário poliglota da Seção 2.1. Alternativamente, o script `run_example.sh`, na raiz do repositório, automatiza o fluxo completo: sobe os contêineres do Docker Compose, se preciso, esvazia os SGBDs, executa o `--dry-run` e a importação real e, por fim, exibe os dados gravados.

Complementarmente à evidência de execução, testes automatizados (`pytest`) cobrem a validação por schema, a separação e mesclagem dos dois arquivos de configuração, a leitura das fontes (multifonte e combinada), o mapeamento de colunas (`csv_column`, `schema_column`, aninhamento, mapeamento automático), a união de fontes, a inferência e conversão de tipos, os filtros, cada problema apontado pela leitura de validação e a leitura em blocos. Um dos testes executa o `--dry-run` do cenário exemplo nos dois modos e confere que ambos produzem exatamente as contagens da Tabela 12.

4.4 OBSERVABILIDADE E MÉTRICAS

Importar dados para cinco SGBDs em uma só execução exige que o usuário consiga **acompanhar** o que ocorre e **diagnosticar** falhas sem recorrer ao código-fonte. Para isso, a ferramenta incorpora uma camada de observabilidade, construída sobre a biblioteca `rich`, e um subsistema de métricas de desempenho. Além de servir ao uso cotidiano, esse subsistema é o **instrumento de medição** empregado na avaliação de desempenho do Capítulo 5.

Relato da execução. Cada execução emite, no terminal, um relato estruturado:

um cabeçalho com o modo (importação ou *dry-run*), uma linha para cada passo do fluxo (seção 4.3), a contagem de linhas de cada entidade e, ao final, o quadro de métricas. Os problemas encontrados pela leitura de validação aparecem em um quadro próprio, com a contagem e os exemplos de cada um. O nível de detalhe das mensagens é ajustável por `--log-level` (`DEBUG`, `INFO`, `WARNING` ou `ERROR`; padrão `INFO`). Independentemente do nível escolhido para o terminal, a ferramenta grava um **arquivo de *log* de sessão** sempre em nível `DEBUG`, em `logs/polyglotimportcsv_<carimbo de tempo>.log`, preservando o rastro completo de cada execução para diagnóstico posterior. Para inspeção dos dados, a ferramenta exibe as primeiras linhas de cada entidade — 50, por padrão, número ajustável por `--sample N` —, acompanhadas da contagem total; `--show-data` exibe todas as linhas e `--no-data` suprime a exibição. As linhas da amostra são retidas à medida que os lotes passam, só até o tamanho da amostra, de modo que a exibição não compromete o consumo limitado de memória da leitura em blocos (seção 4.5.2).

Métricas de desempenho. Ao longo da execução, a ferramenta mede o tempo de três **fases**: a **inferência** (`infer`, a leitura de inferência de todas as fontes), a **validação** (`validate`, a leitura de validação) e a **escrita** (`write`), medida uma vez para cada SGBD destino, do preparo do SGBD ao fechamento da conexão. Para cada fase registram-se o número de linhas processadas e o tempo decorrido, do que se deriva a vazão em linhas por segundo. Ao final, um quadro-resumo apresenta essas métricas no terminal. Quando a opção `--benchmark` está ativa, a ferramenta grava as métricas em disco — um arquivo JSON com carimbo de tempo e uma linha acrescentada a um CSV histórico, no diretório `benchmarks/` —, acompanhadas de metadados do ambiente de execução (versão do Python, sistema operacional e tamanho de cada fonte).

O **pico de memória** é medido pelo executor das campanhas de medição do Capítulo 5, que registra, para cada importação, o maior volume de memória alocado pelo interpretador Python, com a biblioteca `tracemalloc`. Essa instrumentação deixa as fases mais lentas em proporções diferentes umas das outras, e por isso o tempo e o pico de memória vêm de campanhas separadas, como descreve o Capítulo 5. Essa gravação estruturada é o que viabiliza a coleta sistemática de resultados reproduzíveis.

4.5 ESTRATÉGIA DE ESCRITA E MODELO DE EXECUÇÃO

O desempenho de uma importação depende de dois aspectos do projeto da ferramenta. O primeiro é a **estratégia de escrita**: a forma como os valores lidos são **convertidos** aos tipos nativos e **gravados** no SGBD, linha a linha ou em lote. O segundo é o **modelo de execução**: a forma como os arquivos ocupam a memória durante a importação. A seção 4.5.1 descreve como os dois evoluíram ao longo do projeto, e a seção 4.5.2, o modelo da versão final, a leitura em blocos, com o efeito do

tamanho do bloco.

4.5.1 Evolução da Estratégia de Escrita e do Modelo de Execução

A primeira implementação da ferramenta, desenvolvida na primeira etapa deste Trabalho de Conclusão de Curso (TCC1), adotava a estratégia aqui chamada de **ingênua** (*naive*): os registros eram percorridos **um a um**, cada célula era convertida ao tipo nativo por uma chamada individual e cada linha era gravada no SGBD por um comando próprio. Esse caminho é simples, mas paga, por linha, o custo de uma conversão isolada e de uma ida e volta à rede (e, quando aplicável, de uma confirmação de transação).

No TCC2, a ferramenta evoluiu para a estratégia **em lote** (*batch*), que amortiza esses dois custos processando os dados em blocos. A conversão de tipos passou a ser **vetorizada**: realizada uma vez por coluna, sobre todo o conjunto de valores, em vez de célula a célula, produzindo exatamente os mesmos valores e tipos que a conversão individual. Concretamente, uma única operação da biblioteca de dados (pandas) converte todos os valores de uma coluna de uma vez; nenhuma estrutura de índice é criada para isso. A gravação passou a ser feita em **lotes**: um único comando carrega muitos registros de uma vez, reduzindo drasticamente o número de idas e vindas à rede. A estratégia em lote é a única da ferramenta; não há opção para escolher outra.

Cada SGBD implementa o lote com o recurso idiomático do seu respectivo controlador (*driver*): no **PostgreSQL**, a inserção em lote de `execute_values`; no **MongoDB**, a inserção múltipla de `insert_many`; no **Cassandra**, a execução concorrente de comandos preparados (com grau de concorrência 64 dentro de cada lote); no **Redis**, o enfileiramento de comandos em um *pipeline* despachado de uma só vez; e no **Neo4j**, a cláusula `UNWIND` aplicada a uma lista de registros, seguida de `MERGE`, sobre um rótulo com restrição de unicidade.

O modelo de execução também mudou ao longo do projeto. O modelo original, a **materialização**, carregava cada fonte inteira na memória, em uma estrutura tabular (*DataFrame*), antes de gravá-la. O pico de memória desse modelo cresce com o tamanho do arquivo: um arquivo maior que a memória disponível não chegaria a ser carregado, e a importação falharia por falta de memória. Essa limitação motivou a leitura em blocos, descrita a seguir, que conviveu com a materialização durante o TCC2 e é o único modelo de execução da versão final da ferramenta.

~~A~~ As duas mudanças foram decididas com base em medições feitas com uma versão anterior da ferramenta, que ainda oferecia a estratégia ingênua e a materialização~~permanecem descritas neste trabalho porque são as *linhas de base* contra~~

~~as quais o Capítulo 5 mede, com números históricos, o ganho da~~ , sobre a carga do cenário exemplo sem a coleção `orders` do MongoDB. Em uma importação de dez mil linhas com materialização, a estratégia em lote ~~e a redução~~ foi 9,3 vezes mais rápida que a ingênua no modo multifonte (14,54 contra 135,74 s) e 8,5 vezes no combinado (16,30 contra 138,44 s). Em cem mil linhas, a leitura em blocos atingiu um pico de memória ~~da~~ 12,5 vezes menor que o da materialização (75,9 contra 950,7 MB), a um custo de apenas 10% a mais de tempo (165,03 contra 149,93 s); e, enquanto o pico da materialização cresceu quase na mesma proporção que o arquivo, o da leitura em blocos ~~.~~ cresceu bem menos. Esses números justificam as duas decisões e são citados aqui apenas para isso: o Capítulo 5 mede somente a versão final da ferramenta.

4.5.2 Modelo de Execução: Leitura em Blocos

Na **leitura em blocos** (em inglês, *streaming*), nenhum arquivo é carregado inteiro: cada uma das leituras do fluxo (seção 4.3) percorre o arquivo em **blocos** de linhas, e cada bloco é tratado antes de o próximo ser lido. O tamanho do bloco é dado em memória, ~~pela opção `--chunk-size` (8 MB, por padrão, de 8 a 256 MB)~~em MB. Para convertê-lo em linhas, a ferramenta lê as primeiras mil linhas de cada arquivo, mede quanto cada linha ocupa na memória e divide o orçamento do bloco por esse valor; a estimativa é aproximada, pois um arquivo cujas linhas fiquem mais largas adiante ultrapassa o orçamento. Na gravação, as linhas de cada destino acumulam-se até completar um **lote** de ~~`--batch-size` linhas(1024, por padrão, de 1024 a 8192),~~ linhas, limitado às linhas de um bloco, para que um lote não retenha vários blocos na memória.

~~O~~ Os dois tamanhos são escolhidos **automaticamente** a cada execução, a partir da campanha exploratória da seção 5.3.5. O lote tem 2.048 linhas, porque nenhum tamanho de lote mostrou vantagem mensurável. O bloco é o que lê a maior fonte da importação inteira, porque é isso que torna as leituras mais rápidas, e um bloco maior que ela só ocuparia memória. Esse bloco é limitado pela memória livre do computador, lida no início da execução: o pico de memória previsto para a importação — uma base que cresce com o tamanho dos arquivos em disco, mais cerca de 1,08 MB por MB de bloco — deve caber em 25% dela. Quando não cabe, o bloco é o maior que cabe, e a importação troca um pouco de tempo por memória. O resultado fica sempre entre 16 e 256 MB, e a ferramenta informa no console e no *log* o tamanho escolhido e o motivo, por exemplo `Read block: 96 MB (auto: largest source read whole (96.1 MB); 1033 MB free)`. Para estimar quanto a maior fonte ocupa inteira, a ferramenta multiplica o tamanho do arquivo pela razão entre a memória e o espaço em disco das suas primeiras mil linhas, sem ler o arquivo de novo. As opções `--chunk-size` (de 16 a 256 MB) e `--batch-size` (de 512 a 8.192 linhas) continuam disponíveis para fixar os dois valores à mão.

O pico de memória acompanha, assim, o tamanho do bloco, e não o do arquivo. Além do bloco, a memória guarda os agregados por coluna da leitura de inferência, que resumem o necessário para decidir o tipo de cada coluna; na leitura de validação, os conjuntos de chaves das entidades referenciadas, usados para conferir as referências pendentes; e, na escrita no Neo4j, o conjunto das chaves de nós já gravadas, usado para não repeti-las. Esses conjuntos crescem com o número de chaves distintas, e não com o número de linhas; um arquivo maior que a memória disponível pode ser importado desde que eles caibam nela.

A Tabela **??** mostra o efeito do tamanho do bloco em uma importação de cem mil linhas no modo multifonte, medida nas campanhas do Capítulo 5.

Efeito do tamanho do bloco ($N = 100\,000$, multifonte): pico de memória e tempos, em medianas de três repetições. Fonte: Elaborado pelo autor (2026). Pico de `benchmarks/v3/chunks-memory/` (com instrumentação de memória); tempos de `benchmarks/v3/chunks-timings/` (sem instrumentação).

Em cem mil linhas, a maior fonte, `purchase`, ocupa 10 blocos de 8 MB, 2 de 64 MB e um só de 256 MB; as outras três ocupam 2 blocos de 8 MB e um só a partir de 64 MB. Com o bloco de 256 MB, portanto, cada fonte já é lida inteira de uma vez. Em relação ao bloco de 8 MB, o de 64 MB dobra o pico de memória e reduz o tempo total em 5,4%; o de 256 MB eleva o pico 2,3 vezes e reduz o tempo em 6,4%. O ganho concentra-se nas leituras de inferência e de validação, que leem mais linhas por bloco; a escrita, que domina o tempo, quase não muda. O padrão de 8 MB privilegia, portanto, a memória, e blocos maiores compensam pouco.

A arquitetura que viabiliza a leitura em blocos segue o padrão **portas e adaptadores** (*ports and adapters*). Um **orquestrador** agnóstico de SGBD coordena o fluxo, mas não conhece nenhum banco em particular: ele não emite SQL nem Cypher e não remove duplicatas. Toda a especificidade de cada SGBD é isolada atrás de uma **porta** de escrita comum, para a qual cada banco fornece um **adaptador**. A leitura de validação usa o mesmo orquestrador, com adaptadores que, em vez de gravar, conferem os registros; é isso que garante que ela passe as linhas pelo mesmo tratamento da gravação.

O tratamento de cada bloco reproduz, em pequena escala, os passos de gravação: o orquestrador aplica os filtros de seleção, converte os tipos (de forma vetorizada, com os tipos fixados na leitura de inferência) e roteia as linhas para as suas partições de destino, acumulando-as em áreas de espera; quando uma partição completa um lote, ele é entregue ao adaptador correspondente. Duas particularidades merecem nota: as **arestas** do Neo4j exigem uma **releitura** das fontes que as alimentam, feita depois de todos os nós, pois uma aresta só pode ser criada entre nós que já existem; e

uma mesma entidade pode ser alimentada por mais de um CSV (**fontes-união**).

4.6 INTERFACE GRÁFICA

Todas as capacidades descritas até aqui são acionadas por uma interface de linha de comando governada por doze opções, que precisam ser digitadas corretamente a cada execução e cujos erros de sintaxe só se manifestam depois que o comando é submetido. Para reduzir essa barreira — sem esconder a ferramenta de quem deseja aprendê-la — foi construída uma **interface gráfica** *desktop* sobre a CLI já existente. O princípio que orienta o seu projeto é deliberadamente didático: **o comando exibido é o comando executado**. Cada opção de uso cotidiano da CLI corresponde a um controle gráfico, e o comando resultante permanece visível o tempo todo, de modo que a interface **ensina** a linha de comando em vez de substituí-la.

A interface é um **invólucro fino**: ela não reimplementa nenhum passo da importação. O seu núcleo traduz o estado do formulário na lista de argumentos da CLI e a executa como **processo filho**, capturando a saída do processo e apresentando-a em um console integrado. Duas consequências decorrem dessa escolha. A primeira é de correção: como quem importa é a própria CLI, não existe risco de a interface e a linha de comando divergirem em comportamento, e toda a validação por *JSON Schema* descrita na Seção 4.2 continua sendo exercida pelo mesmo código. A segunda é de arquitetura: os módulos que montam o comando, validam as entradas, resolvem o executável e traduzem a saída não dependem da biblioteca gráfica, podendo ser testados sem instanciar uma aplicação de janelas.

A janela divide-se em duas regiões, separadas por um divisor ajustável, como mostra a Figura 13. Os textos da interface estão em inglês, como as mensagens da CLI, para que a ferramenta possa ser usada fora do Brasil; o texto desta seção cita os rótulos como aparecem na tela. Na metade superior estão três cartões de formulário. O primeiro seleciona, por diálogos de arquivo, os dois arquivos de configuração. O segundo reúne as opções de execução (*Run options*), com um controle para cada opção: os SGBDs destino, ~~os campos “Bloco em MB (`--chunk-size`)” e “Lote (`--batch-size`)”, descritos na Seção 4.5.2,~~ a simulação (`--dry-run`), o nível de *log* e a exibição de dados — uma amostra das primeiras linhas de cada entidade, em quantidade escolhida pelo usuário, todos os dados ou nenhum. Ao lado de cada opção cujo nome não se explica sozinho há um **ícone de ajuda** que, ao receber o cursor ou um clique, descreve o efeito da opção; o ~~do bloco~~da simulação, por exemplo, explica que ~~blocos maiores usam mais memória. Uma~~ ela lê os dados sem conectar a nenhum SGBD. O bloco de leitura e o lote de gravação não têm controle no formulário, porque a CLI os escolhe a cada execução (Seção 4.5.2). Outra opção da CLI também não aparece no formulário: o registro de métricas de *benchmark*, instrumento da avaliação de desempenho

do Capítulo 5, e não do uso cotidiano da ferramenta, que continua disponível na linha de comando. O terceiro cartão~~contém a tabela de sobrescrita de caminhos das fontes CSV~~, *CSV files*, recebe os **arquivos CSV de entrada**: se ficar vazio, valem os caminhos declarados no bloco `sources` da configuração de importação; cada arquivo escolhido substitui o caminho da fonte correspondente (opção `--source`). Na metade inferior está o console integrado, que exibe o comando montado e, abaixo dele, a saída da execução.

O cartão de fontes adapta-se ao arquivo de importação escolhido. Sem uma configuração de importação válida, ele não aceita ~~fontes, pois uma sobrescrita~~ arquivos, pois um arquivo só ~~faz sentido diante das fontes~~ pode ser associado a uma fonte que a configuração declara. Com uma configuração **multifonte**, aceita vários arquivos — escolhidos um a um, de uma pasta inteira ou arrastados sobre a tabela —, e o nome de cada fonte é deduzido comparando o arquivo com o bloco `sources`, de modo que ~~a sobrescrita gerada~~ cada arquivo se refira a uma fonte que de fato existe. ~~Com uma~~ Uma configuração **combinada** ~~,~~ aceita um único arquivo, associado à única fonte declarada. Trocar de configuração não descarta as linhas já escolhidas: as que deixam de caber na nova configuração são apontadas como erro até que o usuário as remova.

Antes de executar, a interface faz uma **validação prévia** com o próprio código da CLI: as etapas 1 e 2 de validação e a parte da etapa 3 que olha os cabeçalhos (Seção 4.2.4). Os dois arquivos de configuração passam pelo mesmo *JSON Schema* e pela mesma verificação de consistência entre si; em seguida, cada CSV envolvido tem apenas o seu cabeçalho lido e conferido pela mesma regra da CLI. Uma coluna referenciada na configuração e ausente do arquivo produz, assim, exatamente a mensagem que a CLI emitiria, só que antes da execução, e o botão de execução permanece desabilitado enquanto houver pendências. A validação prévia da interface tem um limite deliberado: nada que exija conexão com um SGBD ou a leitura das linhas de dados é verificado nesse momento, porque os arquivos podem ser grandes e a interface responde a cada clique. A leitura dos dados fica a cargo da CLI, que a faz nas leituras de inferência e de validação, antes de gravar qualquer dado.

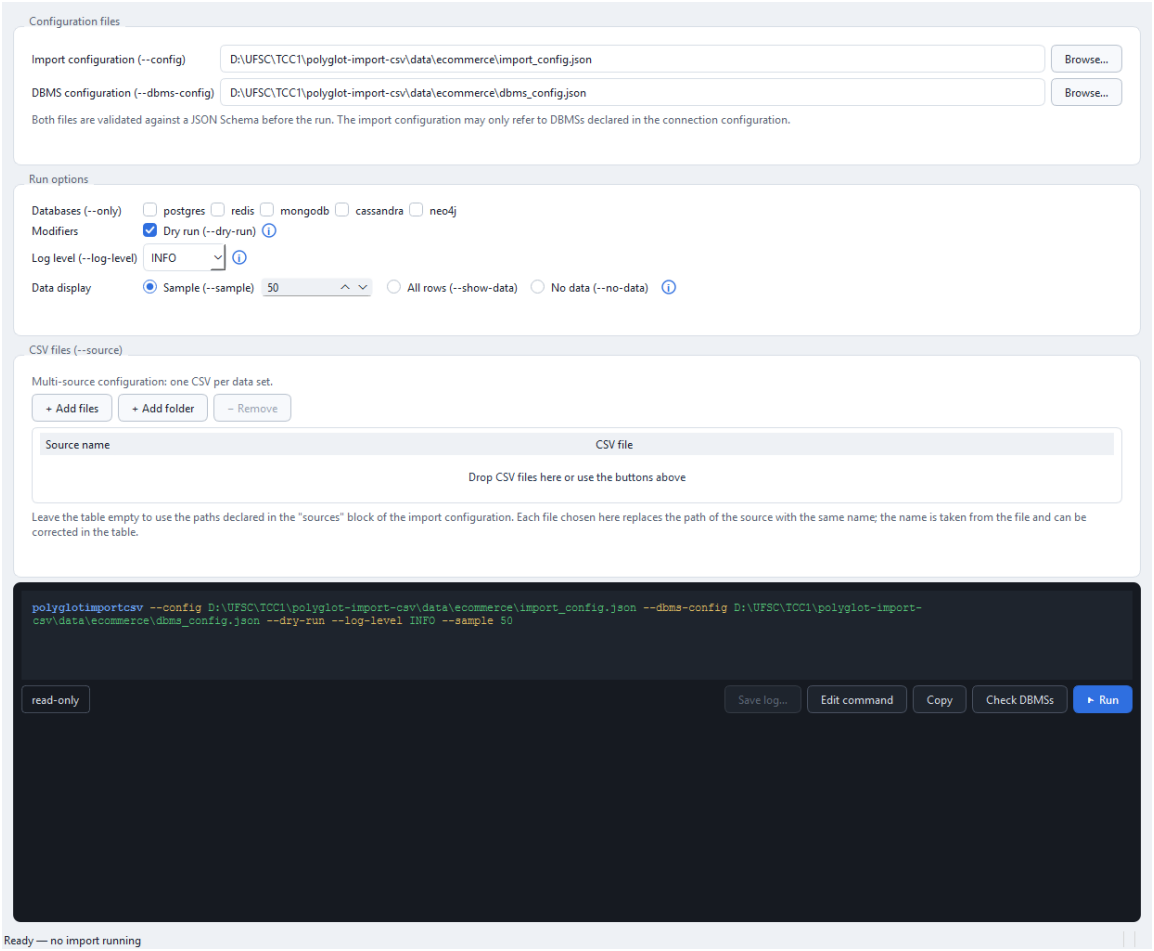


Figura 13 – Interface gráfica no estado ocioso: configuração multifonte escolhida, ícones de ajuda e comando montado, colorido, em modo somente leitura.

Fonte: Elaborado pelo autor (2026).

O comando montado é, por padrão, **somente leitura**, e **explicita todas as opções do formulário**, inclusive aquelas mantidas no valor padrão da CLI. A alternativa — omitir o que coincide com o padrão, de modo a permanecer tão curto quanto aquilo que uma pessoa realmente digitaria — contraria o propósito didático da interface: um controle deixado no padrão não produziria alteração visível no texto, e o clique pareceria ter sido ignorado. Escrever a opção por extenso custa alguns caracteres e devolve ao comando a propriedade que justifica exibi-lo — a de que cada controle do formulário tem um correspondente literal na linha de comando; o bloco e o lote, que a CLI escolhe sozinha, ficam de fora. Para facilitar a leitura, o comando é colorido: o nome do programa, as opções e os seus valores recebem cores distintas. Um **modo de edição** permite editar o texto diretamente; ao entrá-lo, o formulário é **bloqueado**, sinalizando que o texto passou a ser a fonte da verdade. Essa decisão é intencional e tem uma razão precisa: **não existe analisador de comando** na ferramenta. O caminho do formulário para o texto é de mão única, e manter os dois editáveis ao mesmo tempo exigiria reconstruir o estado do formulário a partir de uma cadeia de caracteres

arbitrária — precisamente o tipo de acoplamento que a interface se propõe a evitar. ~~Ao sair do~~ Enquanto o modo de edição ~~,~~ está ativo, é o texto digitado ~~é descartado~~ que será executado. Ao sair dele, mediante confirmação~~e o comando ,~~ esse texto é ~~remontado a partir dos controles~~desconsiderado e substituído pelo comando que a interface representa.

Durante a execução, o formulário permanece desabilitado, o botão principal passa a oferecer a interrupção do processo e a saída da CLI chega ao console de forma incremental, com as mesmas cores que teria em um terminal, como ilustra a Figura 14. Ao término, a barra de estado informa o desfecho: a Figura 15 mostra uma execução concluída, com o tempo total e o caminho do arquivo de *log* da sessão. Um clique nesse caminho abre a pasta em que o arquivo está, e o botão ~~**Salvar**~~ **Save log** copia-o para um local escolhido pelo usuário. O arquivo salvo é o *log* completo da sessão, em nível `DEBUG`, e não apenas o texto exibido no console.

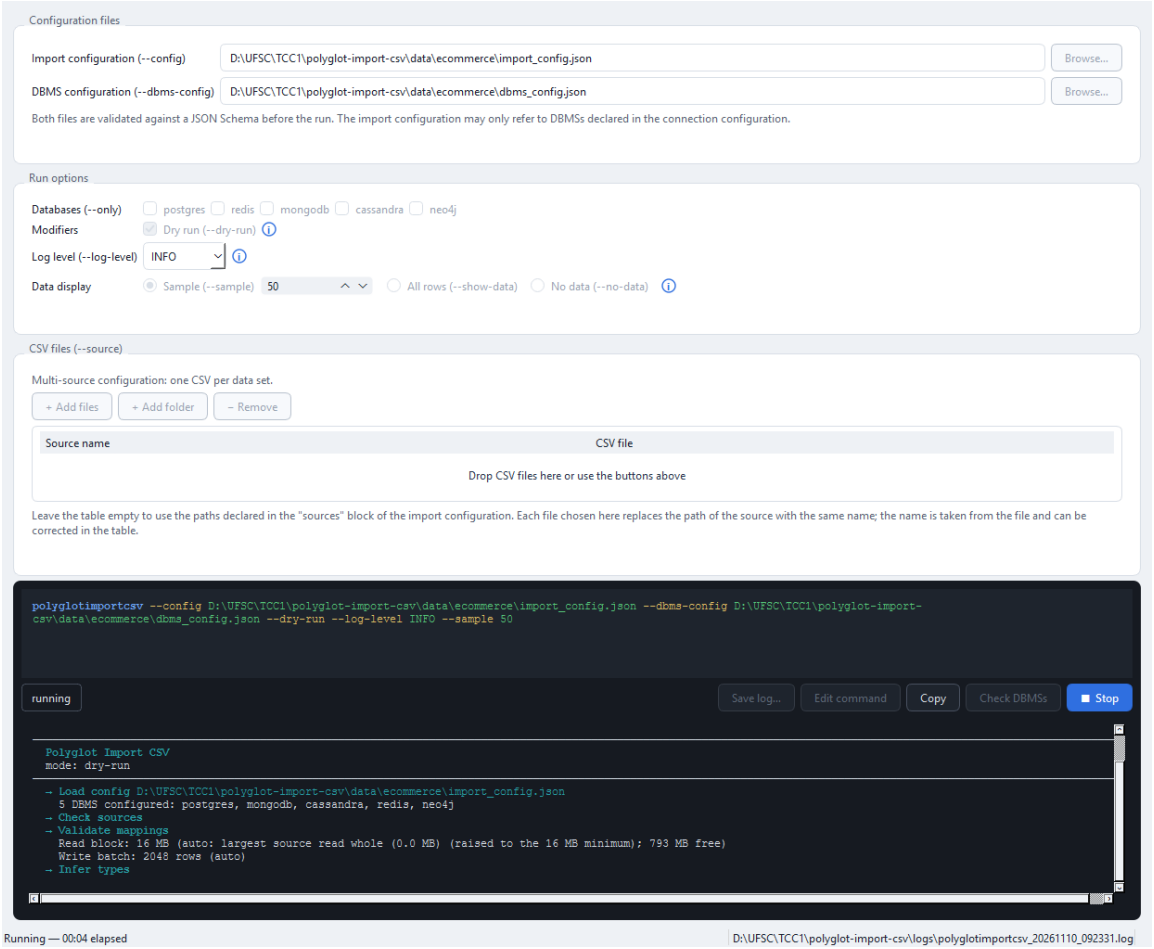


Figura 14 – Execução em andamento: formulário bloqueado, botão de interrupção e saída colorida da CLI chegando ao console em tempo real.

Fonte: Elaborado pelo autor (2026).

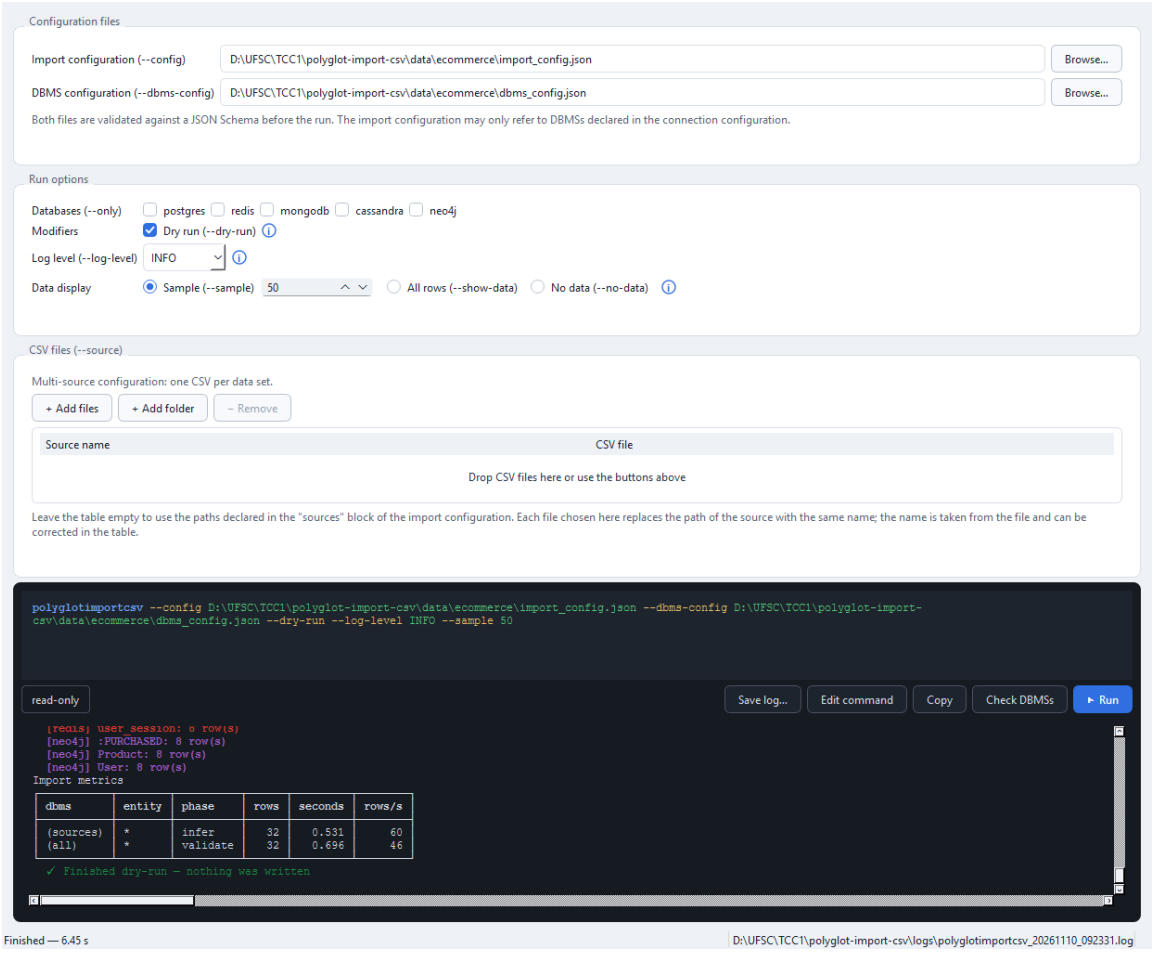


Figura 15 – ~~Execução~~ Simulação (`--dry-run`) concluída com sucesso, com o tempo total e o arquivo de *log* da sessão na barra de estado.

Fonte: Elaborado pelo autor (2026).

Os erros aparecem em dois momentos. Os que a validação prévia detecta são apresentados no próprio formulário, junto ao cartão a que se referem, como mostra a Figura 16: a mensagem é a mesma que a CLI produziria, e a execução fica bloqueada. Quando o usuário corrige o arquivo em um editor externo e retorna à janela, a validação é refeita automaticamente. Os erros que só surgem durante a execução — os problemas encontrados pela leitura de validação e as falhas de gravação em um SGBD — aparecem no console exatamente como apareceriam no terminal, e a barra de estado informa o código de saída do processo. Como a interface executa a CLI real, não há tradução intermediária que pudesse mascarar a mensagem.

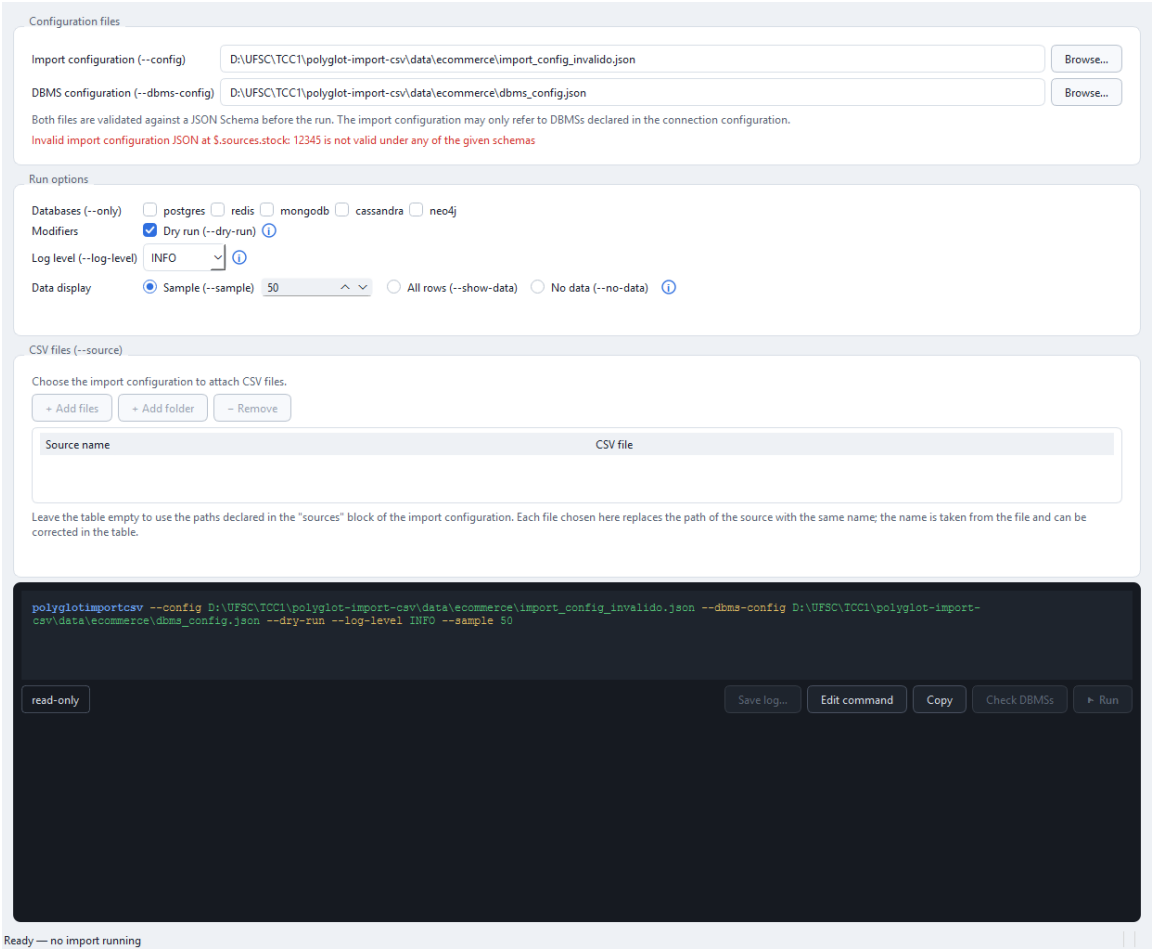


Figura 16 – Erro detectado antes da execução: a configuração de importação viola o *JSON Schema*, a mensagem da CLI, com o caminho do campo recusado, aparece no cartão de configuração e o botão de execução permanece desabilitado.

Fonte: Elaborado pelo autor (2026).

A disponibilidade dos SGBDs, que a validação prévia deliberadamente não examina, tem um botão próprio: ~~Verificar SGBDs~~Check DBMSs, ao lado do botão de execução. Ele executa a CLI com `--check-dbms`, com os arquivos de configuração e a seleção de SGBDs do formulário, e depende apenas de que esses dois arquivos sejam válidos — pendências nas fontes CSV não o bloqueiam, porque a verificação não lê dados. A saída é a mesma do terminal, inclusive os comandos que iniciam cada SGBD fora do ar, que o usuário copia para um terminal: o console integrado executa somente a própria ferramenta. A Figura 17 mostra uma verificação com dois SGBDs fora do ar.

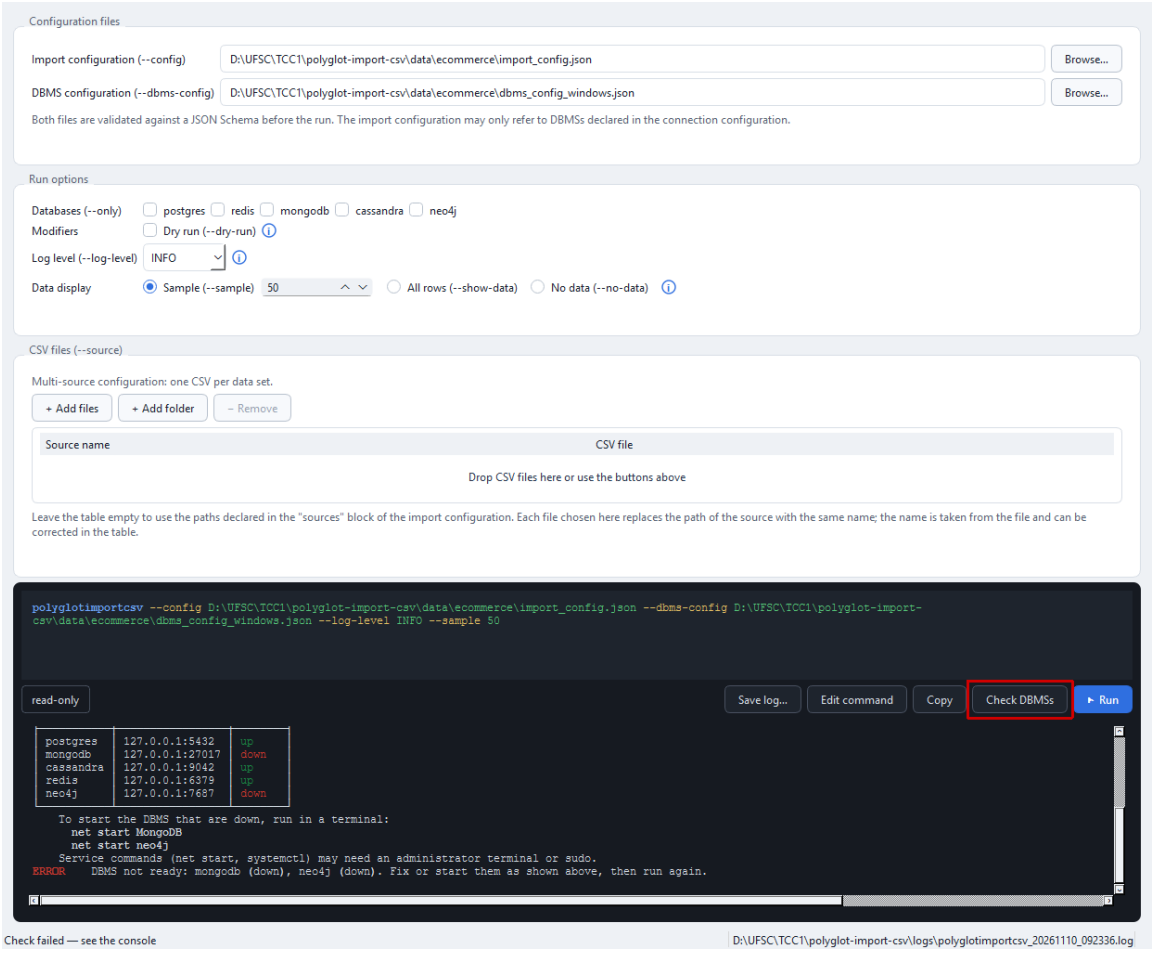


Figura 17 – Verificação dos SGBDs pela interface gráfica: o botão **Check DBMSs**, acionado, aparece destacado em vermelho; no console, MongoDB e Neo4j fora do ar e, abaixo da tabela de estados, os comandos que os iniciam.

Fonte: Elaborado pelo autor (2026).

Uma limitação de escopo deve ser registrada: a interface **monta, valida e executa** o comando, mas não **edita** os arquivos JSON de configuração, que continuam a ser mantidos em um editor de texto externo. Ampliar a interface para editar a configuração de forma assistida é uma das atividades futuras discutidas ~~no Capítulo ??~~na Seção 6.1.

5 AVALIAÇÃO DE DESEMPENHO

Este capítulo avalia empiricamente o desempenho da versão final da PolyglotImportCSV. A avaliação foi listada como objetivo específico no Capítulo 1 e apoia-se ~~diretamente no instrumento de medição~~ no subsistema de métricas descrito na seção 4.4~~— o subsistema de métricas~~, que cronometra cada fase da importação~~— e no~~ , e em um executor de campanhas, que ~~registra o pico de memória de cada importação~~repete as importações, limpa os SGBDs entre elas e consolida os resultados. O objetivo não é eleger o "melhor" SGBD — os cinco atendem a modelos de dados distintos —, mas caracterizar o custo de importar um mesmo conjunto de dados para cinco paradigmas ~~, o custo da validação prévia dos dados e o efeito do tamanho do bloco de leitura (~~e verificar como esse custo cresce com o volume de dados. As alternativas abandonadas durante o projeto — a escrita linha a linha e a carga do arquivo inteiro na memória — não são medidas aqui; os números que justificaram abandoná-las estão na seção ~~4.5.2~~). ~~Como linha de base, o capítulo apresenta ainda medições históricas das duas decisões de projeto descritas na seção 4.5.1: a escrita em lote, comparada à ingênua, e a leitura em blocos, comparada à materialização~~ 4.5.1.

A prática de comparar sistemas de dados sob uma carga sintética controlada e reproduzível segue a tradição consolidada por Cooper et al. (2010) com o *Yahoo! Cloud Serving Benchmark* (YCSB), que estabeleceu o gerador de carga determinístico e as métricas de *throughput* como base para avaliar sistemas de dados heterogêneos. No contexto específico de persistência poliglota, Landuyt et al. (2023) e Ye et al. (2023) conduzem comparações de desempenho entre múltiplos modelos de dados sob uma carga comum — o mesmo princípio que orienta este capítulo, aqui aplicado à etapa de **importação** e não à de consulta.

5.1 METODOLOGIA

A avaliação é organizada em torno de ~~sete~~ cinco **questões de pesquisa** (QP), ~~que os resultados da~~ respondidas na seção 5.3~~respondem~~, na mesma ordem:

- **QP1 — Custo por fase e por SGBD.** Como o tempo ~~total~~ de uma importação se ~~decompõe~~ divide entre as fases de inferência, validação e escrita, e ~~qual é o *throughput* de escrita de cada SGBD~~ quanto cada SGBD leva para gravar a sua parte dos dados?
- **QP2 — Modos de importação.** Importar a partir de um CSV por tipo de evento

(modo multifonte) ou de um único CSV combinado impõe custos distintos, e que vantagens tem cada modo?

- **QP3 — Escalabilidade.** Como o tempo e ~~a~~ o pico de memória ~~evoluem ao multiplicar~~ crescem com o volume de dados~~por dez, de mil a cem mil linhas~~: linearmente ou mais que linearmente?
- **QP4 — ~~Estratégia de escrita (histórica)~~Custo da validação prévia.** ~~Qual é o ganho de desempenho da estratégia em lote (conversão vetorizada e gravação em lotes) sobre a ingênua (linha a linha)?~~
- ~~**QP5 — Modelo de execução (histórica).** Qual é o custo, em tempo e em pico de memória, da leitura em blocos em relação à materialização?~~
- ~~**QP6 — Memória limitada (histórica).** O pico de memória da leitura em blocos deixa de acompanhar o tamanho do arquivo, como prevê o seu projeto?~~
- ~~**QP7 — Validação prévia e tamanho do bloco.** Quanto custam~~ Que fração do tempo de uma importação as leituras de inferência e de validação ~~, e como o tamanho do bloco afeta o pico de memória e o tempo?~~ ocupam?
- **QP5 — Tamanhos do bloco e do lote.** Como os tamanhos do bloco de leitura e do lote de gravação afetam o tempo e o pico de memória, e que valores a ferramenta deve escolher automaticamente?

~~As questões QP1, QP2, QP3 e QP7 são respondidas com a versão final da ferramenta. As questões QP4, QP5 e QP6 comparam opções que a versão final não oferece — a escrita ingênua e a materialização — e são respondidas com medições históricas, feitas com versões anteriores da ferramenta , como linhas de base das decisões de projeto da seção 4.5.1.~~

5.1.1 Geração dos Dados

A carga de trabalho é produzida por um **gerador determinístico** que sintetiza o domínio de comércio eletrônico do cenário exemplo (seção 4.3.2) a partir de um único parâmetro de escala N: o número total de linhas dos quatro CSVs, que o gerador divide entre as fontes em proporções fixas. Em ~~$N = 100\,000$~~$N = 262.144$, por exemplo, a fonte `stock` tem ~~11.609~~ 30.433 linhas, `purchase` tem ~~38.833~~101.797, `select_product` tem ~~25.445~~ 66.702 e `add_to_cart` tem ~~24.113. Todos os valores derivam de sementes fixas, de modo que a mesma escala N produz **sempre os mesmos arquivos**,~~ 63.212.

Os valores sintetizados derivam de uma **semente**: o número que inicializa o gerador de números pseudoaleatórios. A mesma semente produz sempre a mesma

sequência de valores e, portanto, os mesmos arquivos, byte a byte; o valor usado, 42, preservando é arbitrário — o que importa é que seja fixo. Os arquivos preservam a integridade referencial entre as fontes (todo produto referenciado em uma compra existe no estoque). Essa reprodutibilidade é o que permite comparar campanhas medidas em momentos diferentes: , e, como a carga é idêntica em todas as execuções, apenas o tempo e a memória variam entre execuçõeselas. O uso de um gerador sintético parametrizável, em vez de um conjunto de dados fixo, segue a mesma orientação metodológica do YCSB (COOPER et al., 2010).

Foram medidos seis volumes: $N = 1.024$, 16.384, 32.768, 65.536, 131.072 e 262.144 linhas. A partir de 16.384, cada volume é o dobro do anterior, o que torna direta a leitura do crescimento: se o tempo também dobra a cada passo, ele cresce em proporção ao volume.

5.1.2 Protocolo de Medição

Cada célula **célula** experimental é definida por uma combinação de **tamanho** ($N \in \{1000, 10\,000, 100\,000\}$), **modo** (volume e modo de importação (multifonte ou combinado)e **tamanho do bloco** de leitura (8, 64 ou 256 MB), e é repetida **três vezes**. Antes de cada repetiçãoexecução, os cinco SGBDs são **limpos**(*cold-load*): as estruturas de destino são esvaziadas, de modo que nenhuma repetição execução se beneficia de dados ou de caches *caches* deixados pela anterior. O valor reportado para cada Cada célula é executada **três vezes**, e o valor reportado é a **mediana** das trêsrepetições, que é , robusta a uma eventual repetição execução anômala; o . O tempo total de uma importação é a soma das medianas das suas fases.

O instrumento de medição impõe uma restrição metodológica importante. O tempo por fase é cronometrado com um relógio de alta resolução; já Tempo e memória são medidos em execuções separadas, por um motivo prático. Para obter o pico de memóriaé obtido instrumentando as alocações do interpretador Python . Essa instrumentação , o Python precisa registrar cada alocação de memória , porém, **infla o tempo** das fasesem proporções diferentes: na feita pelo programa (com o módulo `tracemalloc`), e esse registro deixa a importação de cem mil linhas no modo multifonte, ela multiplica o tempo total por $3{,}3$, o da mais lenta — e de forma desigual entre as fases. Na importação multifonte de 262.144 linhas desta avaliação, o registro deixou a importação inteira $2{,}5$ vezes mais lenta, mas a fase de inferênciapor $6{,}2$ e o da , que aloca muita memória, ficou $5{,}4$ vezes mais lenta, e a escrita no Cassandrapor apenas $2{,}1$, distorcendo, portanto, as fases umas em relação às outrasque passa a maior parte do tempo esperando o SGBD, apenas $1{,}6$ vez. Os tempos de uma execução que mede memória estariam, portanto, inflados e distorcidos entre as fases. Por isso, tempo e memória **não podem ser lidos da mesma execução**. Adotou-se um **protocolo**

pareado: duas campanhas cada célula é executada em duas **campanhas** idênticas em carga e configuração, uma : uma **comsem** a instrumentação o registro de memóriaativada (fonte dos picos de memória) e outra , de onde vêm todos os tempos, e outra **semcom** ela (fonte dos tempos). As campanhas pareadas produziram ele, de onde vêm todos os picos de memória. As duas campanhas processaram exatamente as mesmas contagens de linhas idênticas em todas as células, confirmando que o que confirma que executam a mesma carga. Ao longo do capítulo, **cada tabela e figura declara na legenda de qual campanha os seus números provêm**, e valores de tempo e de memória nunca são combinados em uma mesma linha.

Foram medidas quatro campanhas da versão final, todas com As duas campanhas fazem três repetições: duas com os execuções por célula; o pico reportado é a mediana dos três tamanhos e os dois modos, no bloco padrão de 8 MB (uma com e outra sem instrumentação de picos.

Os tamanhos do bloco de leitura e do lote de gravação são os que a ferramenta escolhe sozinha (seção 4.5.2). Como a escolha do bloco depende da memória), e duas com os três tamanhos de bloco, em cem mil linhas no modo multifonte (idem). A livre no momento, ela foi feita **uma vez por célula**, no início da campanha de tempo, e registrada nos metadados; todas as repetições da célulade cem mil linhas, multifonte, com bloco de 8 MB aparece nos dois pares de campanhas e serve de medida da precisão: o tempototal diferiu $2{,}7\%$ entre as duas campanhas sem instrumentação ($209{,}51$ e $204{,}00$ s) , e o pico de , nas duas campanhas, usaram o mesmo bloco. Os blocos escolhidos estão na Tabela 22.

Os resultados brutos de cada campanha (um arquivo CSV e um JSON com os metadados) estão no repositório do projeto[1], e a "Fonte" de cada tabela indica de qual das duas pastas vêm os seus números. Quando uma tabela mostra tempo e pico de memória , menos de $0{,}2\%$ entre as duas com instrumentação ($66{,}1$ e $66{,}2$ MB). Como essa comparação cobre uma só célula, ela não é generalizada: diferenças de tempo de poucos por cento lado a lado, cada valor vem da sua campanha, como indica a legenda; os dois nunca são lidas com cautela. As medições históricas (QP4 a QP6) vêm de outras quatro campanhas, pareadas da mesma forma, em que duas campanhas de tempo da mesma célula chegaram a diferir entre 15% e 38%; para elas, vale uma incerteza de tempo da ordem de 20%lidos de uma mesma execução.

[1] <https://github.com/lucasbc92/polyglot-import-csv/tree/50aee35/benchmarks/v4>: pasta `timings` (tempos) e pasta `memory` (picos de memória).

5.2 CONFIGURAÇÃO EXPERIMENTAL

Todos os experimentos ~~foram executados em uma **única máquina** com sistema operacional~~ rodaram em um mesmo computador, com processador Intel Core i5-8265U (8 processadores lógicos), 8 GB de memória e armazenamento SSD, sob Windows 11 ~~e Python 3.14.5; as campanhas da versão final rodaram no~~ (*build* 10.0.26300~~do sistema, e as históricas, no 10.0.26200. A semente global de geração foi fixada em 42 e cada célula foi repetida três vezes.~~), com Python 3.14.5. Os cinco SGBDs foram providos por contêineres Docker, nas versões indicadas na Tabela 13~~. Os contêineres partilham os recursos do mesmo hospedeiro (8 GB de memória física)~~, dentro de uma máquina virtual Docker de ~~3,88~~$3{,}88$ GiB e 8 processadores~~; em particular, o~~ , que partilha a memória do computador com a ferramenta. O Cassandra opera em um único nó, com fator de replicação 1 e *heap* de 1 GB — uma restrição de ambiente que se ~~mostrará relevante na análise da~~ mostra relevante na fase de escrita. ~~Durante as campanhas da versão final, o hospedeiro tinha de 650 a 800~~Com os contêineres no ar, restavam 922 MB de memória livre ~~; a campanha de~~ no computador quando os blocos foram escolhidos; no início de cada célula da campanha de tempo, a memória ~~do bloco padrão foi interrompida depois de 8 das suas 18 execuções, por falta de memória no hospedeiro, e retomada a partir delas~~livre ficou entre 594 e 905 MB.

Tabela 13 – Imagens Docker dos SGBDs utilizadas na avaliação.

SGBD	**Imagem Docker**
PostgreSQL	`postgres:16-alpine`
Redis	`redis:7-alpine`
MongoDB	`mongo:7`
Cassandra	`cassandra:4.1`
Neo4j	`neo4j:5-community`

Fonte: Elaborado pelo autor (2026), a partir de `docker-compose.yml`.

~~As campanhas da versão final gravam a carga~~ A carga gravada é a do cenário exemplo completo ~~, inclusive a coleção `orders` do MongoDB, dividida por estado~~ (seção ~~4.2.1.3~~)~~: em cem mil linhas, são 38.833 documentos a mais do que nas campanhas históricas, que não tinham essa coleção. Por isso, os totais das duas épocas não são comparados como se a carga fosse a mesma. Nas campanhas históricas, a estratégia ingênua — a implementação original da ferramenta , do TCC1 (seção 4.5.1)— serve de linha de base e foi medida apenas no ponto $N = 10\,000$, com materialização~~4.3.2). Para entender por que alguns SGBDs levam mais tempo para

gravar, convém lembrar o que cada um recebe, resumido na Tabela 14: o Cassandra grava os eventos das quatro fontes, enquanto o Redis, por exemplo, grava apenas as seleções e os carrinhos.

Tabela 14 – O que cada SGBD grava no cenário exemplo, e de quais fontes.

SGBD	Entidades gravadas	Fontes
PostgreSQL	tabelas `categories`, `products`, `inventory`	`stock`
	tabela `orders`	`purchase`
MongoDB	coleção `product_catalog`	`stock`
	coleções `orders_state_*` (uma por estado)	`purchase`
Cassandra	tabela `user_activity_log`	as quatro fontes
Redis	chaves `shopping_cart`	`add_to_cart`
	chaves `user_session`	`select_product`
Neo4j	nós `Product`	`stock`
	nós `User` e arestas `PURCHASED`	`purchase`

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/import_config.json`.

A ferramenta foi medida sem as opções `--chunk-size` e `--batch-size`: o bloco de leitura é o da escolha automática, que varia com o volume e o modo (Tabela 22), e o lote de gravação é o padrão de 2.048 linhas.

5.3 RESULTADOS

Exceto a seção 5.3.3, que percorre os seis volumes medidos, as seções a seguir apresentam os resultados do maior volume, $N = 262.144$ linhas.

5.3.1 ~~Decomposição~~ Custo por Fase e ~~Escrita~~ por SGBD (QP1)

A Tabela ~~??~~ ~~decompõe~~ 15 divide o tempo de uma importação de ~~$N = 100\,000$ linhas nas~~ 262.144 linhas entre as suas fases, nos dois modos~~, com o bloco padrão de 8 MB~~. A escrita nos bancos domina o custo~~, respondendo por $78{,}7\%$~~ : no modo multifonte, ela responde por $79{,}8\%$ do tempo total~~no modo multifonte;~~ , e as leituras de inferência e de validação, juntas, ~~respondem pelos $21{,}3\%$~~ pelos $20{,}2\%$ restantes.

Tabela 15 – Tempo por fase de uma importação ($N = 100\,000$, bloco de 8 MB$N = 262.144$), em segundos. Campanha sem instrumentação de memóriatempo.

Fase	Multifonte	Participação	Combinado
Inferência	31,27	6,3%	35,52
Validação	68,18	13,8%	72,08
Escrita no PostgreSQL	32,57	6,6%	30,44
Escrita no MongoDB	21,42	4,3%	22,98
Escrita no Cassandra	270,51	54,9%	269,79
Escrita no Redis	13,95	2,8%	30,39
Escrita no Neo4j	55,25	11,2%	64,97
Total	493,15	100%	526,17

Fonte: Elaborado pelo autor (2026), a partir de da pasta `benchmarks/v3/timings/`.

Como a escrita concentra o custo, convém abri-la por SGBD. A Tabela 16 e a Figura **??** apresentamapresenta, para a importação multifonte, o número de linhas processadas pela escrita que a escrita processa em cada SGBD, o tempo de escrita e o a vazão (*throughput*) resultante, em linhas processadas por segundo, em cada um dos cinco bancos. As linhas processadas são as enviadas a cada SGBD antes da eliminação de duplicatas (seção 4.3.4); no PostgreSQL e no Neo4j, as linhas com chave repetida não geram registros novos. . Os valores variam por uma ordem de grandeza: o Redis processa cerca de 9.118 linhas /s9.310 linhas por segundo, enquanto o Cassandra fica em 901 linhas/s969.

Tabela 16 – Escrita por SGBD em uma importação ($N = 100\,000$, multifonte , bloco de 8 MB$N = 262.144$): linhas processadaspela escrita, antes da eliminação de duplicatas. Campanha sem instrumentação de memóriatempo.

SGBD	Linhas processadas	Tempo (s)	Linhas/s
Cassandra	262.144	270,51	969
Neo4j	234.027	55,25	4.236
PostgreSQL	193.096	32,57	5.928
MongoDB	132.230	21,42	6.173
Redis	129.914	13,95	9.310

Fonte: Elaborado pelo autor (2026), a partir de da pasta `benchmarks/v3/timings/`.

Throughput de escrita por SGBD ($N = 100\,000$, multifonte, bloco de 8 MB).

Campanha sem instrumentação de memória. Fonte: Elaborado pelo autor (2026), a partir de `benchmarks/v3/timings/`.

O Cassandra sozinho responde por 110,96 s dos 164,84 s 68,7% da fase de escrita — cerca de 67% — e por 53% e por 54,9% da importação inteira. Qualquer afirmação sobre "o tempo de escrita" é, portanto, em larga medida uma afirmação sobre o Cassandra neste ambiente, Parte dessa diferença vem da carga: como mostra a Tabela 14, o que reforça a necessidade de abrir a fase por SGBD em vez de tratá-la como um bloco único. Cassandra grava os eventos das quatro fontes — todas as 262.144 linhas —, enquanto o Redis grava apenas as seleções e os carrinhos. A outra parte vem do ambiente em que o Cassandra roda (seção 5.2), discutido na seção 5.4.

As linhas processadas também diferem entre os SGBDs, porque cada um recebeas entidades do seu mapeamento: o MongoDBnão correspondem todas a registros novos, porque os dados do cenário são redundantes. A Tabela 16 conta as linhas que cada SGBD recebe; a eliminação de duplicatas vem depois. No arquivo de estoque, por exemplo, grava o catálogo de produtos e os pedidos, e o Cassandra, os eventos das quatro fontes. Nem todas viram registros: no PostgreSQL, as 73.660 linhas processadas resultam em 62.167 linhas guardadas, pois a 8.ª e a 11.ª linha de dados descrevem produtos diferentes (`Product8` e `Product11`, mas ambas trazem a mesma categoria (`category_id` 9, `Categoria9`): a tabela `categories` recebe uma linha por produto do estoque, mas guarda do PostgreSQL recebe as duas linhas e guarda uma sóas 116 categorias distintas; . Em 262.144 linhas, as 30.433 linhas de estoque citam apenas 304 categorias distintas, e, no Neo4j, as 89.275 linhas resultam em 51.602 101.797 compras foram feitas por apenas 3.043 compradores distintos, que viram 3.043 nós e arestas, pois os 38.833 compradores das compras são apenas 1.160 usuários distintos`User`.

5.3.2 Modos de Importação: Multifonte *versus* Combinado (QP2)

Os dois modos de importação — um CSV por tipo de evento ou um único CSV combinado — gravam os mesmos dados. A Tabela 17 compara-os no ponto de 100 000 linhas quanto ao tamanho dos arquivos, ao bloco de leitura escolhido, às leituras de inferência e de validação, ao tempo total e ao pico de memória.

Tabela 17 – Multifonte *versus* combinado (~~$N = 100\,000$, bloco de 8 MB~~$N = 262.144$). Tempos ~~e~~ da campanha de tempo; picos da campanha de memória~~provêm de campanhas distintas, conforme indicado~~.

Critério	**Multifonte**	**Combinado**
Tamanho dos arquivos (MB)	63,26 (4 arquivos)	75,92
Colunas por arquivo	20, 33, 6 e 7*	39
Células vazias	0%	44%
Bloco de leitura (MB)	63	38
Inferência (s)	31,27	35,52
Validação (s)	68,18	72,08
Tempo total (s)	493,15	526,17
Pico de memória (MB)	253,8	141,9

*Na ordem `stock`, `purchase`, `select_product` e `add_to_cart`.

Fonte: Elaborado pelo autor (2026). Tamanho, colunas e células vazias ~~de `data/benchmark/generated/100000/`; tempos de~~ dos arquivos gerados; tempos da pasta ~~`benchmarks/v3/`~~`timings`~~`/`~~; memória ~~de~~ da pasta ~~`benchmarks/v3/`~~`memory`~~`/`~~. Tamanho em MB de 10^6 bytes; memória em MB de 2^{20} bytes (MiB).

O arquivo combinado é ~~cerca de~~ 20% **maior**, porque todos os tipos de evento partilham um único cabeçalho de 39 colunas e cada linha preenche apenas as do seu tipo: ~~45%~~ 44% das células ~~de dados~~ do arquivo ficam vazias, contra nenhuma nos arquivos do modo multifonte. ~~Por isso, e porque a ferramenta separa o arquivo combinado por tipo de evento durante a leitura, as leituras de inferência e~~ A leitura de inferência, que percorre o arquivo inteiro, leva 14% mais tempo no combinado, e a de validação~~do combinado levam cerca de 26% maistempo~~, 6% mais. A escrita também fica mais lenta ~~, porque,~~ onde o SGBD lê pouco do arquivo: na gravação, cada SGBD relê as fontes de que precisa (seção 4.3)~~: no~~ . No modo multifonte, o Redis ~~, por exemplo,~~ relê apenas os arquivos de seleções e de carrinhos (~~cerca de 5,7~~$15{,}30$ MB), enquanto no combinado ~~todo SGBD~~ relê o arquivo inteiro (~~$28{,}55$~~$75{,}92$ MB) — ~~a escrita no Redis passa de $5{,}44$ para $12{,}61$ s(Tabela **??**)~~e a sua escrita passa de $13{,}95$ para $30{,}39$ s. No total, a importação combinada leva ~~13% mais tempo, diferença bem maior que a variação de $2{,}7\%$ observada entre campanhas.~~ 7% mais tempo.

O pico de memória~~do combinado, por outro lado~~, ao contrário, é ~~menor ($54{,}6$ contra $66{,}1$~~**menor** no combinado ($141{,}9$ contra $253{,}8$ MB)~~; a causa dessa diferença~~ , e a causa é o bloco, não ~~foi isolada neste trabalho~~o modo. Nesse volume, a memória livre limitou o bloco nos dois modos, e mais no combinado: como a base do pico previsto cresce com o tamanho dos arquivos, e o arquivo combinado é maior, sobrou

menos para o bloco (38 contra 63 MB). A comparação de tempo entre os modos inclui, portanto, o efeito de blocos diferentes: no multifonte, só a maior fonte, `purchase`, foi lida em mais de um bloco (quatro), enquanto o arquivo combinado foi lido em cerca de quinze.

Além do desempenho, o modo multifonte tem vantagens de **organização**. Cada arquivo traz apenas as colunas do seu tipo de evento, o que o torna mais fácil de ler, de validar e de produzir: cada um pode vir de um sistema diferente e ser atualizado independentemente dos demais. A opção `--source` (seção 4.1) substitui uma fonte isolada — por exemplo, apenas as compras —, enquanto no modo combinado só o arquivo inteiro pode ser substituído. A vantagem do modo combinado é a simplicidade de um único arquivo, formato natural quando a origem dos dados já é um registro único de ~~eventos. Em síntese, o modo multifonte é mais rápido e mais fácil de organizar; o combinado ocupa menos memória neste volume.~~ vários tipos de eventos.

5.3.3 Escalabilidade (QP3)

A Tabela 18 mostra o tempo total, o tempo por linha e o pico de memória nos ~~três~~ seis volumes, nos dois modos~~, com o bloco padrão. De mil para cem mil linhas ($100\times$ mais dados), o tempo total cresce $32\times$ no modo multifonte e $41\times$ no combinado; de dez mil para cem mil ($10\times$), cresce $9{,}2\times$ e $8{,}7\times$, quase em proporção ao volume. Em mil linhas,~~ . O bloco de leitura de cada célula é o da Tabela 22.

Tabela 18 – Tempo total, tempo por linha e pico de memória por volume. Tempos da campanha de tempo; picos da campanha de memória.

	Multifonte			Combinado		
Linhas	**Tempo (s)**	**ms/linha**	**Pico (MB)**	**Tempo (s)**	**ms/linha**	**Pico (MB)**
1.024	11,55	11,28	10,5	8,94	8,73	10,8
16.384	40,63	2,48	58,4	38,33	2,34	72,9
32.768	65,84	2,01	74,8	69,86	2,13	99,2
65.536	124,58	1,90	98,5	127,16	1,94	144,9
131.072	229,95	1,75	195,4	270,93	2,07	209,3
262.144	493,15	1,88	253,8	526,17	2,01	141,9

Fonte: Elaborado pelo autor (2026). Tempos da pasta `timings`; picos da pasta `memory`.

O **tempo cresce linearmente com o volume**. A partir de 16.384 linhas, cada linha custa entre 1,8 e 2,5 ms, sem tendência de alta: o tempo por linha de 262.144 linhas é até menor que o de 16.384. Em 1.024 linhas, o tempo por linha é bem maior

(de 8,7 a 11,3 ms) porque os custos fixos de cada execução ~~(conexões, preparo dos SGBDs~~ — conexão aos cinco SGBDs, preparo das estruturas de destino e leitura dos cabeçalhos ~~) pesam mais~~ — pesam mais que os dados. Para medir o crescimento sem esse efeito, ajustou-se uma reta aos pontos de 16.384 linhas em diante, em escala logarítmica ($\log t = a + b \log N$): o expoente b indica como o tempo cresce — $b = 1$ significa crescimento proporcional ao volume, $b = 2$, ~~o que explica o crescimento menor que o do volume no primeiro intervalo.~~ quadrático. O expoente obtido é $b = 0{,}90$ no modo multifonte e $b = 0{,}95$ no combinado, ambos próximos de 1. Ficar um pouco abaixo de 1 é efeito dos custos fixos, que ainda pesam em 16.384 linhas: descontando de cada volume o tempo total da importação de 1.024 linhas, que é quase só custo fixo, o expoente passa a $1{,}01$ no multifonte e $1{,}04$ no combinado — o crescimento proporcional ao volume que se espera de uma importação que percorre os dados um número fixo de vezes. A Figura 18 mostra o mesmo resultado: em escala logarítmica nos dois eixos, os pontos dos dois modos acompanham a reta de crescimento linear.

~~Tempo total e pico de memória por volume (bloco de 8 MB). Tempos e picos provêm de campanhas distintas, conforme indicado.~~

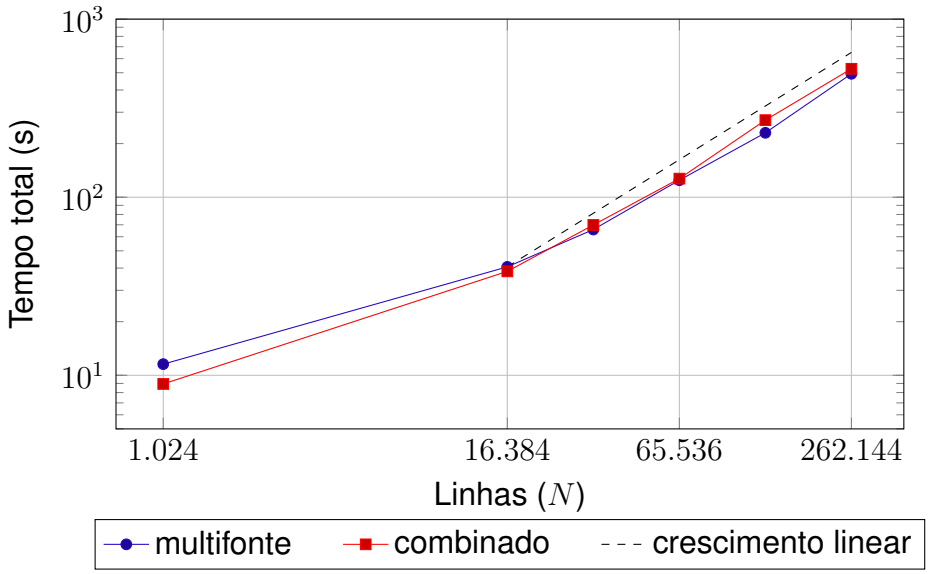


Figura 18 – Tempo total de importação em função do volume, em escala logarítmica nos dois eixos. A reta tracejada representa o crescimento linear (tempo proporcional ao volume) a partir do ponto de 16.384 linhas do modo multifonte. Campanha de tempo.

Fonte: Elaborado pelo autor (2026). ~~Tempos de `benchmarks/v3/timings/`; picos de `benchmarks/v3/memory/`.~~ a partir da pasta `timings`.

O ~~pico de memória cresce bem menos que o volume: $6{,}4\times$~~ **pico de memória acompanha o bloco de leitura, e não o volume**. Enquanto o bloco lê a maior fonte inteira, o pico cresce com os dados, mas menos que eles: no modo multifonte~~e $5{,}3\times$ no combinado,~~ , de 16.384 para 131.072 linhas (8 vezes mais dados), o pico passa de

58,4 para 100× mais linhas . No modo multifonte, até dez mil linhascada arquivo cabe em um único bloco de 8 MB 195,4 MB (3,3 vezes). Quando a memória livre passa a limitar o bloco, o pico deixa de acompanhar o volume. No multifonte, de modo que o bloco é o próprio arquivo de 131.072 para 262.144 linhas, o bloco cai de 97 para 63 MB e o pico cresce apenas 30%, para 253,8 MB. No combinado, o bloco cai de 116 para 38 MB e o pico cresce com ele. Em cem mil linhas , os arquivos maiores passam a ocupar vários blocos, e **diminui**, de 209,3 para 141,9 MB, embora o volume dobre. De 1.024 para 262.144 linhas (256 vezes mais dados), o pico cresce apenas 1,65× 24 vezes no multifonte e 1,24× no combinadoem relação a dez mil linhas. Além do bloco , a 13 vezes no combinado.

Como o bloco muda de uma célula para outra, esses picos não medem o crescimento da memória guarda os agregados da leitura de inferência e os com o volume sob um bloco fixo, e por isso não se ajustou um expoente a eles. Mesmo com o bloco limitado, o pico não fica constante: a base cresce com os dados, por causa dos conjuntos de chaves referenciadas da leitura de distintas que a validação , que crescem com o número de chaves distintas e a escrita no Neo4j guardam (seção 4.5.2). O efeito do tamanho do bloco sobre o pico, isolado em um volume fixo, é o objeto da QP5.

5.3.4 Custo da Validação Prévia e Tamanho do Bloco (QP7QP4)

As leituras de inferência e de validação são o preço de conferir os dados antes de gravar. A Tabela 19 mostra a fração do tempo total que elas ocupam, por volume e modo.

Tabela 19 – Fração do tempo total ocupada pelas leituras de inferência e de validação(bloco de 8 MB). Campanha sem instrumentação de memóriatempo.

Linhas	Multifonte	Combinado
1.024	28,9%	29,3%
16.384	19,3%	22,9%
32.768	19,1%	23,0%
65.536	17,9%	19,3%
131.072	17,9%	18,2%
262.144	20,2%	20,4%

Fonte: Elaborado pelo autor (2026), a partir de da pasta benchmarks/v3/timings/.

Em cem mil A partir de 16.384 linhas, a validação prévia custa cerca de um quinto entre 18% e 23% do tempo total; em mil 1.024 linhas, a fração é maior porque

a escrita, que domina nos volumes maiores, ainda é pequena. Em troca desse custo, nenhum dos problemas listados na seção 4.2.4 problema nos dados chega a uma gravação parcial: a importação termina antes de gravar qualquer dado .

O tamanho do bloco de leitura afeta as duas leituras. A Tabela **??**, na quando encontra um valor que não converte para o tipo da sua coluna, um valor que o tipo declarado no SGBD recusaria, uma chave vazia ou uma referência pendente — uma chave estrangeira do PostgreSQL ou uma aresta do Neo4j que aponta para uma chave inexistente (seção 4.5.2, mostra que 4.2.4).

5.3.5 Tamanhos do Bloco e do Lote (QP5)

Uma campanha exploratória mediu o efeito dos dois tamanhos em 131.072 linhas, em cem mil linhasno modo multifonte, os blocos de variando um de cada vez: blocos de leitura de 16, 32, 64, 128 e 256 MBreduzem o tempo total em 5,4% e 6,4%, à custa de dobrar ou mais o pico de memória (131,9 e 149,9 MB, contra 66,2 MB no bloco de 8 MB, com o lote fixo em 2.048 linhas, e lotes de gravação de 512, 1.024, 2.048, 4.096 e 8.192 linhas, com o bloco fixo em 128 MB. Como nas demais campanhas, o tempo é a mediana de três repetições sem o registro de alocações, e o pico vem de execuções com o registro (uma por célula). A redução concentra-se na inferência (de 15,69 para 10,95 e 9,74 s) e na validação (de 27,53 para 22,71 e 23,57 s), e é cerca de duas vezes a variação observada entre campanhas. O padrão de 8 MB é, portanto, uma escolha favorável à Nesse volume, a maior fonte, `purchase`, ocupa cerca de 95,5 MB na memória, que custa pouco em tempo : os blocos de 16 a 64 MB a leem em vários pedaços, e os de 128 e 256 MB, inteira. A Tabela 20 mostra o eixo do bloco.

5.3.6 Resultados Históricos: Estratégia de Escrita (QP4)

Esta subseção e as duas seguintes apresentam as medições históricas. Elas comparam a escrita ingênua e a materialização, que a versão final não oferece, sobre uma carga sem a coleção `orders`, e por isso não se comparam diretamente aos números das subseções anteriores.

Nessas medições, a ferramenta registrava três fases: a **leitura** do arquivo inteiro, o **mapeamento**, que convertia os tipos e montava os registros de cada SGBD,e a **escrita**. A Tabela **??** contrasta as duas estratégias de escrita no ponto $N = 10\,000$, com materialização. A estratégia em lote importa o mesmo conjunto de dados — as mesmas 27.494 linhas gravadas — entre 8,5 e 9,3 vezes mais rápido que a via ingênua. O ganho concentra-se, como esperado, nas duas fases que a estratégia em lote ataca: o mapeamento, acelerado cerca de 42× pela vetorização da conversão de tipos, e a escrita, acelerada 7,7× pela gravação em lote. A leitura, que a estratégia não altera, leva menos de dois segundos nas duas.

Tabela 20 – ~~Tempo total e das fases dominantes por estratégia~~ Efeito do tamanho do bloco de ~~escrita, em segundos~~ leitura ($~~N = 10\,000~~N = 131.072$, ~~materialização; medição histórica~~multifonte, lote de 2.048 linhas).~~Campanha sem instrumentação de memória.~~

Bloco (MB)	Tempo total (s)	Em relação ao melhor	Pico (MB)
16	275,08	$+10{,}9\%$	103,6
32	304,36	$+22{,}7\%$	127,9
64	282,19	$+13{,}8\%$	144,9
128	248,00	—	195,5
256	251,00	$+1{,}2\%$	195,5

Fonte: Elaborado pelo autor (2026)~~, a partir de~~ . Tempos de `benchmarks/~~timings-naive~~v4-explore/chunks-timings/`; picos de `benchmarks/v4-explore/chunks-memory/`.

~~Tempo total de importação por estratégia de escrita ($N = 10\,000$, materialização, medição histórica; eixo vertical em escala logarítmica). Campanha sem instrumentação de memória. Fonte: Elaborado pelo autor (2026), a partir de `benchmarks/timings-naive/`.~~

~~A estratégia ingênua cumpre aqui o seu papel exclusivamente metodológico: a linha de base que dá sentido ao número "$9{,}3\times$". A versão final da ferramenta grava sempre em lote.~~

5.3.6 ~~Resultados Históricos: Materialização *versus* Leitura em Blocos (QP5 e QP6)~~

~~O resultado histórico central está no contraste entre a materialização e a leitura em blocos, medido quando a ferramenta oferecia os dois modelos de~~ As medianas misturam repetições feitas em momentos diferentes, e o ambiente variou entre elas: na terceira passada pela matriz, todas as células ficaram mais lentas, e uma execução ~~. A Tabela **??** e a Figura **??** mostram o~~ chegou a 471 s. A comparação mais justa é, portanto, dentro de uma mesma passada. Nas duas primeiras, cada bloco de 16 a 64 MB foi mais lento que cada um dos dois blocos que leem a fonte inteira; em média, os blocos menores levaram 14% a mais na primeira passada e 21% a mais na segunda. O pico de memória ~~dos dois modelos em função do tamanho do arquivo, no modo multifonte. A materialização cresce **linearmente** com o volume: de $10{,}5$ MBem mil linhas para $950{,}7$ MBem cem mil — praticamente $90\times$ mais~~ cresce com o bloco até que ele contenha a maior fonte inteira e, a partir daí, para de crescer: é o mesmo, 195,5 MB, com 128 e com 256 MB. Ler a maior fonte de uma vez é, assim, o que torna

a importação mais rápida, e um bloco maior que ela só ocupa memóriapara $100\times$ mais dados. A leitura em blocos.

O lote de gravação, ao contrário, **achata**: de $10{,}7$ MB para $75{,}9$ MB no mesmo intervalo. Em cem mil linhas, ela usa $12{,}5\times$ **menos memória** que a materialização, e a vantagem cresce com o tamanho do arquivo. Esse achatamento é a evidência empírica que responde à QP6: o pico da leitura em blocos é governado sobretudo pelo tamanho do bloco, e não pelo do arquivo, como prevê o seu projeto (seção 4.5.2)teve efeito mensurável, como mostra a Tabela 21. As medianas ficaram a até $8{,}5\%$ da melhor, e o pico de memória quase não variou.

Tabela 21 – Pico Efeito do tamanho do lote de memória por modelo de execução gravação (N crescente$N = 131.072$, multifonte, estratégia em lote; medição histórica), em bloco de 128 MB).Campanha com instrumentação de memória.

Lote (linhas)	Tempo total (s)	Em relação ao melhor	Pico (MB)
512	211,97	$+8{,}5\%$	200,4
1.024	206,57	$+5{,}8\%$	197,0
2.048	195,34	—	195,5
4.096	208,00	$+6{,}5\%$	195,6
8.192	202,80	$+3{,}8\%$	197,1

Fonte: Elaborado pelo autor (2026), a partir de . Tempos de `benchmarks/v4-explore/batches-timings/`(raiz); picos de `benchmarks/v4-explore/batches-memory/`.

Pico de memória por modelo de execução em função do volume (multifonte, escala logarítmica, medição histórica): a materialização cresce com o arquivo; a leitura em blocos achata. Fonte: Elaborado pelo autor (2026), a partir de `benchmarks/` (raiz).O lote de 2.048 linhas foi o mais rápido em duas das três passadas, por margens de $2{,}5\%$ e $7{,}0\%$, e o de 8.192 linhas, na terceira. Essas margens são da mesma ordem da variação de uma mesma célula entre passadas, que foi de $3{,}5\%$ a 24% nessa campanha. Nenhum lote mostrou, portanto, vantagem acima do ruído da medição.

Essa economia de memória tinha um custo em tempo, mas modesto e **decrescente**. A Tabela **??** e a Figura **??** mostram que o sobrecusto de tempo da leitura em blocos caía de $+61\%$ em mil linhaspara apenas $+10\%$ em cem mil. A razão Desses resultados sai a **escolha automática** dos dois tamanhos, descrita na seção 4.5.2. O lote fica fixo em 2.048 linhas, o melhor nas medianas e o do meio do intervalo permitido. O bloco é que, à medida que o volume cresce, o que lê a maior fonte inteira, a menos que a escrita nos bancos — comum aos dois modelos

— passa a dominar o tempo total,diluindo o custo fixo do processamento entrelaçado da leitura em blocos. Ou seja: **quanto maior o arquivo, mais barata fica a troca** — a vantagem de memória cresce justamente onde o custo de tempo encolhe. Foi esse resultado que justificou manter a leitura em blocos como livre do computador não comporte o pico previsto; nesse caso, é o maior bloco que cabe. Para prever o pico, a campanha exploratória e a campanha de escalabilidade forneceram um modelo simples: o pico cresce cerca de 1,08 MB por MB de bloco e tem uma base que cresce com o tamanho dos arquivos em disco. O pico previsto deve caber em 25% da memória livre lida no início da execução.

A Tabela 22 mostra o bloco que a regra escolheu para cada volume na campanha deste capítulo, com 922 MB livres no início. Até 131.072 linhas no modo multifonte, o bloco lê a maior fonte inteira; nos volumes maiores, sobretudo no modo combinado, cujo único modelo da versão finalarquivo contém todas as linhas, a memória livre passa a limitar o bloco.

Tabela 22 – Tempo total por modelo Bloco de execução (N crescenteleitura escolhido pela regra automática na campanha final, multifonte, estratégia em lote; medição histórica)MB, em segundos. Campanha sem instrumentação com cerca de 920 MB de memória livre.

Volume (N)	Multifonte	Combinado
1.024	16	16
16.384	16	35
32.768	24	71
65.536	48	141
131.072	97	116*
262.144	63*	38*

* Limitado pela memória livre; nos demais, o bloco lê a maior fonte inteira (16 MB é o mínimo).
Fonte: Elaborado pelo autor (2026), a partir de dos metadados de `benchmarks/v4/timings/`.

Tempo total por modelo de execução em função do volume (multifonte, medição histórica): o sobrecusto da leitura em blocos encolhe de $+61\%$ para $+10\%$ à medida que a escrita passa a dominar. Fonte: Elaborado pelo autor (2026) , a partir de `benchmarks/timings/`.

5.3.6 Uma Observação sobre o Pico de Memória da Estratégia em Lote

Um ponto das medições históricas exige cuidado na leitura das medidas de Os picos medidos nessa campanha (Tabela 18) permitem conferir o modelo nas três

células em que a memória . No mesmo ponto de $10\,000$ linhas e com materialização, a estratégia **ingênua** exibia um pico **menor** que a estratégia em lote — $14{,}4$ MB contra $95{,}4$ MB no modo multifonte (Tabela **??**). limitou o bloco. O número não é um erro, e reproduziu-se entre campanhas. A explicação está na natureza da estratégia em lote: para gravar em lotes, ela **acumula registros em memória** antes de despachá-los. No Neo4j, em particular, a gravação de relacionamentos por `UNWIND` montava a lista completa de arestas de uma entidade em memória antes de submetê-la, ao passo que a via ingênua percorria as arestas uma a uma, sem acumular. A escrita em lote, portanto, **troca memória por vazão**: ela é $7{,}7\times$ mais rápida (Tabela **??**), mas ao preço de um pico de memória maior.

Pico de memória por estratégia de escrita ($N = 10\,000$, materialização; medição histórica), em MB. Campanha com instrumentação de memória. Fonte: Elaborado pelo autor (2026), a partir de `benchmarks/naive/`orçamento era de $230{,}5$ MB (25% de 922 MB). No multifonte de 262.144 linhas, o pico medido foi de $253{,}8$ MB: 10% acima do orçamento. No combinado, o modelo errou para o outro lado: os picos medidos foram de $209{,}3$ MB em 131.072 linhas e de $141{,}9$ MB em 262.144, este 38% abaixo do orçamento. O modelo foi ajustado apenas no modo multifonte; no combinado, ele superestima o pico, e a regra escolhe um bloco menor que o necessário, o que custa tempo sem necessidade. A margem de 25% absorveu o erro no multifonte, mas a regra pede um ajuste próprio para o modo combinado.

Vale notar que esse acúmulo é justamente o que a **leitura em blocos** limita: ao processar o arquivo em blocos, ela mantém em memória apenas um bloco e os lotes ainda não descarregados — e é por isso que ela, mesmo gravando em lote, atinge picos muito menores que a materialização (Tabela **??**). Os dois eixos, portanto, atuam sobre a memória de formas complementares.

5.4 ANÁLISE E DISCUSSÃO

Os resultados respondem às sete questões de pesquisa. A escrita nos bancos é a fase dominante de uma importação (QP1): cerca de 79% 80% do tempo em cem mil 262.144 linhas no modo multifonte, com *throughput* vazão que varia por uma ordem de grandeza entre SGBDs. Essa dispersão reflete o modelo de dados de cada banco a quantidade de dados que cada SGBD recebe e a forma de gravação idiomática correspondente — do seu modelo de dados: o Redis, orientado a inserções simples de pares chave-valor, lidera; o Neo4j, que grava nós e arestas com `MERGE` e verificação de unicidade, e o Cassandra, que recebe todos os eventos, ficam atrás. A lentidão do Cassandra , que opera em um único nó, sem replicação, reflete reflete também, ao menos em parte, o ambiente limitado em que ele roda: um único nó, sem replicação, com *heap* de 1 GB (seção 5.2). Trata-se de uma manifestação, na etapa de importação,

das mesmas diferenças de paradigma que a literatura observa na etapa de consulta (MUNISWAMAIAH; AGERWALA; TAPPERT, 2023; LANDUYT et al., 2023).

No modo combinado, a importação leva ~~13%~~ 7% mais tempo que no multifonte: ~~as leituras de inferência e de validação percorrem um arquivo maior e com 45%~~ o arquivo é maior, com 44% de células vazias, e, na gravação, cada SGBD relê o arquivo inteiro; o multifonte tem ainda vantagens de organização (QP2). ~~Quanto à escalabilidade~~ A ferramenta **escala linearmente** com o volume de dados nos volumes medidos (QP3)~~, o tempo cresce quase em proporção ao volume~~ : a partir de ~~dez mil linhas, governado pela fase de escrita, enquanto o~~ 16.384 linhas, o tempo por linha fica estável, e o expoente do crescimento é próximo de 1 nos dois modos. O pico de memória ~~cresce muito~~ acompanha o bloco de leitura: cresce menos que o volume enquanto o bloco lê a maior fonte inteira e é contido quando a memória livre limita o bloco, chegando a 253,8 MB no multifonte em 262.144 linhas. A validação prévia dos dados custa ~~cerca de um quinto do tempo em cem mil linhas (QP7),~~ entre 18% e ~~blocos de leitura maiores reduzem esse custo pouco, à custa de dobrar o pico de memória.~~

~~As medições históricas sustentam as duas decisões de projeto que levaram à versão final. A estratégia em lote acelerava a importação em cerca de 9× (QP4), pela vetorização 23% do tempo~~ da ~~conversão de tipos e pela escrita em lote. A leitura em blocos reduzia o pico de memória em 12,5× em cem mil linhas (QP5), a um custo de tempo de apenas +10% nesse ponto, e o achatamento do pico com o volume (QP6) mostra que ela importa com um pico que acompanha o bloco, e~~ importação (QP4). Ler a maior fonte de uma só vez é o que torna a importação mais rápida, e o tamanho do lote não ~~o arquivo. É esse resultado que sustenta a principal afirmação de projeto da ferramenta: a de importar arquivos maiores que a memória disponível, algo impossível com a materialização, desde que os conjuntos de chaves distintas que a validação e a escrita no Neo4j guardam (seção 4.5.2)caibam nela. Essa possibilidade decorre do projeto e não foi medida neste trabalho, cujo maior volume tem cem mil linhas.~~ tem efeito mensurável; daí sai a escolha automática dos dois tamanhos (QP5), cujo modelo de pico se mostrou conservador demais no modo combinado.

5.4.1 Ameaças à Validade

~~Os resultados devem ser lidos~~ Os resultados devem ser lidos à luz de algumas limitações. Quanto à **~~validade de construção~~**~~, a variação de tempo entre campanhas da versão final foi medida em uma~~ **validade de construção**, tempo e memória vêm de campanhas separadas, pelo motivo explicado na seção 5.1.2: o registro de alocações, necessário para medir a memória, deixa a importação mais lenta e distorce as fases umas em relação às outras, de modo que os tempos só ~~célula (2,7%), e diferenças de poucos por cento~~ são ~~lidas com cautela; nas medições históricas, a incerteza~~

de tempo confiáveis em execuções sem ele. A contrapartida é da ordem de 20% que tempo e pico de uma mesma célula vêm de execuções diferentes, embora de carga idêntica e com o mesmo bloco. Os arquivos de resultado guardam apenas a mediana de cada célula, de modo que a variação entre as três repetições não pode ser reportada; na campanha exploratória, a mesma célula variou de 3,5% a 24% entre passadas (seção 5.1.2). O pico de 5.3.5), e diferenças dessa ordem entre células não devem ser lidas como efeito. Além disso, o computador trabalhou com pouca memória é muito mais estável. A separação em campanhas pareadas para tempo e memória evita a distorção que a instrumentação de memória introduz nas fases, mas impede a leitura das duas métricas de livre (922 MB com os contêineres no ar), e a campanha de tempo não correu de uma mesma execução. As medições históricas e as da versão final usam cargas diferentes (a coleção `orders` só existe nas da versão final) e vez: foi pausada pelo autor depois de 11 das 36 execuções, quase toda a primeira passada, e retomada cerca de sete horas depois, com o Docker reiniciado, sem repetir as execuções já medidas. As medianas de tempo misturam, portanto, execuções de antes e de depois da reinicialização. Os blocos não são comparadas diretamentemudaram: foram escolhidos uma vez, antes da pausa. Por depender da memória livre no momento, a escolha do bloco, e com ela o tempo e o pico dos volumes maiores, seria outra em um computador com mais memória livre.

Quanto à **validade externa**, todos os experimentos correram em uma única máquinaum único computador, sob Windows, com os cinco SGBDs em contêineres partilhando 8 GB de memória física, dos quais restavam de 650 a 800 MB livres durante as campanhas da versão final. Esse ambiente não representa uma implantação de produção, com bancos dedicados e ajustados. O caso mais sensível é o do Cassandra, cujo *throughput* de escrita (901 linhas/s) reflete um nó único com *heap* de 1 GB em uma máquina virtual apertada — uma restrição de **ambiente**, não uma propriedade intrínseca do SGBD; um Cassandra provisionado adequadamente reduziria substancialmente a sua parcela na fase de escrita. Quanto à **validade interna**, o gerador determinístico e a limpeza dos bancos antes de cada repetição execução isolam o efeito medido, mas o volume avaliado (até cem mil 262.144 linhas) é moderado: em cem mil linhas, o bloco de 256 MB já lê cada fonte inteira, e o efeito de blocos grandes sobre arquivos muito maiores , e não foi medido. Também não se explorou o efeito de caches *caches* quentes nem de execuções concorrentes. Aprofundar o caminho de escrita do Cassandra e estender o estudo a volumes maiores figuram entre as atividades futuras (Capítulo **??**).

6 ATIVIDADES FUTURAS

Concluídas a implementação da ferramenta e a sua avaliação de desempenho, esta seçãoreúne as atividades que dão continuidade ao trabalho. Elas dividem-se entre a ampliação da forma de uso, o aprofundamento da avaliação e a extensão das funcionalidades de importação 6.1).

- **Edição assistida da configuração na interface gráfica.** A interface gráfica entregue (Seção 4.6)monta e executa o comando de importação, mas não edita os dois arquivos JSON de configuração, que permanecem sob um editor de texto externo. A extensão natural é trazer essa edição para dentro da interface, com validação por *JSON Schema* durante a digitação, pré-visualização do CSV de origem e um editor de mapeamento coluna a coluna, reduzindo ainda mais a barreira de entrada para usuários menos familiarizados com a linha de comando.

- **Aprofundamento da avaliação de desempenho.** A avaliação do Capítulo 5 cobriu volumes de até cem mil linhas em uma única máquina, com os cinco SGBDs em contêineres partilhando os mesmos recursos. Três extensões se destacam: medir volumes maiores, na ordem de milhões de linhas; aprofundar o caminho de escrita do Cassandra — a fase dominante do custo — para além da concorrência já empregada pela estratégia em lote (Seção 4.5.1); e repetir os experimentos em um ambiente com SGBDs dedicados e ajustados, isolando o desempenho da ferramenta das restrições do ambiente de contêineres.

- **Suporte a outros formatos de entrada.** Aceitar arquivos TSV e planilhas Excel, além de CSV, reaproveitando o mesmo mapeamento declarativo já existente.

- **Operadores de filtro adicionais e políticas de coerção configuráveis.** Ampliar o vocabulário de seleção de linhas e permitir que o usuário defina como valores ambíguos ou malformados são convertidos aos tipos nativos de cada SGBD.

- **Testes de integração em ambiente conteinerizado.** A suíte de testes atual é majoritariamente unitária; prevê-se automatizar testes de integração contra os cinco SGBDs em `docker compose`, dentro de um fluxo de integração contínua (CI).

- **Generalização do núcleo de importação.** Estender a arquitetura de portas e adaptadores (Seção 4.5.2) a novos destinos — sistemas de mensageria, *data*

~~*lakes* e outros SGBDs —, reaproveitando o orquestrador agnóstico de destino sem duplicar a lógica de importação.~~

6 ~~CONSIDERAÇÕES FINAIS~~CONCLUSÃO

Este trabalho apresentou a *PolyglotImportCSV*, uma ferramenta de importação declarativa que grava um mesmo conjunto de dados em formato CSV em cinco SGBDs de paradigmas distintos — PostgreSQL, MongoDB, Cassandra, Redis e Neo4j — a partir de dois arquivos de configuração validados estaticamente. Partindo da fundamentação sobre persistência poliglota e do estado da arte em importação e modelagem de dados heterogêneos, o trabalho evoluiu da proposta a uma implementação funcional, avaliada empiricamente.

As principais contribuições são: (i) um formato de configuração JSON, separado em mapeamento e conexão, com dois modos de entrada — um arquivo por entidade (multifonte) e um único CSV combinado; (ii) três etapas de validação, que conferem os dois arquivos, a consistência entre eles e os próprios dados, com o mesmo código da gravação, antes de qualquer escrita; (iii) o mapeamento declarativo de colunas com conversão nativa aos tipos de cada SGBD; (iv) uma camada de observabilidade e um subsistema de métricas que instrumentam cada fase da importação; (v) dois recursos de desempenho — a estratégia de escrita em lote, com conversão vetorizada e gravação em lotes, e a leitura dos arquivos em blocos, de memória limitada, com ~~tamanhos de bloco e de lote configuráveis~~o tamanho do bloco escolhido automaticamente e ajustável pela linha de comando; e (vi) uma avaliação empírica com dados sintéticos, gerados de forma determinística, que quantifica o custo de importar para os cinco paradigmas, a escalabilidade da ferramenta com o volume de dados e o custo da validação prévia.

A avaliação (Capítulo 5) ~~confirmou~~ confirma os objetivos traçados. Em ~~cem mil~~ 262.144 linhas, a escrita nos bancos responde por cerca de ~~quatro quintos~~ 80% do tempo de uma importação, e a validação prévia dos dados, ~~pelo quinto restante~~por cerca de 20%; em troca, nenhum problema que ela detecta chega a uma gravação parcial. A ferramenta **mostrou-se escalável** nos volumes analisados: de 16.384 a 262.144 linhas, o tempo cresce linearmente com o volume — o tempo por linha fica estável, entre $1{,}8$ e $2{,}5$ ms, e o expoente do crescimento é $0{,}90$ no modo multifonte e $0{,}95$ no combinado, próximo de 1. O pico de memória, por sua vez, acompanha o bloco de leitura, que a ferramenta escolhe sozinha: de 1.024 para 262.144 linhas (256 vezes mais dados), ele passa de $10{,}5$ para $253{,}8$ MB no modo multifonte, cerca de 24 vezes, e, quando a memória livre limita o bloco, deixa de acompanhar o volume. A regra de escolha do bloco saiu de uma campanha exploratória, que mostrou que ler a maior fonte de uma só vez torna a importação mais rápida e que o tamanho do lote de gravação

não tem efeito mensurável; no modo combinado, porém, o modelo que prevê o pico mostrou-se conservador demais. As medições ~~históricas mostraram~~ feitas com uma versão anterior da ferramenta (Seção 4.5.1) mostram que a estratégia em lote ~~acelerou~~ acelera a importação em cerca de nove vezes sobre a ~~linha de base ingênua~~ gravação linha a linha e que a leitura em blocos reduziu~~u~~o pico de memória em mais de doze vezes ~~no maior volume medido~~em cem mil linhas, em relação à carga do arquivo inteiro na memória~~— o que habilita, pelo projeto, a importação de arquivos maiores que a memória disponível, desde que os conjuntos de chaves distintas caibam nela~~. A equivalência das contagens entre os dois modos de importação, conferida por testes automatizados, permite tratar a escolha entre eles como uma questão de organização e de custo, não de correção.

As limitações reconhecidas dizem respeito sobretudo ao ambiente de avaliação: os experimentos correram em uma única máquina, com os cinco SGBDs em contêineres partilhando os mesmos recursos, o que ~~penalizou~~ penaliza em especial a escrita no Cassandra — uma restrição do ambiente, e não uma propriedade da ferramenta. A validação prévia, por sua vez, não cobre as falhas que só aparecem durante a gravação, como a queda de um SGBD no meio da carga, e a ferramenta não desfaz o que já foi gravado. Além disso, a suíte de testes permanece majoritariamente unitária, sem integração contínua contra os SGBDs conteinerizados.

~~Como trabalho futuro (Capítulo **??**) , destacam-se a edição assistida da~~ Consolida-se, assim, a *PolyglotImportCSV* como um artefato resultante de uma pesquisa na área de modelagem poliglota de dados. Uma vez aplicada uma metodologia para projeto poliglota de dados e definidos os modelos de dados alvo sobre os quais os dados devem ser persistidos, caso existam fontes de dados exportáveis em CSV, a *PolyglotImportCSV* é capaz de realizar a carga de dados dessas fontes respeitando o projeto poliglota realizado.

6.1 ATIVIDADES FUTURAS

As atividades que dão continuidade a este trabalho dividem-se entre a ampliação da forma de uso, o aprofundamento da avaliação e a extensão das funcionalidades de importação.

- **Edição assistida da configuração na interface gráfica.** A interface gráfica entregue (Seção 4.6) monta e executa o comando de importação, mas não edita os dois arquivos JSON de configuração, que permanecem sob um editor de texto externo. A extensão natural é trazer essa edição para dentro da interface~~gráfica, o aprofundamento da~~ , com validação por *JSON Schema* durante a digitação, pré-visualização do CSV de origem e um editor de mapeamento coluna a coluna,

reduzindo ainda mais a barreira de entrada para usuários menos familiarizados com a linha de comando.

- **Aprofundamento da avaliação de desempenho.** A avaliação ~~em volumes maiores e em ambientes~~ do Capítulo 5 cobriu volumes de até 262.144 linhas em uma única máquina, com os cinco SGBDs em contêineres partilhando os mesmos recursos. Quatro extensões se destacam: medir volumes maiores, na ordem de milhões de linhas; ajustar ao modo combinado o modelo que prevê o pico de memória na escolha automática do bloco, hoje ajustado apenas no modo multifonte (Seção 5.3.5); aprofundar o caminho de escrita do Cassandra — a fase dominante do custo — para além da concorrência já empregada pela estratégia em lote (Seção 4.5.1); e repetir os experimentos em um ambiente com SGBDs dedicados ~~, e a generalização do núcleo de importação a novos destinos. Consolida-se, assim, a *PolyglotImportCSV* como artefato de pesquisa e~~ e ajustados, isolando o desempenho da ferramenta das restrições do ambiente de contêineres.

- **Suporte a outros formatos de entrada.** Aceitar arquivos TSV e planilhas Excel, além de CSV, reaproveitando o mesmo mapeamento declarativo já existente.

- **Operadores de filtro adicionais e políticas de coerção configuráveis.** Ampliar o vocabulário de ~~código aberto alinhado à literatura sobre persistência poliglota e modelagem de dados heterogêneos.~~ seleção de linhas e permitir que o usuário defina como valores ambíguos ou malformados são convertidos aos tipos nativos de cada SGBD.

- **Testes de integração em ambiente conteinerizado.** A suíte de testes atual é majoritariamente unitária; prevê-se automatizar testes de integração contra os cinco SGBDs em `docker compose`, dentro de um fluxo de integração contínua (CI).

- **Generalização do núcleo de importação.** Estender a arquitetura de portas e adaptadores (Seção 4.5.2) a novos destinos — sistemas de mensageria, *data lakes* e outros SGBDs —, reaproveitando o orquestrador agnóstico de destino sem duplicar a lógica de importação.

REFERÊNCIAS

CANDEL, C. J. F.; RUIZ, D. S.; GARCíA-MOLINA, J. J. A unified metamodel for NoSQL and relational databases. *Information Systems*, v. 104, p. 101898, 2022. Citado na página 30.

CHILLóN, A. H. et al. A generic schema evolution approach for nosql and relational databases. *IEEE Transactions on Knowledge and Data Engineering*, v. 36, n. 7, p. 2774–2789, 2024. Citado na página 30.

CHILLóN, A. H. et al. Propagating schema changes to code: An approach based on a unified data model. In: *Proceedings of the Workshops of the EDBT/ICDT 2023 Joint Conference (CoMoNoS)*. [s.n.], 2023. (CEUR Workshop Proceedings, v. 3379). Disponível em: <https://ceur-ws.org/Vol-3379/CoMoNoS_2023_id251_Alberto_Hernandez_Chillon.pdf>. Citado 2 vezes nas páginas 14 e 30.

COOPER, B. F. et al. Benchmarking cloud serving systems with YCSB. In: *Proceedings of the 1st ACM Symposium on Cloud Computing (SoCC)*. [S.l.]: ACM, 2010. (SoCC '10), p. 143–154. Citado 2 vezes nas páginas 78 e 80.

DBCROSSBAR: copy tabular data between databases, CSV files, and cloud storage. 2024. <https://www.dbcrossbar.org>. Ferramenta de código aberto em Rust para migração e conversão de esquemas. Citado 2 vezes nas páginas 29 e 30.

DUGGAN, J. et al. The BigDAWG polystore system. *ACM SIGMOD Record*, v. 44, n. 2, p. 11–16, 2015. Citado na página 30.

FORD, N. *The Productive Programmer*. [S.l.]: O'Reilly Media, 2008. Citado na página 18.

FOWLER, M. *PolyglotPersistence*. 2011. Disponível em: <https://martinfowler.com/bliki/PolyglotPersistence.html>. Citado na página 18.

GLAKE, D. et al. *Towards Polyglot Data Stores: Overview and Open Research Questions*. 2022. Citado 3 vezes nas páginas 24, 30 e 31.

Hackolade. *Polyglot Data Modeling*. 2024. <https://hackolade.com/polyglot-data-modeling.html>. Modelagem conceitual com engenharia de esquema para múltiplos SGBDs. Citado na página 30.

HECHT, R.; JABLONSKI, S. Nosql evaluation: A use case oriented survey. In: *Proceedings of the 2011 International Conference on Cloud and Service Computing*. [S.l.: s.n.], 2011. p. 336–341. Citado na página 20.

KAUR, K.; SHARMA, S.; KAHLON, K. S. A middleware for polyglot persistence and data portability of big data PaaS cloud applications. *Computers, Materials & Continua*, v. 65, n. 2, p. 1625–1647, 2020. Citado na página 30.

KHINE, P. P.; WANG, Z. A review of polyglot persistence in the big data world. *Information*, v. 10, n. 4, p. 141, 2019. Citado na página 14.

KIEHN, F. et al. Polyglot data management: State of the art & open challenges. *Proceedings of the VLDB Endowment*, v. 15, n. 12, p. 3750–3753, 2022. Citado 4 vezes nas páginas 14, 24, 30 e 31.

LANDUYT, D. V. et al. A comparative performance evaluation of multi-model NoSQL databases and polyglot persistence. In: *Proceedings of the 38th ACM/SIGAPP Symposium on Applied Computing (SAC)*. [S.l.]: ACM, 2023. (SAC '23), p. 286–293. Citado 2 vezes nas páginas 78 e 95.

MongoDB, Inc. *mongoimport — Database Tools*. 2026. <https://www.mongodb.com/docs/database-tools/mongoimport/>. Utilitário de importação de CSV/JSON/TSV para o MongoDB. Citado na página 28.

MUNISWAMAIAH, M.; AGERWALA, T.; TAPPERT, C. C. Comparison of SQL, NoSQL, and NewSQL database technologies. In: *2023 IEEE International Conference on Big Data (BigData)*. [S.l.]: IEEE, 2023. p. 6230–6232. Citado na página 95.

Neo4j, Inc. *Import — Operations Manual*. 2026. <https://neo4j.com/docs/operations-manual/current/tools/neo4j-admin/neo4j-admin-import/>. Importação em massa de CSV com `neo4j-admin database import`. Citado na página 29.

PEREIRA, F. d. O.; GUERRA, E.; ROSA, R. R. A framework model for supporting transparent polyglot persistence with a unified API and extensible for different database types. In: *Proceedings of the 27th International Conference on Enterprise Information Systems (ICEIS)*. [S.l.]: SciTePress, 2025. p. 109–120. Citado na página 30.

Redis Ltd. *Bulk Loading*. 2026. <https://redis.io/docs/latest/develop/clients/patterns/bulk-loading/>. Carga em massa via `redis-cli --pipe` usando o protocolo RESP. Citado na página 27.

ROY-HUBARA, N.; SHOVAL, P.; STURM, A. Selecting databases for polyglot persistence applications. *Data & Knowledge Engineering*, v. 137, p. 101950, 2022. Citado 2 vezes nas páginas 24 e 30.

SACHDEVA, S.; VASAVA, J. Plugging and playing with variety of data using multi-model database and polyglot persistence. In: *2024 Third International Conference on Electrical, Electronics, Information and Communication Technologies (ICEEICT)*. [S.l.]: IEEE, 2024. p. 1–8. Citado na página 30.

SADALAGE, P. J.; FOWLER, M. *NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence*. [S.l.]: Pearson Education, 2013. Citado 2 vezes nas páginas 14 e 24.

SILVA, H. A. B. d.; BORNIA, L. G.; MELLO, R. d. S. Um estudo sobre modelagem poliglota de dados. In: *Anais da Escola Regional de Banco de Dados (ERBD)*. [S.l.]: Sociedade Brasileira de Computação, 2024. p. 11–20. Citado 2 vezes nas páginas 14 e 30.

TAN, R. et al. Enabling query processing across heterogeneous data models: A survey. In: *2017 IEEE International Conference on Big Data (BigData)*. [S.l.: s.n.], 2017. p. 3211–3220. Citado 2 vezes nas páginas 24 e 30.

The Apache Software Foundation. *cqlsh: the CQL shell*. 2026. <https://cassandra.apache.org/doc/latest/cassandra/managing/tools/cqlsh.html>. Inclui o comando COPY FROM, que copia dados de um arquivo CSV para uma tabela. Citado na página 28.

The Apache Software Foundation. *sstableloader*. 2026. <https://cassandra.apache.org/doc/latest/cassandra/managing/tools/sstable/sstableloader.html>. Ferramenta de carga em massa de SSTables no Apache Cassandra. Citado na página 28.

The PostgreSQL Global Development Group. *PostgreSQL Documentation: COPY*. 2026. <https://www.postgresql.org/docs/current/sql-copy.html>. Comando `COPY` para importação/exportação de dados, inclusive CSV. Citado na página 26.

YE, F. et al. A benchmark for performance evaluation of a multi-model database vs. polyglot persistence. *Journal of Database Management*, v. 34, n. 3, p. 1–20, 2023. Citado 3 vezes nas páginas 14, 18 e 78.

APÊNDICES

APÊNDICE A – JSON SCHEMAS DE CONFIGURAÇÃO NA FORMA SERIALIZADA

Este apêndice reproduz os dois documentos *JSON Schema* (rascunho 2020-12) tal como embutidos em `src/polyglotimportcsv/schemas/`. A estrutura de alto nível de ambos é descrita nas seções 4.2.1 e 4.2.3.

A.1 SCHEMA DE IMPORTAÇÃO (`IMPORT_CONFIG.SCHEMA.JSON`)

```
{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "$id": "https://polyglot-import-csv.local/schemas/import_config.schema.json",
  "title": "PolyglotImportCSV import configuration",
  "description": "Declarative mapping from named CSV sources to entities and
      relationships of one or more DBMSs. Connection settings live in the separate
      DBMS configuration.",
  "type": "object",
  "required": ["sources"],
  "properties": {
    "sources": {
      "type": "object",
      "minProperties": 1,
      "description": "Named data sources: a CSV path per entity, or a combined CSV
          whose column 0 holds each row's origin.",
      "additionalProperties": {
        "oneOf": [
          { "type": "string", "minLength": 1 },
          {
            "type": "object",
            "required": ["file", "origin_column"],
            "properties": {
              "file": { "type": "string", "minLength": 1 },
              "origin_column": { "const": true }
            },
            "additionalProperties": false
          }
        ]
      }
    },
    "postgres": { "$ref": "#/$defs/postgresMapping" },
    "mongodb": { "$ref": "#/$defs/mongoMapping" },
    "cassandra": { "$ref": "#/$defs/cassandraMapping" },
    "redis": { "$ref": "#/$defs/redisMapping" },
    "neo4j": { "$ref": "#/$defs/neo4jMapping" }
  },
  "additionalProperties": false,
  "$defs": {
    "columnSpec": {
      "type": "object",
      "description": "Leaf mapping from a CSV column to a destination field.",
      "properties": {
```

```
      "is_key": {
        "type": "boolean",
        "description": "Primary or merge key for the entity."
      },
      "csv_column": {
        "description": "CSV header name or 1-based data-column index when it
            differs from the JSON key.",
        "oneOf": [
          { "type": "string", "minLength": 1 },
          { "type": "integer", "minimum": 1 }
        ]
      },
      "schema_column": {
        "type": "string",
        "minLength": 1,
        "description": "Destination field name when it differs from the JSON key."
      },
      "db_type": {
        "type": "string",
        "description": "SQL/CQL type for DDL generation (PostgreSQL, Cassandra)."
      }
    },
    "additionalProperties": false
  },
  "columnEntry": {
    "description": "Either a leaf columnSpec or a nested object (MongoDB
        subdocuments).",
    "oneOf": [
      { "$ref": "#/$defs/columnSpec" },
      {
        "type": "object",
        "minProperties": 1,
        "additionalProperties": { "$ref": "#/$defs/columnEntry" }
      }
    ]
  },
  "filter": {
    "type": "object",
    "description": "Row predicate applied to the rows of the CSV before they are
        written.",
    "required": ["column", "operator"],
    "properties": {
      "column": { "type": "string", "minLength": 1 },
      "operator": {
        "type": "string",
        "enum": ["==", "!=", ">", "<", ">=", "<=", "in", "not_in", "each"]
      },
      "value": {},
      "target_suffix": {
        "type": "string",
        "pattern": "^[A-Za-z0-9_]*\\{value\\}[A-Za-z0-9_]*$",
        "description": "With operator 'each', template for the suffix of each part
            's name: '{value}' (exactly once, with only letters, digits and '_'
            around it) is replaced by the sanitized distinct value, and the part
            is named <entity>_<suffix>. Default: the sanitized value itself."
      }
```

```
    },
    "additionalProperties": false
  },
  "entity": {
    "type": "object",
    "description": "One logical target (table, collection, label, or Redis entity)
        .",
    "properties": {
      "columns": {
        "type": "object",
        "minProperties": 1,
        "additionalProperties": { "$ref": "#/$defs/columnEntry" }
      },
      "filters": {
        "type": "array",
        "items": { "$ref": "#/$defs/filter" }
      },
      "cassandra_partition": {
        "type": "array",
        "items": { "type": "string" },
        "description": "CSV/source column names forming the partition key (
            compound supported)"
      },
      "cassandra_cluster": {
        "type": "array",
        "items": { "type": "string" },
        "description": "Clustering columns (optional)"
      },
      "source": {
        "description": "Source name, or list of source names (union with _source
            per row). Omit to bind by the entity key name.",
        "oneOf": [
          { "type": "string", "minLength": 1 },
          { "type": "array", "minItems": 1, "items": { "type": "string", "
              minLength": 1 } }
        ]
      },
      "csv_columns": {
        "type": "array",
        "minItems": 1,
        "description": "Auto-map restriction: column names, 1-based indices, or
            ranges like \"1-5\". Only valid with auto-mapping.",
        "items": {
          "oneOf": [
            { "type": "string", "minLength": 1 },
            { "type": "integer", "minimum": 1 }
          ]
        }
      },
      "auto_map": {
        "type": "boolean",
        "description": "With 'columns' present, auto-map the whole source and let
            the manual entries override per column."
      }
    },
    "additionalProperties": false
```

```
    },
    "postgresMapping": {
      "type": "object",
      "required": ["entities"],
      "properties": {
        "entities": {
          "type": "object",
          "additionalProperties": { "$ref": "#/$defs/entity" }
        },
        "relationships": {
          "type": "object",
          "additionalProperties": {
            "type": "object",
            "required": ["from", "to", "foreign_key"],
            "properties": {
              "from": { "type": "string" },
              "to": { "type": "string" },
              "foreign_key": { "type": "string" },
              "references_key": { "type": "string" }
            },
            "additionalProperties": false
          }
        }
      },
      "additionalProperties": false
    },
    "mongoMapping": {
      "type": "object",
      "required": ["entities"],
      "properties": {
        "entities": {
          "type": "object",
          "additionalProperties": { "$ref": "#/$defs/entity" }
        }
      },
      "additionalProperties": false
    },
    "cassandraMapping": {
      "type": "object",
      "required": ["entities"],
      "properties": {
        "entities": {
          "type": "object",
          "additionalProperties": { "$ref": "#/$defs/entity" }
        }
      },
      "additionalProperties": false
    },
    "redisMapping": {
      "type": "object",
      "required": ["entities"],
      "properties": {
        "entities": {
          "type": "object",
          "additionalProperties": { "$ref": "#/$defs/entity" }
        }
```

```
      },
      "additionalProperties": false
    },
    "neo4jMapping": {
      "type": "object",
      "required": ["entities"],
      "properties": {
        "entities": {
          "type": "object",
          "additionalProperties": { "$ref": "#/$defs/entity" }
        },
        "relationships": {
          "type": "object",
          "additionalProperties": {
            "type": "object",
            "required": ["from", "to", "type"],
            "properties": {
              "from": { "type": "string" },
              "to": { "type": "string" },
              "type": { "type": "string" },
              "columns": {
                "type": "object",
                "additionalProperties": { "$ref": "#/$defs/columnSpec" }
              }
            },
            "additionalProperties": false
          }
        }
      },
      "additionalProperties": false
    }
  }
}
```

A.2 SCHEMA DE CONEXÃO (DBMS_CONFIG.SCHEMA.JSON)

```
{
  "$schema": "https://json-schema.org/draft/2020-12/schema",
  "$id": "https://polyglot-import-csv.local/schemas/dbms_config.schema.json",
  "title": "PolyglotImportCSV DBMS connection configuration",
  "description": "Connection settings for each DBMS. Lists which DBMSs are available
      ; the import configuration may only target DBMSs declared here.",
  "type": "object",
  "required": ["version"],
  "properties": {
    "version": {
      "type": "integer",
      "minimum": 1,
      "description": "Configuration format version."
    },
    "postgres": { "$ref": "#/$defs/postgresConnection" },
    "mongodb": { "$ref": "#/$defs/mongoConnection" },
    "cassandra": { "$ref": "#/$defs/cassandraConnection" },
    "redis": { "$ref": "#/$defs/redisConnection" },
    "neo4j": { "$ref": "#/$defs/neo4jConnection" }
```

```
},
"additionalProperties": false,
"$defs": {
  "postgresConnection": {
    "type": "object",
    "required": ["connection"],
    "properties": {
      "connection": {
        "type": "object",
        "properties": {
          "host": { "type": "string" },
          "port": { "type": "integer" },
          "database": { "type": "string" },
          "user": { "type": "string" },
          "password": { "type": "string" }
        },
        "additionalProperties": false
      },
      "schema": {
        "type": "string",
        "default": "public",
        "description": "Target schema for created tables."
      },
      "start": { "$ref": "#/$defs/start" }
    },
    "additionalProperties": false
  },
  "mongoConnection": {
    "type": "object",
    "required": ["connection"],
    "properties": {
      "connection": {
        "type": "object",
        "properties": {
          "uri": { "type": "string" },
          "database": { "type": "string" }
        },
        "required": ["uri", "database"],
        "additionalProperties": false
      },
      "start": { "$ref": "#/$defs/start" }
    },
    "additionalProperties": false
  },
  "cassandraConnection": {
    "type": "object",
    "required": ["connection"],
    "properties": {
      "connection": {
        "type": "object",
        "properties": {
          "hosts": { "type": "array", "items": { "type": "string" } },
          "port": { "type": "integer" },
          "keyspace": { "type": "string" },
          "protocol_version": { "type": "integer" },
```

```
          "request_timeout": { "type": "number", "exclusiveMinimum": 0, "
              description": "Client-side request timeout in seconds (default 30).
              The driver's own default of 10s is short for a bulk load." }
        },
        "required": ["hosts", "keyspace"],
        "additionalProperties": false
      },
      "start": { "$ref": "#/$defs/start" }
    },
    "additionalProperties": false
  },
  "redisConnection": {
    "type": "object",
    "required": ["connection"],
    "properties": {
      "connection": {
        "type": "object",
        "properties": {
          "host": { "type": "string" },
          "port": { "type": "integer" },
          "db": { "type": "integer" },
          "password": { "type": "string" }
        },
        "additionalProperties": false
      },
      "start": { "$ref": "#/$defs/start" }
    },
    "additionalProperties": false
  },
  "neo4jConnection": {
    "type": "object",
    "required": ["connection"],
    "properties": {
      "connection": {
        "type": "object",
        "properties": {
          "uri": { "type": "string" },
          "user": { "type": "string" },
          "password": { "type": "string" },
          "database": { "type": "string" }
        },
        "required": ["uri", "user", "password"],
        "additionalProperties": false
      },
      "start": { "$ref": "#/$defs/start" }
    },
    "additionalProperties": false
  },
  "start": {
    "description": "How to start this DBMS when it does not answer. Shown to the
       user, never executed.",
    "oneOf": [
      {
        "type": "object",
        "properties": {
```

```
            "command": { "type": "string", "minLength": 1, "description": "Command
                line that starts a DBMS installed on this machine." }
          },
          "required": ["command"],
          "additionalProperties": false
        },
        {
          "type": "object",
          "properties": {
            "compose": {
              "type": "object",
              "properties": {
                "file": { "type": "string", "minLength": 1, "description": "Docker
                    Compose file, relative to this configuration file's folder." },
                "service": { "type": "string", "minLength": 1, "description": "
                    Service of that file that runs this DBMS." }
              },
              "required": ["file", "service"],
              "additionalProperties": false
            }
          },
          "required": ["compose"],
          "additionalProperties": false
        }
      ]
    }
  }
}
```

APÊNDICE B – O ARQUIVO DE DADOS `ecommerce_join.csv`

Este apêndice reproduz, em forma tabular, o arquivo de dados do cenário exemplo, `data/ecommerce/ecommerce_join.csv`, utilizado nas seções 4.3 e 4.3.4. O arquivo contém 32 linhas de dados e 39 colunas, e resulta da **junção** (*join*) de todas as coleções de dados da fonte — usuários, endereços, produtos, categorias, estoque, pedidos, seleções de produto e carrinhos de compra — em uma única tabela larga. Por isso ele é **esparso**: cada linha representa um evento da loja virtual, identificado pela coluna `action` (`stock`, `purchase`, `select_product` ou `add_to_cart`), e preenche apenas as colunas pertinentes àquele tipo de evento — as demais permanecem vazias. A Tabela 23 resume quais grupos de colunas cada ação preenche. Este arquivo é a entrada do **modo combinado** de importação; no **modo multifonte**, os mesmos dados são fornecidos como quatro arquivos CSV separados, um por origem (`ecommerce_stock.csv`, `ecommerce_purchase.csv`, `ecommerce_select_product.csv` e `ecommerce_add_to_cart.csv`).

Tabela 23 – Grupos de colunas do `ecommerce_join.csv` preenchidos por ação.

Grupo	**Colunas**	`stock`	`purchase`	`select_product`	`add_to_cart`
Evento	`action`, `timestamp`	•	•	•	•
Usuário	`user_id`, `user_name`, `user_email`	•	•	•	•
Endereço do usuário	`street`, `neighborhood`, `state`, `country`, `zip_code`	•	•	—	—
Pedido	`order_number`, `order_date`, `order_status`	—	•	—	—
Contraparte da venda	`traded_with`, `trader_street`, `trader_neighborhood`, `trader_state`, `trader_country`, `trader_zip_code`	—	•	—	—
Avaliação e pagamento	`comment`, `rating`, `payment_method`, `quantity`	—	•	—	—
Produto	`product_id`, `product_name`, `product_variant`, `product_brand`, `product_description`, `product_image`	•	•	—	—
Categoria	`category_id`, `category_name`	•	•	—	—
Estoque	`quantity_available`, `price`, `last_restock_date`	•	•	—	—
Seleção de produto	`selected_product_id`, `suggested_product_count`	—	—	•	—
Carrinho	`shopping_cart_id`, `cart_product_id`, `cart_quantity`	—	—	—	•

Fonte: Elaborado pelo autor (2026).

Vários valores do arquivo seguem padrões regulares, o que permite apresentá-

los de forma resumida sem perda de informação. O produto `Product`N tem `product_id` N, pertence à categoria `Categoria`N (`category_id` N) e tem descrição e imagem padronizadas (`Description`M e `https://example.com/image`M`.jpg`). Cada usuário `user`N tem e-mail `user`N`@example.com`, rua `Street` N, `42` e um identificador alfanumérico (`user_id`) cujo início é dado na Tabela 24, junto com os demais dados de endereço. Nas tabelas deste apêndice, os usuários são referidos pelo nome (`user`N), tanto na coluna `user_id` quanto em `traded_with`.

Tabela 24 – Usuários do `ecommerce_join.csv` e seus dados de identificação e endereço.

Usuário	**`user_id` (início)**	**Bairro**	**Estado**	**País**	**CEP**
user1	`7fd7eee7-...`	ABC	CA	United States	12345
user2	`f246fb91-...`	DEF	SC	Brasil	84102149
user3	`09b3458a-...`	GHI	RS	Brasil	18057313
user4	`1fd3d09a-...`	JKL	TO	Brasil	19645442
user5	`0331463b-...`	MNO	RJ	Brasil	30097508
user6	`f4857da9-...`	PQR	SP	Brasil	92083256
user7	`a87df805-...`	STU	SP	Brasil	67065799
user8	`c11a1ef2-...`	VWX	SE	Brasil	18439703
user9	`d0416923-...`	YZ	AM	Brasil	18439666

Fonte: Elaborado pelo autor (2026).

Nas seções seguintes, o arquivo é apresentado em quatro blocos, um por ação. As tabelas são **verticais**: cada linha da tabela corresponde a uma coluna do CSV, e cada coluna da tabela, a uma linha de dados daquela ação, na ordem em que aparece no arquivo. Todas as colunas que a ação preenche são mostradas, com os valores exatamente como no arquivo, exceto `user_id` e `traded_with`, que aparecem pelo nome do usuário (Tabela 24). Como cada ação tem oito linhas, cada bloco ocupa duas tabelas, com as linhas 1 a 4 e 5 a 8.

B.1 LINHAS COM `ACTION == STOCK`

As oito linhas de reposição de estoque preenchem os grupos de evento, usuário, endereço, produto, categoria e estoque (21 das 39 colunas). Todas ocorrem em 02/11/2023 e, em cada uma, `last_restock_date` repete o instante do próprio evento (`timestamp`). As Tabelas 25 e 26 apresentam os valores.

Tabela 25 – Linhas `action == stock` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4).

Coluna	**Linha 1**	**Linha 2**	**Linha 3**	**Linha 4**
`action`	stock	stock	stock	stock
`timestamp`	2023-11-02 03:30:00Z	2023-11-02 06:45:00Z	2023-11-02 09:15:00Z	2023-11-02 12:00:00Z
`user_id`	user1	user2	user2	user8
`user_name`	user1	user2	user2	user8
`user_email`	user1@ example.com	user2@ example.com	user2@ example.com	user8@ example.com
`street`	Street 1, 42	Street 2, 42	Street 2, 42	Street 8, 42
`neighborhood`	ABC	DEF	DEF	VWX
`state`	CA	SC	SC	SE
`country`	United States	Brasil	Brasil	Brasil
`zip_code`	12345	84102149	84102149	18439703
`product_id`	2	3	9	8
`product_name`	Product2	Product3	Product9	Product8
`product_variant`	blue	green	black	white
`product_brand`	Microsoft	Google	Pepsi	Google
`product_description`	Description1	Description2	Description8	Description7
`product_image`	https:// example.com/ image1.jpg	https:// example.com/ image2.jpg	https:// example.com/ image8.jpg	https:// example.com/ image7.jpg
`category_id`	2	3	9	8
`category_name`	Categoria2	Categoria3	Categoria9	Categoria8
`quantity_available`	2	1	67	60
`price`	50.5	52.07	32.78	46.79
`last_restock_date`	2023-11-02 03:30:00Z	2023-11-02 06:45:00Z	2023-11-02 09:15:00Z	2023-11-02 12:00:00Z

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

Tabela 26 – Linhas `action == stock` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8).

Coluna	**Linha 5**	**Linha 6**	**Linha 7**	**Linha 8**
`action`	stock	stock	stock	stock
`timestamp`	2023-11-02 14:30:00Z	2023-11-02 17:15:00Z	2023-11-02 20:00:00Z	2023-11-02 22:30:00Z
`user_id`	user9	user9	user9	user9
`user_name`	user9	user9	user9	user9
`user_email`	user9@ example.com	user9@ example.com	user9@ example.com	user9@ example.com
`street`	Street 9, 42	Street 9, 42	Street 9, 42	Street 9, 42
`neighborhood`	YZ	YZ	YZ	YZ
`state`	AM	AM	AM	AM
`country`	Brasil	Brasil	Brasil	Brasil
`zip_code`	18439666	18439666	18439666	18439666
`product_id`	4	5	6	7
`product_name`	Product4	Product5	Product6	Product7
`product_variant`	yellow	red	orange	grey
`product_brand`	Apple	Samsung	Coca-Cola	Audi
`product_description`	Description3	Description4	Description5	Description6
`product_image`	https:// example.com/ image3.jpg	https:// example.com/ image4.jpg	https:// example.com/ image5.jpg	https:// example.com/ image6.jpg
`category_id`	4	5	6	7
`category_name`	Categoria4	Categoria5	Categoria6	Categoria7
`quantity_available`	82	57	64	1
`price`	55.94	34.21	51.98	100000
`last_restock_date`	2023-11-02 14:30:00Z	2023-11-02 17:15:00Z	2023-11-02 20:00:00Z	2023-11-02 22:30:00Z

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

B.2 LINHAS COM `ACTION == PURCHASE`

As oito linhas de compra são as mais completas do arquivo (34 das 39 colunas): acrescentam aos grupos anteriores os dados de pedido, contraparte da venda, avaliação e pagamento. As colunas de produto, categoria e estoque trazem os dados cadastrais do produto negociado, tal como nas linhas de estoque (Tabela 25), e as colunas `trader_*` trazem o endereço do vendedor. As Tabelas 27 e 28 apresentam os valores.

Tabela 27 – Linhas `action == purchase` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4).

Coluna	Linha 1	Linha 2	Linha 3	Linha 4
`action`	purchase	purchase	purchase	purchase
`timestamp`	2023-11-15 15:46:30Z	2023-11-16 03:46:30Z	2023-11-16 18:46:30Z	2023-11-17 06:46:30Z
`user_id`	user1	user2	user3	user4
`user_name`	user1	user2	user3	user4
`user_email`	user1@ example.com	user2@ example.com	user3@ example.com	user4@ example.com
`street`	Street 1, 42	Street 2, 42	Street 3, 42	Street 4, 42
`neighborhood`	ABC	DEF	GHI	JKL
`state`	CA	SC	RS	TO
`country`	United States	Brasil	Brasil	Brasil
`zip_code`	12345	84102149	18057313	19645442
`order_number`	ORD1	ORD2	ORD3	ORD4
`order_date`	2023-11-03T14:30:00-05:00	2023-11-03T12:30:00-03:00	2023-11-05T15:30:00-03:00	2023-11-07T16:20:00-03:00
`order_status`	Completed	Completed	Completed	Completed
`traded_with`	user2	user1	user9	user9
`trader_street`	Street 2, 42	Street 1, 42	Street 9, 42	Street 9, 42
`trader_neighborhood`	DEF	ABC	YZ	YZ
`trader_state`	SC	CA	AM	AM
`trader_country`	Brasil	United States	Brasil	Brasil
`trader_zip_code`	84102149	12345	18439666	18439666
`comment`	Bad	Bom	Médio	Ótimo produto
`rating`	2	4	3	5
`payment_method`	cash	cash	credit_card	credit_card
`quantity`	1	1	1	1
`product_id`	2	3	4	5
`product_name`	Product2	Product3	Product4	Product5
`product_variant`	blue	green	yellow	red
`product_brand`	Microsoft	Google	Apple	Samsung
`product_description`	Description1	Description2	Description3	Description4
`product_image`	https:// example.com/ image1.jpg	https:// example.com/ image2.jpg	https:// example.com/ image3.jpg	https:// example.com/ image4.jpg
`category_id`	2	3	4	5
`category_name`	Categoria2	Categoria3	Categoria4	Categoria5
`quantity_available`	2	1	82	57
`price`	50.5	52.07	55.94	34.21
`last_restock_date`	2023-11-02 03:30:00Z	2023-11-02 06:45:00Z	2023-11-02 14:30:00Z	2023-11-02 17:15:00Z

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

Tabela 28 – Linhas `action == purchase` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8).

Coluna	Linha 5	Linha 6	Linha 7	Linha 8
`action`	purchase	purchase	purchase	purchase
`timestamp`	2023-11-17 22:46:30Z	2023-11-18 10:46:30Z	2023-11-18 23:46:30Z	2023-11-19 15:46:30Z
`user_id`	user5	user6	user7	user8
`user_name`	user5	user6	user7	user8
`user_email`	user5@ example.com	user6@ example.com	user7@ example.com	user8@ example.com
`street`	Street 5, 42	Street 6, 42	Street 7, 42	Street 8, 42
`neighborhood`	MNO	PQR	STU	VWX
`state`	RJ	SP	SP	SE
`country`	Brasil	Brasil	Brasil	Brasil
`zip_code`	30097508	92083256	67065799	18439703
`order_number`	ORD5	ORD6	ORD7	ORD8
`order_date`	2023-11-09T12:30:00-03:00	2023-11-10T12:30:00-03:00	2023-11-11T12:30:00-03:00	2023-11-14T12:30:00-03:00
`order_status`	Completed	Completed	Completed	Completed
`traded_with`	user9	user9	user8	user2
`trader_street`	Street 9, 42	Street 9, 42	Street 8, 42	Street 2, 42
`trader_neighborhood`	YZ	YZ	VWX	DEF
`trader_state`	AM	AM	SE	SC
`trader_country`	Brasil	Brasil	Brasil	Brasil
`trader_zip_code`	18439666	18439666	18439703	84102149
`comment`	Não gostei	—	Reprovado	Bom, bonito e barato
`rating`	1	5	1	4
`payment_method`	credit_card	credit_card	credit_card	credit_card
`quantity`	1	1	1	1
`product_id`	6	7	8	9
`product_name`	Product6	Product7	Product8	Product9
`product_variant`	orange	grey	white	black
`product_brand`	Coca-Cola	Audi	Google	Pepsi
`product_description`	Description5	Description6	Description7	Description8
`product_image`	https:// example.com/ image5.jpg	https:// example.com/ image6.jpg	https:// example.com/ image7.jpg	https:// example.com/ image8.jpg
`category_id`	6	7	8	9
`category_name`	Categoria6	Categoria7	Categoria8	Categoria9
`quantity_available`	64	1	60	67
`price`	51.98	100000	46.79	32.78
`last_restock_date`	2023-11-02 20:00:00Z	2023-11-01T00:00:00-03:00	2023-11-02 12:00:00Z	2023-11-02 09:15:00Z

B.3 LINHAS COM `ACTION == SELECT_PRODUCT`

As oito linhas de seleção de produto preenchem apenas a identificação do evento, o usuário e o grupo de seleção (7 das 39 colunas): o produto visualizado (`selected_product_id`) e a quantidade de sugestões exibidas (`suggested_product_count`). As Tabelas 29 e 30 apresentam os valores.

Tabela 29 – Linhas `action == select_product` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4).

Coluna	Linha 1	Linha 2	Linha 3	Linha 4
`action`	select_ product	select_ product	select_ product	select_ product
`timestamp`	2023-11-15 15:09:30Z	2023-11-16 03:11:30Z	2023-11-16 17:50:30Z	2023-11-17 06:05:30Z
`user_id`	user1	user2	user3	user4
`user_name`	user1	user2	user3	user4
`user_email`	user1@ example.com	user2@ example.com	user3@ example.com	user4@ example.com
`selected_product_id`	11	12	22	14
`suggested_product_count`	3	3	3	3

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

Tabela 30 – Linhas `action == select_product` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8).

Coluna	Linha 5	Linha 6	Linha 7	Linha 8
`action`	select_ product	select_ product	select_ product	select_ product
`timestamp`	2023-11-17 21:56:30Z	2023-11-18 10:09:30Z	2023-11-18 23:20:30Z	2023-11-19 15:18:30Z
`user_id`	user5	user6	user7	user8
`user_name`	user5	user6	user7	user8
`user_email`	user5@ example.com	user6@ example.com	user7@ example.com	user8@ example.com
`selected_product_id`	14	21	33	17
`suggested_product_count`	3	3	3	3

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

B.4 LINHAS COM `ACTION == ADD_TO_CART`

As oito linhas de adição ao carrinho preenchem a identificação do evento, o usuário e o grupo de carrinho (8 das 39 colunas). O identificador do carrinho

(`shopping_cart_id`) segue o padrão `user:⟨user_id⟩:cart`. As Tabelas 31 e 32 apresentam os valores.

Tabela 31 – Linhas `action == add_to_cart` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 1 a 4).

Coluna	Linha 1	Linha 2	Linha 3	Linha 4
`action`	add_to_cart	add_to_cart	add_to_cart	add_to_cart
`timestamp`	2023-11-15 15:17:30Z	2023-11-16 03:27:30Z	2023-11-16 18:08:30Z	2023-11-17 06:14:30Z
`user_id`	user1	user2	user3	user4
`user_name`	user1	user2	user3	user4
`user_email`	user1@ example.com	user2@ example.com	user3@ example.com	user4@ example.com
`shopping_cart_id`	user: 7fd7eee7- 4675-4f56- ad81- 108da6cecebc: cart	user:f246fb91- e47d-44e8- a015- ce5dfd2cb8d1: cart	user: 09b3458a- 9d1d-4708- 8d2d- 3eb5fadbac9b: cart	user: 1fd3d09a- a310-4a46- bfdf- 37f2f9935a8c: cart
`cart_product_id`	3	2	2	2
`cart_quantity`	1	1	1	1

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

Tabela 32 – Linhas `action == add_to_cart` do `ecommerce_join.csv`, todas as colunas preenchidas (linhas 5 a 8).

Coluna	Linha 5	Linha 6	Linha 7	Linha 8
`action`	add_to_cart	add_to_cart	add_to_cart	add_to_cart
`timestamp`	2023-11-17 22:11:30Z	2023-11-18 10:21:30Z	2023-11-18 23:34:30Z	2023-11-19 15:29:30Z
`user_id`	user5	user6	user7	user8
`user_name`	user5	user6	user7	user8
`user_email`	user5@ example.com	user6@ example.com	user7@ example.com	user8@ example.com
`shopping_cart_id`	user: 0331463b- 7e62-44ed- 945f- 6b3c8195245b: cart	user: f4857da9- c991-4bc6- b0a9- a4277c005956: cart	user: a87df805- ad1b-4ae9- b5ad- cbb64ce9e475: cart	user: c11a1ef2- c7c0-4a47- 8128- 16dc3da9d72b: cart
`cart_product_id`	2	2	2	2
`cart_quantity`	1	1	1	1

Fonte: Elaborado pelo autor (2026), a partir de `data/ecommerce/ecommerce_join.csv`.

APÊNDICE C – ARQUIVOS DE CONFIGURAÇÃO DO CENÁRIO EXEMPLO

Este apêndice reproduz os arquivos de configuração do cenário exemplo utilizado no capítulo 4, tal como se encontram no diretório `data/ecommerce/` do repositório da ferramenta: o arquivo de importação no modo multifonte `import_config.json` (Listagem C.1), cujos fragmentos por SGBD ilustraram a seção 4.2; a sua variante para o modo combinado `import_config_combined.json` (Listagem C.2); e o arquivo de conexão `dbms_config.json` (Listagem C.3). Junto com o arquivo de dados reproduzido no Apêndice B, eles constituem as entradas completas do exemplo, e neles podem ser conferidas as entidades, fontes e chaves que fundamentam as saídas gravadas da seção 4.3.3 e as contagens da Tabela 12. O arquivo de importação inclui a coleção `orders` do MongoDB, dividida por estado com o operador `each` (Listagem 4.8).

C.1 ARQUIVO DE IMPORTAÇÃO (`IMPORT_CONFIG.JSON`)

```
{
  "sources": {
    "stock": "ecommerce_stock.csv",
    "purchase": "ecommerce_purchase.csv",
    "select_product": "ecommerce_select_product.csv",
    "add_to_cart": "ecommerce_add_to_cart.csv"
  },

  "postgres": {
    "entities": {
      "categories": {
        "source": "stock",
        "columns": {
          "category_id": { "is_key": true, "db_type": "BIGINT" },
          "category_name": { "db_type": "TEXT" }
        }
      },
      "products": {
        "source": "stock",
        "columns": {
          "product_id": { "is_key": true, "db_type": "BIGINT" },
          "product_name": { "db_type": "TEXT" },
          "product_variant": { "db_type": "TEXT" },
          "product_brand": { "db_type": "TEXT" },
          "category_id": { "db_type": "BIGINT" },
          "price": { "db_type": "NUMERIC(14,2)" }
        }
      },
      "inventory": {
        "source": "stock",
        "columns": {
          "product_id": { "is_key": true, "db_type": "BIGINT" },
          "quantity_available": { "db_type": "BIGINT" },
```

```
        "last_restock_date": { "db_type": "TIMESTAMPTZ" },
        "price": { "db_type": "NUMERIC(14,2)" }
      }
    },
    "orders": {
      "source": "purchase",
      "columns": {
        "order_number": { "is_key": true, "db_type": "TEXT" },
        "user_id": { "db_type": "TEXT" },
        "order_date": { "db_type": "TIMESTAMPTZ" },
        "order_status": { "db_type": "TEXT" },
        "payment_method": { "db_type": "TEXT" },
        "quantity": { "db_type": "BIGINT" },
        "product_id": { "db_type": "BIGINT" },
        "price": { "db_type": "NUMERIC(14,2)" },
        "comment": { "db_type": "TEXT" },
        "rating": { "db_type": "BIGINT" }
      }
    }
  },
  "relationships": {
    "product_category": {
      "from": "products",
      "to": "categories",
      "foreign_key": "category_id",
      "references_key": "category_id"
    },
    "order_product": {
      "from": "orders",
      "to": "products",
      "foreign_key": "product_id",
      "references_key": "product_id"
    }
  }
},

"mongodb": {
  "entities": {
    "product_catalog": {
      "source": "stock",
      "columns": {
        "product_id": {},
        "product_name": {},
        "product_variant": {},
        "product_brand": {},
        "product_description": {},
        "product_image": {},
        "price": {},
        "category": {
          "category_id": {},
          "category_name": {}
        },
        "stock": {
          "quantity_available": {},
          "last_restock_date": {}
        }
```

```
      }
    },
    "orders": {
      "source": "purchase",
      "columns": {
        "order_number": {},
        "user_id": {},
        "order_date": {},
        "order_status": {},
        "payment_method": {},
        "quantity": {},
        "product_id": {},
        "price": {},
        "comment": {},
        "rating": {}
      },
      "filters": [
        { "column": "state", "operator": "each", "target_suffix": "state_{value}"
            }
      ]
    }
  }
},

"cassandra": {
  "entities": {
    "user_activity_log": {
      "source": ["stock", "purchase", "select_product", "add_to_cart"],
      "columns": {
        "user_id": {},
        "timestamp": { "schema_column": "event_time" },
        "_source": { "schema_column": "event_type" },
        "product_id": {},
        "order_number": {},
        "selected_product_id": {},
        "shopping_cart_id": {}
      },
      "cassandra_partition": ["user_id"],
      "cassandra_cluster": ["timestamp"]
    }
  }
},

"redis": {
  "entities": {
    "shopping_cart": {
      "source": "add_to_cart",
      "auto_map": true,
      "columns": {
        "shopping_cart_id": { "is_key": true }
      }
    },
    "user_session": {
      "source": "select_product",
      "columns": {
        "user_id": { "is_key": true },
```

```
          "user_name": {},
          "user_email": {},
          "timestamp": { "schema_column": "last_seen" }
        }
      }
    }
  },

  "neo4j": {
    "entities": {
      "User": {
        "source": "purchase",
        "columns": {
          "user_id": { "is_key": true },
          "user_name": {},
          "user_email": {}
        }
      },
      "Product": {
        "source": "stock",
        "columns": {
          "product_id": { "is_key": true },
          "product_name": {},
          "product_brand": {}
        }
      }
    },
    "relationships": {
      "PURCHASED": {
        "from": "User",
        "to": "Product",
        "type": "PURCHASED",
        "columns": {
          "order_number": { "is_key": true },
          "quantity": {},
          "price": {},
          "rating": {}
        }
      }
    }
  }
}
```

Listagem C.1 – Arquivo de importação completo do cenário exemplo (`import_config.json`).

C.2 ARQUIVO DE IMPORTAÇÃO NO MODO COMBINADO (`IMPORT_CONFIG_COMBINED.JSON`)

No modo combinado, uma única fonte declara o arquivo largo `ecommerce_join.csv` com a marca `origin_column`, que instrui a ferramenta a tratar a primeira coluna de cada linha como a sua origem. O restante do arquivo — os mapeamentos de `postgres`, `mongodb`, `cassandra`, `redis` e `neo4j` — é **idêntico** ao do arquivo multifonte da

Listagem C.1: as entidades continuam a referir-se às origens pelos mesmos nomes (`stock`, `purchase`, `select_product` e `add_to_cart`). A Listagem C.2 reproduz apenas o bloco `sources` que distingue os dois arquivos; as reticências indicam o trecho de mapeamento omitido por ser igual ao já apresentado.

```
{
  "sources": {
    "ecommerce": { "file": "ecommerce_join.csv", "origin_column": true }
  },

  "postgres":  { ... },
  "mongodb":   { ... },
  "cassandra": { ... },
  "redis":     { ... },
  "neo4j":     { ... }
}
```

Listagem C.2 – Bloco `sources` do arquivo de importação no modo combinado (`import_config_combined.json`).

C.3 ARQUIVO DE CONEXÃO (`DBMS_CONFIG.JSON`)

```
{
  "version": 1,

  "postgres": {
    "connection": {
      "host": "127.0.0.1",
      "port": 5432,
      "database": "ecommerce",
      "user": "postgres",
      "password": "postgres"
    },
    "schema": "public",
    "start": { "compose": { "file": "../../docker-compose.yml", "service": "postgres
        " } }
  },

  "mongodb": {
    "connection": {
      "uri": "mongodb://127.0.0.1:27017",
      "database": "ecommerce"
    },
    "start": { "compose": { "file": "../../docker-compose.yml", "service": "mongodb"
         } }
  },

  "cassandra": {
    "connection": {
      "hosts": ["127.0.0.1"],
      "port": 9042,
      "keyspace": "ecommerce"
    },
    "start": { "compose": { "file": "../../docker-compose.yml", "service": "
        cassandra" } }
```

```
  },

  "redis": {
    "connection": { "host": "127.0.0.1", "port": 6379, "db": 0 },
    "start": { "compose": { "file": "../../docker-compose.yml", "service": "redis" }
        }
  },

  "neo4j": {
    "connection": {
      "uri": "bolt://127.0.0.1:7687",
      "user": "neo4j",
      "password": "password",
      "database": "neo4j"
    },
    "start": { "compose": { "file": "../../docker-compose.yml", "service": "neo4j" }
        }
  }
}
```

Listagem C.3 – Arquivo de conexão completo do cenário exemplo (`dbms_config.json`).