

UNIVERSIDADE FEDERAL DE SANTA CATARINA

**UM MÉTODO DE INDEXAÇÃO DE FORMULÁRIOS WEB
VISANDO CONSULTAS POR SIMILARIDADE**

WILLIAN VENTURA KOERICH

Florianópolis – SC

2013

UNIVERSIDADE FEDERAL DE SANTA CATARINA
DEPARTAMENTO DE INFORMÁTICA E ESTATÍSTICA
CURSO DE CIÊNCIA DA COMPUTAÇÃO

UM MÉTODO DE INDEXAÇÃO DE FORMULÁRIOS WEB
VISANDO CONSULTAS POR SIMILARIDADE

Willian Ventura Koerich

Trabalho de conclusão de
curso apresentado como parte
dos requisitos para obtenção
do grau de Bacharel em
Ciência da Computação.

Florianópolis – SC

2013

Willian Ventura Koerich

UM MÉTODO DE INDEXAÇÃO DE FORMULÁRIOS WEB
VISANDO CONSULTAS POR SIMILARIDADE

Trabalho de conclusão de curso apresentado como parte dos requisitos para obtenção do grau de Bacharel em Ciência da Computação.

Orientador: Ronaldo dos Santos Mello, Dr.

Banca Examinadora

Prof^a. Carina Friedrich Dorneles

Prof. Renato Fileto

SUMÁRIO

1. Introdução.....	7
2. DeepWeb.....	12
3. WF-Sim.....	17
4. Proposta.....	20
5. Atividades Futuras.....	27
Referências Bibliográficas.....	29

LISTA DE FIGURAS

Figura 1: Funcionamento Web Crawler Tradicional.....	12
Figura 2: Analogia da Internet vista como um oceano.....	13
Figura 3: Exemplo de Formulário Web no domínio de Passagens Aéreas.....	15
Figura 4. Arquitetura do projeto WF-Sim.....	18
Figura 5. Estrutura dos Índices Propostos.....	21
Figura 6. Exemplos de entradas de Índice encontradas nas estruturas existentes no projeto.....	22
Figura 7. Exemplo de rótulos extraídos de formulários.....	23
Figura 8. Informações sobre elementos considerados nos índices.....	25

Resumo

Motores de busca atuais não possuem suporte à buscas específicas por formulários web relacionados à Deep Web. Neste contexto, o projeto WF-Sim, em desenvolvimento no Grupo de Banco de Dados da UFSC (GBD/UFSC), propõe um processador de consultas por similaridade para formulários Web para lidar com esta limitação. Este trabalho apresenta uma técnica de indexação para buscas por similaridade em formulários web, atuando como um componente do sistema WF-Sim. Esta técnica está centrada em estruturas de índice adequadas aos principais tipos de consulta aplicados a formulários web, bem como otimizações nestas estruturas para reduzir a quantidade de entradas no índice. Pretende-se realizar experimentos sobre duas estratégias de persistência de dados suportados pelo WF-Sim foram realizados: sistema de arquivos e banco de dados. Além disso, pretende-se testar o desempenho dos índices propostos contra o tradicional índice de palavras-chave.

Palavras chave: formulários Web, DeepWeb, consultas por similaridade, Lucene.

1. Introdução

1.1 Visão Geral

Uma grande quantidade de serviços está atualmente à disposição das pessoas através da Web, como locação e vendas de veículos, reserva de hotéis, compra de livros, oferta de empregos, etc. Esses serviços disponibilizam uma diversidade de informação para consultas aos usuários, porém, seu verdadeiro conteúdo se encontra invisível pelo fato dos seus resultados de consultas serem gerados dinamicamente através de especificação de filtros via formulários web[Madhavan et al. 2009].

Esses formulários web, existentes em páginas web, são a porta de entrada ao usuário do conteúdo existente nos bancos de dados de determinado serviço. Devido à existência desses formulários web, mascarando o conteúdo dessas informações, Bergman [2001] em um artigo da Bright Planet, denominou a essa porção de conteúdo de informação escondida como *Deep web* (web oculta) ou *Hidden-databases* (bancos de dados escondidos).

A existência dessas informações presentes em formulários web e bancos de dados cujo conteúdo é recuperável através de páginas dinâmicas, torna o processo de consultas e recuperação de informação por web crawlers (indexadores web automatizados) muito difícil. De modo a recuperar essas informações e criar um repositório do conteúdo desses serviços é necessário criar um processo automatizado de investigação do conteúdo dos formulários, bem como de preenchimento dos mesmos que explore as infinitudes de

combinações possíveis de valores de seus campos, visando indexar a informação recolhida para facilitar futuros acessos.

O projeto WF-Sim visa desenvolver uma solução para amenizar esta problemática: um processador de consultas por similaridade para formulários Web [Gonçalves, 2011]. Este processador caracteriza-se por ser um software responsável pela execução de todas as tarefas necessárias à geração de um resultado a uma consulta utilizando similaridade para recuperação de formulários web, como especificação de uma consulta por parte do usuário e métricas adequadas para definição do grau de similaridade entre os formulários.

Consultas no WF-Sim ocorrem sobre elementos de formulários web indexados, sendo um elemento um campo de formulários web. No contexto deste projeto, estruturas de índice são definidas a partir de clusters gerados por um processo de *matching* de elementos de formulários, permitindo recuperação de formulários com elementos similares. Estas estruturas de índice devem ser devidamente projetadas para facilitar as consultas típicas por formulários web. Esta é a principal contribuição deste trabalho de conclusão de curso.

Este trabalho apresenta uma estratégia de indexação por similaridade para formulários web desenvolvida para o WF-Sim, visando o acesso a dados mantidos em dois tipos de mecanismos de persistência: arquivos e banco de dados relacional. Avalia-se aqui não apenas o desempenho das estruturas de índice para cada tipo de persistência, mas também quais estruturas de índice apresentaram melhor desempenho.

1.2 Objetivos

1.2.1 Geral

Desenvolvimento de uma estratégia de indexação para formulários Web visando a realização de consultas por similaridade entre formulários.

1.2.2 Específicos

- Realizar a indexação dos formulários através da estrutura de clusters desenvolvidas [Silva 2012].
- Utilizar métricas e estratégias que otimizem o processamento de consultas por similaridade para formulários web.
- Executar e avaliar um conjunto de experimentos sobre as formas de persistência (banco de dados relacional e arquivos serializados) usadas na clusterização dos formulários Web, bem como avaliar o desempenho das estruturas propostas contra o tradicional índice de palavra-chave.

1.3. Metodologia

Buscando obter conhecimento necessário sobre o assunto, este trabalho seguiu as seguintes etapas para seu desenvolvimento:

- Estudo sobre estruturas de indexação e seus respectivos enfoques de utilização;
- Estudo de ferramentas de indexação disponíveis no mercado e amplamente utilizadas para serviços de consulta;

- Estudo das métricas utilizadas nas etapas anteriores do projeto;
- Implementação do módulo de indexação.

Na primeira etapa foram estudadas as estruturas tradicionais de indexação, buscando escolher a estrutura mais adequada a atender as propriedades dos formulários Web. Na segunda etapa, foi feito estudo sobre quais ferramentas disponíveis, possuíam as características vistas como necessárias para a implementação de nossa solução pra a indexação. Na terceira etapa, foi realizado um rápido estudo sobre as métricas utilizadas no trabalho anterior [Silva 2012], visando conhecer o processo de formação dos clusters a serem indexados. Na quarta e quinta etapa são realizadas a implementação da solução desenvolvida, corresponde ao módulo de indexação de formulários Web.

1.4 Estrutura do Trabalho

Este trabalho está dividido da seguinte forma:

- Capítulo 1: Introdução – Apresentação do trabalho, com uma contextualização da área de pesquisa, das tecnologias envolvidas e trabalhos correlatos.
- Capítulo 2: Deep Web – Apresentação dos conceitos e visão geral da Deep Web.
- Capítulo 3: WF-Sim – Apresentação do projeto ao qual esse trabalho de conclusão de curso está inserido.
- Capítulo 4: Proposta – Apresentação das estruturas de índice propostas, bem como das técnicas e teoria utilizadas.

- Capítulo 5: Atividades Futuras – Apresentação das atividades a serem desenvolvidas na segunda parte do trabalho de conclusão de curso (Projeto II).

2. DeepWeb

Deep Web é o nome dado a uma grande parcela do conteúdo geral da *World Wide Web*. Esse termo surgiu a partir de um estudo elaborado nos laboratórios da BrightPlanet, por seu fundador Mike Bergman [2001], que afirma que buscas na Internet podem ser comparadas ao ato de pescar em um oceano. Ele afirma que os usuais motores de busca encontrados na Internet, como Google, Yahoo entre outros, podem ser vistos como barcos pesqueiros que conseguem apenas capturar animais (analogia com conteúdo da Internet) presentes apenas na superfície do oceano, animais estes que correspondem a uma pequena porção de uma imensidão de conteúdo disponível a todos. A essa pequena porção ao qual esses serviços de busca atuam denomina-se Surface Web.




Figura 1: Funcionamento Web Crawler Tradicional

A Surface Web corresponde ao conteúdo indexado pelos serviços de busca, ou seja, páginas web estáticas que são referenciadas por outras

páginas web e/ou possuam permissão por parte do responsável de serem anexadas ao conteúdo de serviços de busca. Como pode ser visto na Figura 1, um web *crawler*(indexador automático de páginas estáticas), através de um conjunto inicial de links de páginas web, navega através desses links disponíveis no conjunto inicial indexando todo link alcançável e que não possua restrições de acesso e indexação.




Figura 2: Analogia da Internet vista como um oceano.

Como definido anteriormente, a Deep Web é chamada “porção escondida” porque não é recuperada por consultas processadas por serviços de busca. Nesta porção “inalcançável” da web, como visto na Figura 2, são encontradas informações bastante relevantes comercialmente e para fins de pesquisa. A diversidade de informação escondida nessa porção da Web

envolve principalmente bancos de dados de diferentes domínios do conhecimento, como prestadores de serviço (revendas, hotéis, etc), bases de dados biológicos, arquivos de patentes, ofertas de emprego e negócios, acervos de livros e anúncios classificados, dentre outros.

De acordo com Bergman[2001], a Surface Web possuía, no ano de 2001, um número aproximado de 1 bilhão de documentos e tamanho total de 19 terabytes de informação. A Deep Web nesse mesmo 2001, possuía uma quantidade de 550 bilhões de documentos e tamanho total de 7.500 terabytes de informação. Sendo que um subconjunto dos 60 maiores websites encontrados na DeepWeb possuía tamanho de 750 terabytes, extrapolando com muita facilidade o tamanho obtido na época para o tamanho total da Surface Web.

A intenção do projeto WF-Sim na área de Deep Web tem como foco a exploração de conteúdo escondido através de formulários web. Um formulário web, como visto na Figura 3, é o meio pelo qual é possível obter acesso ao conteúdo dinâmico escondido na Deep Web. Os formulários web são encontrados em inúmeras páginas que reúnem ricos conjuntos de informações sobre domínios específicos. Essas informações escondidas são acessíveis mediante interação do usuário e especificação de filtros representados pela escolha de valores atribuídos aos campos dos formulários web.

Figura 3: Exemplo de Formulário Web no domínio de Passagens Aéreas.

Formulários web não possuem apenas a função de definição de filtros de entrada para bancos de dados escondidos. Muitas vezes são utilizados como recursos para o acesso a conta de email, páginas de cadastro, páginas de resposta a questionários, etc. Nesse caso, os *crawlers* voltados para a extração de dados de Deep Web necessitam possuir um direcionamento no momento de execução, ou seja, devem ser especialistas nos determinados tipos de formulários presentes na Web, visando extrair apenas aqueles pertinentes a bancos de dados escondidos.

Os formulários web são divididos em elementos. Um elemento de formulário web é normalmente composto por um conjunto de valores que são atribuídos a um rótulo. Como pode ser visto na Figura 3, o rótulo *Destino* representa o elemento de formulário de aeroportos de destino para a emissão

de uma passagem aérea e seu respectivo conjunto de valores são os aeroportos cadastrados no sistema do serviço.

3. WF-Sim

As técnicas de busca por formulários web atualmente utilizadas geralmente são baseadas no modelo de busca por palavra-chave, que executa o *matching* entre a entrada com termos existentes nos formulários. O principal exemplo é a máquina de busca *DeepPeep*¹. Visando adicionar capacidade de busca por similaridade a formulários web, o projeto WF-Sim, desenvolvido pelo GBD/UFSC², com financiamento do CNPq, se inspira no fato de que os dados disponíveis na Deep Web são relevantes para usuários que desejam encontrar formulários web que satisfaçam suas necessidades em termos de serviços online para os mais diversos fins.

O WF-Sim é um processador de busca por similaridade para formulários web baseados nos seus elementos e através de um processo de clusterização de elementos similares são apenas indexados os elementos representativos de cada cluster (ditos centroides). A motivação da criação de clusters, além de reunir informações similares sobre campos de formulários, possibilita um mecanismo de recuperação eficaz por reduzir a grande quantidade de entradas de elementos de formulário no índice e, com isso, prejudicar o desempenho de acesso.

A Figura 4 mostra a arquitetura do sistema WF-Sim. Com base em uma consulta de entrada, no caso, um conjunto de elementos denominado *formulário template*, o sistema retorna um conjunto de formulários web que

¹<http://www.deeppeep.org/>

²<http://www.gbd.inf.ufsc.br>

possuem elementos similares. O sistema possui os módulos de busca, indexação e clusterização.




Figura 4. Arquitetura do projeto WF-Sim.

No módulo de clusterização são aplicadas métricas de similaridade de modo a agrupar os formulários em clusters com elementos similares. Neste módulo, através das métricas de similaridade aplicadas [Silva, 2012], a clusterização ocorre utilizando-se uma extensão do algoritmo *Median Shift* [Jouili, Tabbone & Lacroix, 2010], onde os elementos medianos são definidos como os centróides dos clusters. Um exemplo seria um cluster formado pelos elementos “Make”, “Brand”, “Select a Make”, sendo “Make” eleito como centróide.

O módulo de indexação é o foco deste trabalho e visa criar estruturas de índice, garantir o acesso a estas estruturas e retornar os formulários relevantes. Estas estruturas foram desenvolvidas especialmente para manter informações relevantes sobre formulários web e facilitar o mapeamento de elementos do *template* para os elementos centróides indexados. A próxima seção descreve o módulo de indexação.

4. Proposta

4.1. Estruturas de Índice Propostas

Três estruturas de índice foram definidas para o acesso a dados de formulários Web: *palavra-chave*, *contexto* e *metadado*. A idéia destas estruturas foi obtida de um trabalho anterior do GBD/UFSC [Mello et. al. 2010] e adaptada à problemática de busca por similaridade em formulários Web. Estas estruturas, em particular os índices de contexto e metadado, são adequadas aos tipos de consulta mais frequentes sobre formulários web.

Consultas por contexto associam um rótulo aos seus respectivos valores presentes em um formulário. A idéia é recuperar formulários com base na contextualização de campos por domínio, ou seja, permite que o usuário recupere formulários com determinado tipo de conteúdo de campo que lhe interessa. Já consultas por metadado permitem indicar se um termo de interesse é um metadado do tipo *rótulo* ou *valor*, limitando o resultado de acordo com a natureza da informação armazenada.

A Figura 5 exemplifica as estruturas de índice desenvolvidas. O índice de palavra-chave (*keyword*) possui entradas tradicionais de termos para cada possível valor ou rótulo existente. Ele foi considerado para fins de futura avaliação de desempenho contra as outras estruturas propostas.

O índice de contexto define entradas de índice para as combinações de rótulos com seus respectivos valores presentes em elementos, no formato *nome_valor###nome_rótulo*. O índice de metadado classifica o tipo de informação que se deseja recuperar (rótulo ou valor), com entradas no formato

nome_valor###VALUE ou *nome_valor###LABEL*. Priorizou-se os termos cuja variação de conteúdo é maior (nomes de valores) no início da entrada do índice, para tornar a ordenação do índice mais adequada para fins de busca.




Figura 5. Estrutura dos Índices Propostos

A eficiência da estrutura de índice de contexto é visível ao se notar as otimizações propostas na fase de criação do índice. Usando-se a estrutura padrão de palavra-chave para simular uma consulta por contexto, seriam necessários, para cada filtro, dois acessos a mais na estrutura de índice de palavras chave, dois acessos a mais na persistência para recuperar os valores em separado e um acréscimo de processamento do sistema para processar o conjunto contextualizado resultante.




Figura 6. Exemplos de entradas de Índice encontradas nas estruturas existentes no projeto

De modo a exemplificar essa diferença resultante da proposta de um índice de contexto e metadado, veja a Figura 6. Ela mostra como são representadas as entradas existentes em cada estrutura de índice. Para processar uma consulta realizada no índice de contexto proposto, como *CIVIC####MODEL*, no índice de palavra chave é necessário realizar duas consultas ao índice, realizar a recuperação das informações de dois clusters e processar a intersecção entre os conjunto de *MODEL* e *CIVIC*. Esse processamento do índice de palavra-chave, considerando o proposto índice de contexto, realiza um acesso adicional ao índice e um acesso adicional a persistência, sem considerar que no índice de contexto a intersecção é tratada na etapa de indexação.

O índice de metadado realiza as mesmas otimizações apresentadas no exemplo anterior, possibilitando discriminar que tipo de informação que se deseja recuperar e distinguindo a informação a ser recuperada entre valor (*VALUE*) e rótulo (*LABEL*).

4.2 Limpeza de Dados

O método de indexação é responsável também pela execução de procedimentos de limpeza nos dados para melhorar a indexação dos mesmos. Para tanto, esse módulo possui um analisador que faz a uniformização dos termos, passando as letras para o formato minúsculo e removendo variações indesejadas através do processo de *stemming* e remoção de *stop words*. Esses procedimentos garantem que campos de formulários representando uma mesma informação, mas com grafias diferentes, possam ser indexados de maneira uniforme. Um exemplo é mostrado na Figura 7. Um elemento com rótulo “Do ano” e outro elemento com rótulo “Ano” sem o processo de limpeza seriam indexados em posições diferentes no índice. Com a inclusão do analisador, os campos são indexados uma única vez, com letras minúsculas sem a *stop word* “Do”.



Do Ano: 1999	Ano: 1999
------------------------	---------------------

Figura 7. Exemplo de rótulos extraídos de formulários

O analisador também é utilizado no processo de busca por formulários web. Neste caso, os rótulos dos elementos do *template* passam igualmente por um processo de limpeza. Após, os termos resultantes são verificados nos índices.

4.3 Acesso aos Índices

O acesso a formulários web relevantes através dos índices se baseia no tradicional modelo booleano de recuperação de informação [Yates & Neto, 1999]. Esse modelo possibilita a definição de filtros utilizando os operadores lógicos AND, OR e NOT.

Para ilustrar a sua utilização, suponha que um usuário necessita encontrar formulários que possuam veículos da marca (*brand*) GM e rótulo ano (*year*), ou seja, um formulário *template* com esses 2 elementos³. O módulo de Busca gera então a seguinte consulta: *GM###brand AND year###LABEL*. Estes filtros gerados são então passados para o módulo de Indexação. Considerando o filtro “GM###Select_a_make”, o módulo de Indexação o caracteriza como sendo um filtro de contexto (formado por 2 termos – rótulo e um possível valor para ele), verifica a necessidade de limpeza de dados para o rótulo. Supondo que o termo “Select_a_make” tenha apenas um (1) centróide como correspondente no índice (*make*), o filtro é convertido para “GM###make” e a entrada correspondente a este filtro é então acessada no índice de contexto. O mesmo raciocínio se aplica ao filtro “year##LABEL” e o conjunto de formulários web resultante de cada filtro retornado pelo módulo de Indexação é processado posteriormente pelo módulo de busca conforme os operadores lógicos definidos na consulta.

4.4. Implementação

³Maiores detalhes sobre como o módulo de busca processa templates e gera filtros de consulta para o módulo de indexação estão fora do escopo deste trabalho.

A ferramenta Lucene⁴ foi escolhida para a implementação das estruturas de indexação propostas [Hatcher, E.; Gospodnetic, 2005]. Lucene é uma biblioteca de software para a recuperação de informação, sendo responsável pela indexação de informação relevante. Essa ferramenta possibilita a criação de índices invertidos, abordagem típica para recuperação de informação na web [Yates & Neto, 1999]. O índice invertido é uma estrutura de dados que mapeia um documento para um entradas de índice que o contém.




Figura 8. Informações sobre elementos considerados nos índices

No contexto deste trabalho, os índices invertidos mapeiam um termo de entrada, como por exemplo, um valor de um campo, para os formulários que contenham esse determinado termo. Como pode ser visto na Figura 8, o WF-Sim persiste um elemento de formulário com as seguintes propriedades: rótulo, valores que lhe podem ser atribuídos, endereço do formulário web original (URL) e um identificador junto ao banco de dados. Neste caso, os índices

⁴<http://lucene.apache.org/core/>

definidos no Lucene apontam para a localização destes elementos persistidos em arquivos ou banco de dados.

5. Atividades Futuras

Na próxima etapa deste trabalho de conclusão de curso (Projetos II), alguns pontos devem ainda ser estudados e aprimorados com relação ao módulo de indexação. Estes pontos são discutidos a seguir.

Durante a implementação preliminar das estruturas de índice, percebeu-se que o módulo de clusterização possui um baixo grau de agregação de elementos similares de formulários, acarretando o surgimento, algumas vezes, de mais de um cluster para elementos similares entre si. Esse problema ocorre por quê a métrica de similaridade adotada considera apenas a similaridade de *string* dos termos e não a similaridade semântica. Isto acaba gerando um número grande de entradas no índice para elementos similares. Visando minimizar este problema, pretende-se utilizar algum tipo de suporte semântico, como um dicionário, e, desta forma, indexar apenas um elemento representativo de um conjunto de termos semanticamente equivalentes.

Outro ponto a ser trabalhado é a investigação e implementação de uma estrutura de *cache* que seja capaz de manter em memória os resultados de consulta mais recentes, assim como as mais requisitadas. Desta forma, consultas mais relevantes teriam seu processamento acelerado. Essa abordagem é interessante pois permitiria que alguns filtros de consulta estivessem carregados previamente em memória, reduzindo o número de acessos aos meios de persistência.

Seguinte à realização dessas modificações, a implementação deverá ter suas funcionalidades testadas. De modo a validar as estruturas de índice, pretende-se adotar dois critérios para fins de experimentação: o desempenho de acesso para os dois tipos de persistência existentes no projeto (banco de dados relacional e arquivos serializados) e um comparativo do desempenho de consultas realizadas utilizando palavras-chaves frente às duas estruturas alternativas propostas neste trabalho.

Referência Bibliográfica

- Elmasri, R.; Shamkant B. (2011). "Sistemas de Banco de Dados"; tradução Daniel Vieira, revisão técnica Enzo Seraphim e Thatyana de Faria Piola Seraphim; 6ª ed. São Paulo: Pearson Addison Wesley, 2011.
- Hatcher, E.; Gospodnetic, O. (2005). "Lucene in Action". Greenwich: Manning Publications Co, 2005.
- Gonçalves, R. et. al. (2011). "A Similarity Search Approach for *Web forms*". In: Proceedings of the IADIS International Conference IADIS WWW/Internet.
- Madhavan, J. et al. (2009) "Harnessing the Deep Web: Present and Future". In: 4th Biennial Conference on Innovative Data Systems Research (CIDR 2009).
- Silva, F. R.; Mello, R. S. (2012). "Estratégias de Persistência de Clusters em uma Técnica de Casamento por Similaridade para Web Forms". In: VIII Escola Regional de Banco de Dados (ERBD 2012).
- Mello, R. S., Pinnamaneni, R., Freire, J., (2010) Indexing Web Form Constraints., In: Journal of Information and Data Management (JIDM), Vol. 5, nº. 3, p.348-358.
- Baeza-Yates, R.; Ribeiro-Neto, R. Modern Information Retrieval. (1999). ACM Press / Addison-Wesley.
- Jouili, S., Tabbone, S. & Lacroix, V. (2010), Median graph shift: A new *clustering* algorithm for graph domain, in 'Proc. of the 20th International Conference on Pattern Recognition', Washington, DC, USA, pp. 950-953.